République Tunisienne
Ministère de l'Enseignement Supérieur
Et de la Recherche Scientifique

Université de Sfax
École Nationale d'Ingénieurs de Sfax



Cycle de Formation d'Ingénieurs
dans la Discipline
Génie informatique

ST-EN07/00

Projet de Fin d'Études

N° d'ordre : 2026/DIMA-055

MEMOIRE

Présenté à

L'École Nationale d'Ingénieurs de Sfax
Département de Génie informatique et mathématiques appliquées

En vue de l'obtention

Du Diplôme National d'Ingénieur en *Génie Informatique*

Réalisé par

Aya TELMOUDI

Plateforme de formation et de mentorat assistée par l'intelligence artificielle

Soutenu le 20 juin 2026, devant la commission d'examen :

Mme. Afef MDHAFFAR	**Présidente**
Mme. Mariem LAHAMI	**Rapportrice**
Mme. Sihem LOUKIL	**Encadrante académique**
M. Hazem RAOUAFI	**Encadrant industriel**

Année Universitaire : 2025/2026

Dédicace

Je dédie ce travail,

À mes très chers parents, **Jamila Ayat** et **Tarek Telmoudi**,
Vous m'avez offert bien plus qu'une éducation : vous m'avez appris à croire en moi, à persévérer et à ne jamais abandonner. Chaque réussite que j'accomplis porte l'empreinte de votre amour, de vos sacrifices et de votre confiance.
Ce travail vous est dédié avec toute ma gratitude et mon amour.

À mes frères et mes sœurs,
Pour votre affection, votre présence et votre soutien tout au long de ces années. Merci pour les moments de partage, les encouragements et l'énergie positive que vous m'avez apportés.
Je vous souhaite à tous réussite, bonheur et épanouissement.

À mes chères belles-sœurs,
Merci pour votre gentillesse, votre soutien et les précieux moments que nous partageons en famille. Je vous adresse à travers ce travail toute mon affection et ma sincère reconnaissance.

À mes chers neveux et nièces,
Poursuivez toujours vos rêves avec courage et confiance. J'espère que ce travail vous inspirera un jour à croire en vous autant que je crois en vous.

À mes chères amies, **Emna** et **Lina**,
Merci pour votre amitié, votre soutien et tous les moments inoubliables partagés ensemble.
Je suis reconnaissante de vous avoir à mes côtés.

À mes chères amies, **Montaha** et **Wiem**,
Merci pour tous les moments partagés durant ces années. Entre les difficultés, les sacrifices et les réussites, nous avons grandi et avancé ensemble. Je suis heureuse d'avoir vécu cette aventure à vos côtés.

À toutes les personnes qui ont contribué, de près ou de loin, à ma formation et à la réalisation de ce projet,
Je leur exprime ma profonde reconnaissance et leur adresse mes plus sincères remerciements.

À moi-même,
Pour n'avoir jamais abandonné, même lorsque le chemin semblait difficile. Ce mémoire est bien plus qu'un aboutissement : il est la preuve que la persévérance transforme les rêves en réalité.

Aya Telmoudi

Remerciements

Au terme de ce travail, je tiens à exprimer ma profonde gratitude à toutes les personnes qui ont contribué, par leur accompagnement, leurs conseils et leur soutien, à la réalisation de ce projet de fin d'études.

Je tiens à adresser mes sincères remerciements à mon encadrante académique, Mme **Sihem LOUKIL**, pour son accompagnement, ses conseils avisés et l'intérêt qu'elle a porté à l'évolution de ce travail. Ses remarques m'ont aidée à prendre du recul sur mes choix, à organiser mes idées avec plus de rigueur et à améliorer la présentation de ce projet.

J'adresse également mes sincères remerciements à mon encadrant industriel, M. **Hazem RAOUAFI**, pour son suivi, sa confiance et les orientations qu'il m'a apportées tout au long de mon stage. Son accompagnement m'a permis de mieux comprendre les besoins du projet et d'avancer de manière plus structurée dans la réalisation de la plateforme.

Je remercie également l'ensemble de l'équipe de la société **3S** qui nous a accompagnés durant cette expérience. Leur accueil, leur disponibilité et leurs échanges m'ont permis d'évoluer dans un cadre professionnel enrichissant et de mieux comprendre les attentes concrètes liées au projet.

Je tiens à exprimer ma reconnaissance à la société **Standard Sharing Software (3S)** pour m'avoir offert l'opportunité d'effectuer mon stage de fin d'études dans un environnement professionnel, stimulant et enrichissant. Cette expérience m'a permis de mettre en pratique mes connaissances, de développer de nouvelles compétences et de travailler sur un sujet concret répondant à des besoins réels.

Enfin, j'adresse mes respectueux remerciements aux membres du jury pour l'honneur qu'ils me font en acceptant d'évaluer ce travail et pour l'attention qu'ils porteront à ce mémoire.

Table des matières

Introduction générale **1**

1 Contexte général et méthodologie de travail **3**

1.1 Introduction 4
1.2 Présentation de la société 4
1.2.1 Présentation générale 4
1.2.2 Domaines d'activité de 3S 5
1.3 Contexte et objectifs du projet 5
1.4 Étude et analyse de l'existant 6
1.4.1 Solutions commercialisées 6
1.4.1.1 Google Skills 6
1.4.1.2 Duolingo 7
1.4.1.3 360Learning 7
1.4.1.4 CYPHER Learning 7
1.4.2 Solutions non commercialisées 8
1.4.2.1 OpenMAIC 8
1.4.2.2 Moodle 8
1.4.3 Synthèse comparative 9
1.4.4 Solution proposée 10
1.5 Spécification des exigences 10
1.5.1 Exigences fonctionnelles 11
1.5.2 Exigences non fonctionnelles 11
1.6 Méthodologie de travail 13
1.6.1 Analyse des approches de développement 13
1.6.1.1 Évolution des méthodes de développement et limites dans le contexte de l'IA 13
1.6.1.2 Le vibe coding : une réponse insuffisante 14
1.6.2 Approche AI-Driven Development Lifecycle (AI-DLC) 14
1.6.3 Étude comparative des frameworks d'implémentation de l'AI-DLC 15
1.6.4 Choix de l'environnement de développement 16
1.7 Conclusion 17

2 Concepts de base et étude préalable **18**
2.1 Introduction . . . 19
2.2 Fondements de l'intelligence artificielle . . . 19
2.2.1 Les modèles de langage de grande taille (LLMs) . . . 19
2.2.1.1 Définition des LLMs . . . 19
2.2.1.2 Utilisation dans le projet . . . 19
2.2.1.3 Étude du choix du LLM . . . 20
2.2.1.4 Choix retenu . . . 20
2.2.2 Les agents intelligents et les systèmes multi-agents . . . 21
2.2.2.1 Définition des agents intelligents . . . 21
2.2.2.2 Définition des systèmes multi-agents . . . 21
2.2.2.3 Utilisation dans le projet . . . 21
2.2.3 Le Retrieval-Augmented Generation (RAG) . . . 22
2.2.3.1 Définition du RAG . . . 22
2.2.3.2 Workflow général . . . 22
2.2.3.3 Agentic RAG . . . 23
2.2.3.4 Utilisation dans le projet . . . 23
2.2.4 Modèles d'Embeddings . . . 23
2.2.4.1 Définition des embeddings . . . 24
2.2.4.2 Embeddings et recherche sémantique . . . 24
2.2.4.3 Étude du choix du modèle d'embeddings . . . 24
2.2.4.4 Choix retenu . . . 24
2.2.5 Les prompts système des agents IA . . . 25
2.2.5.1 Définition . . . 25
2.2.5.2 Rôle dans les agents IA . . . 25
2.2.5.3 Utilisation dans le projet . . . 25
2.2.6 Les agent skills . . . 26
2.2.6.1 Définition . . . 26
2.2.6.2 Besoin des skills dans le projet . . . 26
2.3 Système de mémoire persistante des agents IA . . . 26
2.3.1 Présentation de Hindsight . . . 27
2.3.2 Architecture générale de Hindsight . . . 27
2.3.3 Fonctionnalités fondamentales utilisées . . . 28
2.3.4 Structure des mémoires persistantes dans Hindsight . . . 31
2.4 Conclusion . . . 32

3 Conception architecturale de la plateforme **33**
3.1 Introduction . . . 34
3.2 Architecture de la plateforme . . . 34
3.2.1 Vue d'ensemble de l'architecture . . . 34

3.2.1.1 Organisation générale des couches . . . 34
3.2.1.2 Articulation entre les couches . . . 36
3.2.1.3 Séparation entre logique métier et logique IA . . . 36
3.2.2 Architecture microservices du backend . . . 36
3.2.2.1 API Gateway . . . 36
3.2.2.2 Microservices réels et modules fonctionnels internes . . . 37
3.2.3 Architecture multi-tenant . . . 38
3.2.4 Modèle de données . . . 39
3.2.5 Architecture des agents IA . . . 40
3.2.5.1 Agent de création de cours . . . 40
3.2.5.2 Agent de coaching pédagogique . . . 41
3.2.5.3 Agent de mémoire apprenant . . . 42
3.2.5.4 Agent de recommandation . . . 43
3.2.5.5 Agent de défis personnalisés . . . 44
3.3 Choix technologiques et justification . . . 46
3.3.1 Stack frontend et backend . . . 46
3.3.2 Bases de données, IA et infrastructure . . . 47
3.4 Conclusion . . . 48

4 Réalisation **49**
4.1 Introduction . . . 50
4.2 Réalisation et présentation des modules . . . 50
4.2.1 Module Identity : gestion des identités, des accès et du multi-tenant . . . 50
4.2.1.1 Initialisation de la plateforme et création du SuperAdmin . . . 50
4.2.1.2 Gestion des tenants et isolation multi-tenant . . . 51
4.2.1.3 Gestion des utilisateurs et des comptes . . . 52
4.2.1.4 Mécanisme d'authentification . . . 53
4.2.1.5 Gestion des sessions et des jetons d'accès . . . 54
4.2.1.6 Traçabilité et audit des actions d'administration . . . 54
4.2.2 Gestion des formations, cours et progression . . . 55
4.2.2.1 Gestion administrative et création des cours . . . 55
4.2.2.2 Inscription des apprenants aux cours . . . 58
4.2.2.3 Suivi de la progression individuelle . . . 60
4.2.2.4 Objectifs d'apprentissage personnels et collectifs . . . 61
4.2.2.5 Certificats de fin de cours et vérification . . . 61
4.2.3 Mentorat et gamification . . . 63
4.2.4 Modules IA – les 5 agents . . . 65
4.3 Déploiement et hébergement de la plateforme . . . 68
4.4 Conclusion . . . 69

5 Tests et validation **70**
5.1 Introduction . . . 71
5.2 Tests et validation . . . 71
5.2.1 Tests unitaires . . . 71
5.2.2 Tests fonctionnels . . . 73
5.2.3 Tests de performance . . . 73
5.2.3.1 Temps de réponse des API et capacité sous charge . . . 74
5.2.3.2 Progression et gamification . . . 74
5.2.4 Évaluation qualitative des modules IA . . . 75
5.2.4.1 Objectif de l'évaluation . . . 75
5.2.4.2 Méthodologie avec RAGAS . . . 75
5.2.4.3 Jeu de données d'évaluation . . . 76
5.2.4.4 Résultats obtenus avec RAGAS . . . 76
5.3 Évaluation et discussion des résultats . . . 77
5.3.1 Tableau de traçabilité exigences – réalisation . . . 77
5.3.2 Limites identifiées et perspectives . . . 78
5.4 Conclusion . . . 79

Conclusion et perspectives **80**

Bibliographie **81**

Webographie **82**

Table des figures

2.1 Workflow général d'un système RAG **aws_rag** 23
2.2 Exemple de prompt système utilisé par l'Agent de recommandation 26
2.3 Architecture conceptuelle de Hindsight **hindsight_homepage** 28
2.4 Fonctionnement de l'opération *Retain* dans Hindsight **hindsight_github** . . . 29
2.5 Fonctionnement de l'opération *Recall* dans Hindsight **hindsight_github** 30
2.6 Fonctionnement de l'opération *Reflect* dans Hindsight **hindsight_github** . . . 31

3.1 Vue d'ensemble de l'architecture en couches de la plateforme 35
3.2 Organisation des microservices du backend 37
3.3 Architecture multi-tenant de la plateforme 38
3.4 Diagramme de cas d'utilisation UML des acteurs au sein d'un tenant 39
3.5 Diagramme d'activité UML de l'agent de création de cours 41
3.6 Diagramme d'activité UML de l'agent de coaching pédagogique 42
3.7 Diagramme d'activité UML de l'agent de mémoire apprenant 43
3.8 Diagramme d'activité UML de l'agent de recommandation 44
3.9 Diagramme d'activité UML de l'agent de défis personnalisés 45

4.1 Interface d'initialisation de la plateforme et création du compte SuperAdmin . . 51
4.2 Gestion multi-tenant des entreprises depuis l'espace SuperAdmin 51
4.3 Création d'un tenant avec domaine d'entreprise, limite de sièges et paramètres d'identité 52
4.4 Gestion des utilisateurs et des comptes dans l'espace d'administration d'un tenant 53
4.5 Interface de connexion avec authentification applicative et option Azure Entra ID 54
4.6 Consultation des traces d'audit des actions d'administration 55
4.7 Formulaire de création d'un cours traditionnel dans l'espace d'administration . . 56
4.8 Organisation d'un cours avec ses leçons, vidéos, ressources et quiz 56
4.9 Interface de création d'un cours généré par IA avec les champs de saisie du besoin pédagogique 57
4.10 Résultat de génération affichant le brouillon du cours, ses leçons et ses éléments éditables 58
4.11 Catalogue des cours disponibles pour l'apprenant 59

4.12 Page de détail d'un cours avec l'action d'inscription 59
4.13 Espace My Learning affichant les cours inscrits de l'apprenant 59
4.14 Tableau de progression individuelle affichant les indicateurs d'apprentissage de l'utilisateur 60
4.15 Suivi détaillé de la progression dans une leçon 60
4.16 Interface de suivi des objectifs personnels et des objectifs d'équipe 61
4.17 Liste des certificats obtenus par l'apprenant 61
4.18 Détail d'un certificat délivré 62
4.19 Page de vérification publique d'un certificat après scan du QR code 63
4.20 Illustration de l'obtention des points XP 63
4.21 Affichage des badges obtenus et non encore débloqués 64
4.22 Interface de gestion des badges personnalisés 64
4.23 Classement des apprenants selon leur progression 65
4.24 Interaction entre l'apprenant et l'agent de coaching IA 66
4.25 Recommandations personnalisées proposées par l'agent IA 67
4.26 Challenge personnalisé généré par l'agent IA 68

5.1 Exécution des tests unitaires avec pytest et affichage du résultat dans le terminal 72

Liste des tableaux

1.1 Comparaison des solutions existantes 9
1.2 Exigences fonctionnelles 11
1.3 Exigences non fonctionnelles 12
1.4 Comparaison des frameworks AI-DLC disponibles en 2025–2026 15
1.5 Comparaison des principaux outils de développement assisté par l'IA 16

2.1 Étude comparative des LLMs 20
2.2 Comparaison des modèles d'embeddings utilisables pour le système RAG 24

3.1 Tableau comparatif des technologies frontend et backend retenues 46
3.2 Tableau comparatif des technologies de données, IA et infrastructure 47

5.1 Périmètre des tests unitaires réalisés 72
5.2 Scénarios de tests fonctionnels réalisés 73
5.3 Latence moyenne des API selon le nombre d'utilisateurs simultanés 74
5.4 Temps de réponse des actions de progression et gamification 75
5.5 Scores RAGAS par agent 76
5.6 Tableau de traçabilité exigences fonctionnelles – réalisation 77

Introduction générale

Dans un contexte professionnel en constante mutation, où la transformation numérique et l'intelligence artificielle redéfinissent les modes d'apprentissage et de gestion des compétences, la formation continue devient un levier stratégique essentiel pour les entreprises. L'émergence de l'intelligence artificielle générative et des systèmes multi-agents ouvre aujourd'hui de nouvelles perspectives pour concevoir des plateformes d'apprentissage plus intelligentes, adaptatives et personnalisées.

C'est dans cette dynamique que s'inscrit notre projet de fin d'études, réalisé au sein de la société Standard Sharing Software (3S), acteur majeur de l'intégration de solutions technologiques en Tunisie et en Afrique. Ce projet vise à concevoir et développer une plateforme web intelligente de formation et de mentorat, capable de centraliser la gestion des compétences des collaborateurs du Groupe 3S tout en offrant un accompagnement pédagogique personnalisé basé sur l'intelligence artificielle.

La solution proposée repose sur une architecture microservices multi-tenant intégrant plusieurs agents intelligents spécialisés, chacun ayant un rôle précis dans le processus d'apprentissage : génération de contenus pédagogiques, coaching personnalisé, recommandation de ressources, suivi des apprenants et gestion de la mémoire contextuelle. Ces agents s'appuient sur des modèles de langage avancés, un système de Retrieval-Augmented Generation (RAG) agentique, ainsi qu'un mécanisme de mémoire persistante permettant d'assurer un suivi cohérent et évolutif des utilisateurs.

Ce rapport présente l'ensemble des travaux réalisés au cours de ce projet et s'articule autour de cinq chapitres principaux, chacun mettant en évidence une étape clé de la démarche.

Le premier chapitre, intitulé « Contexte général et méthodologie de travail », présente le cadre du projet, l'organisme d'accueil ainsi que la problématique étudiée. Il expose également les exigences fonctionnelles et non fonctionnelles, ainsi que la méthodologie de développement adoptée.

Le deuxième chapitre, « Concepts de base et étude préalable », introduit les fondements théoriques liés à l'intelligence artificielle générative, aux grands modèles de langage, aux systèmes multi-agents et aux approches de type RAG, qui constituent la base scientifique du projet.

Le troisième chapitre, « Conception et architecture de la plateforme », décrit l'architecture globale du système, notamment l'organisation en microservices, le modèle multi-tenant, ainsi

que la conception des agents intelligents et les choix technologiques retenus.

Le quatrième chapitre, « Réalisation », présente les différents modules développés ainsi que les fonctionnalités implémentées, en mettant l'accent sur les composants liés à l'intelligence artificielle, à la gestion des formations et à l'expérience utilisateur.

Le cinquième chapitre, « Tests et validation », détaille la stratégie de test adoptée ainsi que les résultats obtenus à travers les tests unitaires, fonctionnels et de performance, ainsi que l'évaluation des modules d'intelligence artificielle.

Enfin, la conclusion générale synthétisera les apports du projet, évaluera le niveau d'atteinte des objectifs fixés et proposera des perspectives d'amélioration et d'évolution future de la plateforme.

Chapitre 1

Contexte général et méthodologie de travail

Contents

1.1 Introduction **4**

1.2 Présentation de la société **4**

1.2.1 Présentation générale 4

1.2.2 Domaines d'activité de 3S 5

1.3 Contexte et objectifs du projet **5**

1.4 Étude et analyse de l'existant **6**

1.4.1 Solutions commercialisées 6

1.4.2 Solutions non commercialisées 8

1.4.3 Synthèse comparative 9

1.4.4 Solution proposée 10

1.5 Spécification des exigences **10**

1.5.1 Exigences fonctionnelles 11

1.5.2 Exigences non fonctionnelles 11

1.6 Méthodologie de travail **13**

1.6.1 Analyse des approches de développement 13

1.6.2 Approche AI-Driven Development Lifecycle (AI-DLC) 14

1.6.3 Étude comparative des frameworks d'implémentation de l'AI-DLC . . 15

1.6.4 Choix de l'environnement de développement 16

1.7 Conclusion **17**

1.1 Introduction

Ce chapitre a pour objectif de présenter le cadre général du projet de fin d'études. Nous commençons par une présentation de l'entreprise d'accueil ainsi que de ses principaux domaines d'activité. Ensuite, nous exposons la problématique à l'origine du projet ainsi que les objectifs visés. Nous étudions également les solutions existantes dans le domaine concerné afin d'identifier leurs limites avant de présenter la solution proposée. Enfin, nous présentons les exigences du projet ainsi que la méthodologie de travail adoptée durant sa réalisation.

1.2 Présentation de la société

Cette section est consacrée à la présentation de la société d'accueil au sein de laquelle ce projet a été réalisé. Nous y décrivons son historique, son positionnement dans l'écosystème technologique tunisien ainsi que ses principaux domaines d'intervention.

1.2.1 Présentation générale

Standard Sharing Software, désignée sous l'acronyme **3S site3s**, est une entreprise tunisienne fondée en 1988, spécialisée dans l'intégration de solutions technologiques et les services informatiques à forte valeur ajoutée. Forte de plus de 35 ans d'expérience, elle s'est imposée comme un acteur de référence sur le marché tunisien et africain, en accompagnant les organisations publiques et privées dans leurs projets de modernisation numérique.

3S se distingue par une approche globale qui couvre l'ensemble du cycle de vie des projets IT : de l'étude et de l'audit des besoins jusqu'au déploiement et au pilotage des solutions mises en place. Cette capacité à intervenir de bout en bout, combinée à des partenariats avec des éditeurs et constructeurs de renommée mondiale, lui permet de proposer des réponses adaptées aux exigences les plus complexes.

3S est la filiale fondatrice du **Groupe 3S site3sgroup**, un groupe technologique tunisien structuré autour de deux pôles complémentaires. Le **pôle IT** regroupe les filiales dédiées aux technologies de l'information : **3S** (intégration IT), **GlobalNet** (accès Internet grand public), **GlobalNet Business** (services cloud et sécurité pour entreprises), **Advancia Training** (formation et certification IT), **Smartup** (édition de progiciels), **Hexabyte** (connectivité et solutions high-tech), **Cyberesa** (solutions e-tourisme) et **Pro2C** (centre de contact multicanal). Le **pôle Cleantech** quant à lui rassemble des entités orientées développement durable, telles que **Africa Solar** (énergies renouvelables), **CandyLed** (éclairage LED), **BioPack** (bioplastiques) et **Océane** (construction navale).

1.2.2 Domaines d'activité de 3S

En tant que pôle IT du groupe, 3S intervient sur l'ensemble de la chaîne de valeur liée à la transformation numérique des entreprises. Ses domaines d'activité s'articulent autour de six axes principaux :

- **Intégration des infrastructures IT :** 3S accompagne ses clients dans la conception et le déploiement d'environnements informatiques robustes et évolutifs, conformes aux standards internationaux, depuis l'audit initial jusqu'à la mise en production ;
- **Réseaux et connectivité :** l'entreprise propose des solutions d'interconnexion et de télécommunication garantissant des échanges fiables et sécurisés entre les différents composants des systèmes d'information ;
- **Datacenter et continuité de service :** virtualisation, sauvegarde, stockage et haute disponibilité constituent les piliers de l'offre datacenter de 3S, visant à assurer la résilience et la protection des données critiques ;
- **Cloud computing :** la société déploie des architectures cloud privées, hybrides et publiques, ainsi que des services d'hébergement managés, répondant aux besoins croissants des entreprises en matière de flexibilité et d'agilité ;
- **Cybersécurité :** 3S propose une offre complète de sécurité informatique intégrant des pare-feux nouvelle génération, des systèmes SIEM, une protection Anti-DDoS, des solutions de gestion des identités et des accès (IAM), ainsi que des centres opérationnels SOC et NOC dédiés à la surveillance et à la réponse aux incidents ;
- **Communication unifiée et collaboration :** l'entreprise intègre des outils de communication unifiée permettant d'améliorer la coordination et la productivité des équipes, en facilitant les échanges au sein des organisations.

Cette palette de compétences, combinée à l'écosystème du Groupe 3S, permet à 3S de se positionner comme un partenaire technologique global, capable de répondre aux enjeux actuels de la numérisation, de la sécurisation des systèmes d'information et de l'évolution des infrastructures modernes.

1.3 Contexte et objectifs du projet

Ce projet intitulé *« Plateforme de formation et de mentorat assistée par l'intelligence artificielle »* a été réalisé au sein de la société Standard Sharing Software (3S) dans le cadre du Projet de Fin d'Études en vue de l'obtention du diplôme national d'ingénieur.

Dans un environnement professionnel en constante évolution, les entreprises peinent à assurer une montée en compétences efficace de leurs collaborateurs. Les dispositifs de formation classiques montrent aujourd'hui leurs limites, notamment en matière de motivation et d'engagement des apprenants face à des contenus statiques et peu personnalisés.

Les observations réalisées au sein de 3S montrent que l'intégration et l'évolution des

collaborateurs nécessitent un accompagnement régulier afin de faciliter l'acquisition de compétences, le suivi de la progression et l'adaptation des parcours aux besoins réels de chaque profil. Toutefois, cet accompagnement dépend fortement de la disponibilité des encadrants, ce qui peut créer des écarts de progression et rendre difficile l'évaluation objective des acquis.

À cela s'ajoute l'absence de mécanismes structurés de coaching et de mentorat dans les plateformes existantes, qui restent souvent rigides et peu intelligentes.

Dans ce contexte, le projet répond à un besoin réel de structuration des parcours de formation et d'amélioration du suivi et de l'accompagnement des collaborateurs. Il vise à concevoir une plateforme web intelligente centralisant les formations, les compétences et le mentorat, avec des mécanismes de personnalisation, de recommandation et de gamification afin d'améliorer l'engagement et l'efficacité de l'apprentissage.

1.4 Étude et analyse de l'existant

Avant d'entamer la conception de notre solution, nous avons mené une étude approfondie des plateformes existantes dans le domaine de la formation et du développement professionnel. Cette analyse se concentre sur les plateformes qui intègrent des approches modernes telles que le coaching intelligent piloté par l'IA, la gamification, la génération automatique de cours et l'utilisation de fonctionnalités d'assistance conversationnelle. Elle s'intéresse également à des critères pratiques tels que la confidentialité des données et le modèle tarifaire de chaque solution. L'objectif est d'évaluer dans quelle mesure ces plateformes parviennent à améliorer la motivation des apprenants, à renforcer leur engagement et à leur offrir un accompagnement personnalisé et efficace. Cette étude s'articule autour de deux catégories : les solutions commerciales disponibles sur le marché, et les solutions non commerciales issues de la communauté open source ou de la recherche académique.

1.4.1 Solutions commercialisées

Plusieurs plateformes commerciales ont intégré des fonctionnalités avancées d'intelligence artificielle pour améliorer l'expérience d'apprentissage en entreprise. Nous présentons ci-dessous les solutions les plus représentatives du marché actuel, en nous concentrant sur leurs approches pédagogiques, leurs fonctionnalités clés et leur positionnement.

1.4.1.1 Google Skills

Lancée en octobre 2025, Google Skills **googleSkillsFeatures** est une plateforme d'apprentissage unifiée regroupant près de 3 000 cours, labs et certifications issus de l'écosystème Google (Google Cloud, DeepMind, Grow with Google et Google for Education). Elle cible des profils allant du débutant au développeur confirmé, avec un accent fort sur l'IA générative et les technologies cloud. La plateforme mise sur la gamification pour stimuler l'engagement

des apprenants à travers des ligues de points, des badges de compétences, des streaks d'apprentissage et des tableaux de classement par équipe. Pour les entreprises clientes de Google Cloud, un accès organisationnel gratuit est disponible via Google Skills for Orgs, permettant d'assigner des parcours aux équipes et de suivre leur progression via des tableaux de bord analytiques.

1.4.1.2 Duolingo

Duolingo **duolingo** est une plateforme d'apprentissage des langues largement reconnue pour son approche basée sur la gamification. Elle intègre des mécanismes tels que les points d'expérience, les séries de connexions quotidiennes (streaks) et les classements, afin de renforcer l'engagement et la régularité des apprenants. Son modèle pédagogique repose sur des exercices courts et interactifs, favorisant un apprentissage progressif et motivant.

Ces dernières années, la plateforme a renforcé son orientation vers l'intelligence artificielle en automatisant une grande partie de la création de ses contenus pédagogiques, avec le déploiement de nombreux cours générés par IA. Par ailleurs, son offre premium Duolingo Max intègre des fonctionnalités avancées basées sur des modèles de langage, notamment des agents conversationnels permettant de simuler des dialogues réalistes, ainsi qu'un moteur adaptatif qui ajuste dynamiquement la difficulté des exercices en fonction du niveau et des performances de l'apprenant.

1.4.1.3 360Learning

360Learning **learning360** est une plateforme d'apprentissage collaborative destinée aux entreprises, basée sur un modèle où les employés deviennent eux-mêmes créateurs de contenus pédagogiques. Elle favorise ainsi une approche d'apprentissage pair-à-pair et une production de formations directement issues des experts métiers.

La plateforme se distingue par son fort niveau d'engagement des apprenants, lié à son intégration dans le travail quotidien et à son approche collaborative. Elle intègre également des fonctionnalités d'intelligence artificielle, notamment des outils de recommandation de contenus et de création assistée permettant de transformer rapidement des documents (PDF, PowerPoint, Word) en modules de formation structurés.

1.4.1.4 CYPHER Learning

CYPHER Learning **cypherLearning** est une plateforme LMS et LXP alimentée par l'IA, positionnée comme solution tout-en-un pour la création, la gestion et la personnalisation des parcours d'apprentissage. Son outil phare, CYPHER Copilot, permet de générer automatiquement des cours complets, des quiz et des évaluations à partir de ressources fournies par l'organisation, avec un mécanisme de vérification de l'exactitude des contenus générés (AI Crosscheck). La plateforme propose également une gamification pilotée par l'IA, adaptant les

points, badges et niveaux au profil de chaque apprenant, ainsi que des parcours adaptatifs qui s'ajustent dynamiquement selon les résultats obtenus.

1.4.2 Solutions non commercialisées

Des initiatives issues de la communauté open source et de la recherche académique proposent des alternatives libres, transparentes et hautement personnalisables aux plateformes propriétaires. Ces solutions présentent un intérêt particulier pour les organisations qui souhaitent conserver la maîtrise de leurs données ou expérimenter des approches pédagogiques innovantes.

1.4.2.1 OpenMAIC

OpenMAIC **openmaic** (Open Multi-Agent Interactive Classroom) est une plateforme open source développée par l'équipe de recherche MAIC de l'Université de Tsinghua et publiée en 2025. Elle propose une approche pédagogique basée sur des systèmes multi-agents, allant au-delà des chatbots éducatifs classiques.

À partir d'un document ou d'un sujet décrit en langage naturel, la plateforme génère automatiquement une expérience d'apprentissage interactive complète incluant des supports de cours, des quiz, des simulations et des activités collaboratives. Cette interaction est assurée par plusieurs agents spécialisés (enseignant, assistant et apprenants simulés) reproduisant une dynamique de classe réaliste.

Sur le plan technique, OpenMAIC repose sur une architecture d'orchestration d'agents et est compatible avec plusieurs fournisseurs de modèles de langage. En tant que solution open source, elle peut être déployée sur une infrastructure locale, offrant ainsi un contrôle total sur les données et leur confidentialité.

1.4.2.2 Moodle

Moodle **moodle** est la plateforme LMS open source la plus utilisée dans le monde, déployée dans plus de 240 pays par des universités, des gouvernements et des entreprises. Elle offre un ensemble complet de fonctionnalités couvrant la création de cours, la gestion des évaluations, les forums de discussion, le suivi de progression et le support SCORM. Sa bibliothèque de plus de 1 800 plugins permet d'étendre ses capacités avec des modules de gamification, d'apprentissage adaptatif et d'intégrations tierces. La version 4.5, publiée en octobre 2024, introduit un sous-système d'intelligence artificielle ouvrant la voie aux fonctionnalités de tutorat intelligent et de recommandation de contenus. Entièrement auto-hébergeable, Moodle offre un contrôle total sur les données et représente un choix privilégié pour les organisations soumises à des contraintes réglementaires strictes.

1.4.3 Synthèse comparative

L'analyse des solutions présentées met en évidence des différences importantes selon les critères qui sont au cœur de notre projet. Les plateformes commerciales offrent des fonctionnalités avancées mais à des coûts élevés et avec un contrôle limité sur les données, tandis que les solutions open source garantissent la souveraineté des données mais manquent de fonctionnalités intelligentes intégrées. En se basant sur les solutions étudiées, aucune plateforme ne combine l'ensemble de ces fonctionnalités dans un environnement unifié destiné au contexte du Groupe 3S. Le tableau 1.1 présente une synthèse comparative des solutions étudiées selon les critères retenus pour notre projet.

TABLE 1.1 – Comparaison des solutions existantes

Critère	**Google Skills**	**Duolingo**	**360Learning**	**CYPHER Learning**	**OpenMAIC**	**Moodle**
Coaching IA	Non	Oui (GPT-4)	Partiel	Non	Oui (multi-agents + LLM)	Non
Gamification	Oui	Oui	Oui	Oui (pilotée par IA)	Non	Via plugin
Génération auto de cours	Non	Oui (IA générative)	Oui (PDF/DOCX)	Oui (CYPHER Copilot)	Oui (multi-agents)	Non
Assistance conversationnelle	Non	Oui (Lily)	Non	Non	Oui (AI Teacher + assistants)	Non
Mentorat structuré	Non	Non	Partiel	Non	Non	Non
Suivi des compétences	Partiel	Non	Oui	Oui	Non	Partiel
Confidentialité	Faible (Google)	Faible (Duolingo)	Bonne (RGPD, AI Act)	Moyenne (cloud)	Totale (auto-hébergeable)	Totale (auto-hébergeable)
Architecture multi-tenant	Non	Non	Non	Oui (plan Enterprise)	Non	Partiel
Open source	Non	Non	Non	Non	Oui (AGPL-3.0, BYO LLM)	Oui (GPL)
Coût	**Gratuit (Starter) ; Pro 29$/mois googleSkills**	**Gratuit ; Super Duolingo 12,99$/mois duolingoMax**	**8$/utilisateur/mois (Team) learning360pricing**	**Sur devis (dès 10 000$/an) cypherLearning**	**Gratuit (OSS) ; API LLM + hébergement requis openmaic**	**Gratuit (OSS) ; hébergement + support moodle**

1.4.4 Solution proposée

L'analyse des solutions existantes montre qu'aucune d'entre elles ne répond de manière complète aux besoins d'une entreprise souhaitant centraliser la formation, le suivi des compétences et l'accompagnement intelligent des collaborateurs au sein d'un outil unifié. À partir de ce constat, nous proposons une plateforme web centralisée permettant de gérer les utilisateurs, les formations, les compétences et les parcours d'apprentissage dans un environnement unique.

La plateforme intègre des fonctionnalités d'intelligence artificielle destinées à accompagner les apprenants tout au long de leur parcours de formation. Un module de coaching intelligent fournit une assistance pédagogique personnalisée en fonction du profil de l'utilisateur, de sa progression et de ses objectifs d'apprentissage. Il permet d'obtenir des explications complémentaires et des clarifications adaptées afin de faciliter la compréhension des contenus étudiés.

La solution permet également la génération automatique de contenus pédagogiques à partir de consignes simplifiées et propose des recommandations de ressources adaptées au niveau et aux besoins de chaque apprenant. Afin de renforcer l'acquisition des connaissances, la plateforme suggère également des exercices et des défis personnalisés permettant de mettre en pratique les notions étudiées et de consolider les compétences développées.

La plateforme permet également de proposer des parcours d'apprentissage adaptés au contexte interne du Groupe 3S. Les recommandations et les contenus générés tiennent compte des ressources internes, des compétences cibles, du niveau de l'apprenant et des besoins métiers des différentes filiales. Des mécanismes de gamification, tels que les points, les badges, les niveaux et les tableaux de progression, sont intégrés afin de renforcer la motivation et d'encourager la complétion des formations.

Enfin, la solution est adaptée à l'organisation du Groupe 3S, qui regroupe plusieurs filiales aux besoins de formation différents. Chaque filiale dispose d'un espace indépendant pour gérer ses utilisateurs, ses formations, ses parcours, ses contenus et ses paramètres, tout en partageant une infrastructure commune. Cette organisation permet de préserver la confidentialité des données, de contrôler l'accès aux contenus internes et d'offrir aux responsables une vision unifiée du développement professionnel des collaborateurs.

1.5 Spécification des exigences

Cette section présente l'ensemble des exigences identifiées pour la plateforme. Ces exigences ont été définies à partir de l'analyse des besoins du Groupe 3S et des limites des solutions existantes étudiées dans la section précédente. Elles se divisent en deux catégories : les exigences fonctionnelles, qui décrivent ce que le système doit faire, et les exigences non fonctionnelles, qui définissent comment il doit le faire.

1.5.1 Exigences fonctionnelles

Les exigences fonctionnelles décrivent les fonctionnalités que le système doit offrir pour répondre aux besoins des utilisateurs. Le tableau 1.2 présente l'ensemble des exigences fonctionnelles identifiées.

TABLE 1.2 – Exigences fonctionnelles

ID	Catégorie	Description
EF-01	Authentification	Le système doit permettre l'authentification sécurisée des utilisateurs.
EF-02	Gestion des rôles	Le système doit gérer plusieurs rôles : super administrateur, administrateur, manager, expert pédagogique et membre d'équipe.
EF-03	Gestion des profils	Le système doit permettre la création et la modification des profils utilisateurs.
EF-04	Multi-tenant	Le système doit permettre la gestion de plusieurs entreprises (tenants) de façon cloisonnée.
EF-05	Gestion des formations	Le système doit permettre la création, la modification, la suppression et la consultation des formations.
EF-06	Suivi des apprentissages	Le système doit permettre le suivi de l'avancement de chaque apprenant dans son parcours.
EF-07	Recommandation IA	Le système doit recommander des contenus de formation adaptés au profil et aux besoins de chaque utilisateur.
EF-08	Coaching IA	Le système doit intégrer un module d'assistance intelligent capable d'accompagner l'utilisateur tout au long de son apprentissage.
EF-09	Génération de cours	Le système doit permettre la génération automatique de cours à partir de documents ou de sujets fournis.
EF-10	Évaluations	Le système doit permettre la création et la gestion de quiz.
EF-11	Gamification	Le système doit permettre l'attribution de points, badges et récompenses selon la progression des apprenants.
EF-12	Recherche	Le système doit permettre la recherche et la consultation des formations disponibles.
EF-13	Traçabilité	Le système doit enregistrer les activités des utilisateurs sur la plateforme.

1.5.2 Exigences non fonctionnelles

Les exigences non fonctionnelles définissent les critères de qualité que le système doit respecter, indépendamment des fonctionnalités qu'il offre. Conformément à la norme ISO/IEC 25010 **iso25010**, ces exigences couvrent des dimensions telles que la sécurité, la performance, la maintenabilité et l'ergonomie. Le tableau 1.3 présente l'ensemble des exigences non fonctionnelles retenues.

TABLE 1.3 – Exigences non fonctionnelles

ID	**Catégorie**	**Description**
ENF-01	Sécurité	L'authentification est assurée via JWT (HS256) avec access token (15 min) et refresh token (7 jours). Les mots de passe locaux sont hashés avec bcrypt. Un SSO est également implémenté via Azure Entra ID, avec une configuration par tenant (client_id, tenant_id).
ENF-02	Confidentialité	La plateforme doit garantir que les contenus de formation, les parcours pédagogiques et les données de progression restent accessibles uniquement dans le périmètre de l'entité concernée. Pour cela, la plateforme repose sur une architecture multi-tenant. L'isolation des données est assurée via tenant_id (utilisé dans les tables principales). Chaque JWT contient le tenantId, tandis que le SuperAdmin dispose d'un accès global sans appartenance à un tenant.
ENF-03	Performance	Les API principales de la plateforme répondent en moins de 2 secondes pour la majorité des requêtes courantes, à l'exception des traitements liés à l'intelligence artificielle (RAG, génération de contenu et recommandations).
ENF-04	Disponibilité	La plateforme est conçue pour assurer une disponibilité continue grâce à une architecture backend stable et découplée, garantissant le fonctionnement des services essentiels même en cas de défaillance partielle.
ENF-05	Évolutivité	L'architecture microservices permet l'ajout de nouveaux modules ou fonctionnalités sans impact sur les services existants.
ENF-06	Modularité	Le système est structuré en services indépendants (authentification, formation, IA, etc.), facilitant la maintenance et l'évolution de la plateforme.
ENF-07	Maintenabilité	Le code backend et frontend est organisé en couches avec une séparation claire des responsabilités, ce qui facilite les interventions, la correction et l'évolution du système.
ENF-08	Extensibilité	La plateforme permet l'intégration de nouveaux agents IA et de nouvelles fonctionnalités sans modification de l'architecture existante.

ID	Catégorie	Description
ENF-09	Ergonomie	L'interface utilisateur propose une navigation simple et intuitive adaptée aux différents profils (apprenant, administrateur, mentor).
ENF-10	Accessibilité	La plateforme est accessible via navigateur web et s'adapte aux différents formats d'écran (desktop, tablette).
ENF-11	Intégrité des données	La plateforme doit garantir l'intégrité des certificats générés et empêcher toute falsification. Pour cela, un mécanisme de signature numérique RS256 (RSA avec SHA-256) est utilisé afin de vérifier l'authenticité des certificats. Chaque certificat est également associé à un QR code permettant sa vérification via une URL sécurisée.
ENF-12	Journalisation	Les événements système sont tracés via un système d'audit logs composé de deux tables : identity_audit_logs (actions utilisateurs, scoped tenant) et super_admin_audit_logs (actions globales plateforme).
ENF-13	Déployabilité	Les composants de la plateforme (backend, frontend et services IA) sont conteneurisés avec Docker, permettant un déploiement indépendant, reproductible et simplifié.

1.6 Méthodologie de travail

La réalisation d'une plateforme intelligente intégrant des fonctionnalités d'intelligence artificielle, de mentorat et de gestion des compétences nécessite une démarche de développement adaptée à la complexité du projet. Cette section présente la méthodologie adoptée pour conduire les différentes phases de réalisation, depuis la définition des besoins jusqu'à l'implémentation de la solution. Après une analyse des approches traditionnelles de gestion de projet logiciel, nous présentons le cadre méthodologique retenu ainsi que les outils utilisés pour assister le développement.

1.6.1 Analyse des approches de développement

1.6.1.1 Évolution des méthodes de développement et limites dans le contexte de l'IA

Les méthodes agiles telles que Scrum, Kanban et Extreme Programming (XP) constituent depuis les années 2000 un cadre de référence du développement logiciel. Basées sur des itérations courtes, la collaboration d'équipes pluridisciplinaires et une livraison continue de valeur, elles

ont permis d'améliorer la flexibilité et la réactivité par rapport aux approches traditionnelles de type waterfall.

Cependant, avec l'émergence de l'intelligence artificielle générative et des systèmes agentiques, ces méthodes montrent certaines limites. Le modèle agile repose sur des équipes humaines structurées (développeurs, testeurs, Product Owner, UX designers) et sur des cérémonies régulières, ce qui devient moins adapté dans un contexte où les tâches peuvent être partiellement automatisées ou orchestrées par des systèmes intelligents.

Plusieurs travaux récents indiquent que l'intégration de l'IA dans le cycle de développement logiciel accélère fortement la production, rendant les cycles de type sprint de plus en plus courts et parfois inadaptés. Par ailleurs, les méthodes agiles actuelles ne prévoient pas explicitement le rôle de l'IA dans le processus de développement, celle-ci étant encore considérée comme un simple outil d'assistance.

Dans ce contexte, le développement assisté par l'IA remet en question certaines pratiques classiques, notamment la durée des sprints, la structure des équipes et la gestion des interactions humaines, ouvrant la voie à de nouveaux modèles de développement plus flexibles et automatisés.

1.6.1.2 Le vibe coding : une réponse insuffisante

Dans ce contexte de remise en question des méthodes de développement traditionnelles face à l'essor de l'intelligence artificielle, une première approche expérimentale a émergé sous le nom de *vibe coding*, concept popularisé par Andrej Karpathy en 2025 **sarkar2025vibecoding**.

Cette approche consiste à laisser l'IA générer du code à partir d'enchaînements de prompts conversationnels, sans réelle structuration du processus de développement. Si elle permet un prototypage rapide, elle montre rapidement ses limites pour des applications en production, notamment en raison de l'absence d'architecture cohérente, de faiblesses en matière de sécurité et de la perte progressive du contexte de l'agent.

Ainsi, en 2026, l'industrie s'oriente davantage vers des approches plus structurées, capables de tirer parti de l'IA tout en conservant un cadre rigoureux de développement logiciel.

1.6.2 Approche AI-Driven Development Lifecycle (AI-DLC)

L'**AI-Driven Development Lifecycle (AI-DLC)** est une méthodologie proposée par AWS en 2025 **awsblog2025**, visant à intégrer l'intelligence artificielle comme acteur central du cycle de développement logiciel, tout en maintenant une supervision humaine pour les décisions critiques.

Contrairement aux approches agiles traditionnelles, l'AI-DLC place la spécification et la planification au cœur du processus, en considérant l'IA comme un collaborateur à part entière.

Ce cadre repose principalement sur la planification avant exécution, la décomposition des tâches, la gestion rigoureuse du contexte et la validation humaine continue. Le cycle

de développement est structuré en trois phases principales : l'inception, la construction et l'opération, couvrant respectivement la définition des besoins, l'implémentation et le déploiement/maintenance.

1.6.3 Étude comparative des frameworks d'implémentation de l'AI-DLC

L'adoption croissante des approches AI-Driven Development Lifecycle a conduit à l'émergence de plusieurs frameworks destinés à structurer le développement assisté par l'intelligence artificielle. Parmi les solutions les plus répandues figurent GitHub Spec Kit **githubspeckit**, BMAD Method **bmad2025**, GSD Framework **gsd2026** et AWS Kiro **kiro2025**. Ces frameworks se distinguent par leur mode de gestion du contexte, leur niveau d'automatisation, leur compatibilité avec les outils de développement assistés par IA ainsi que leur complexité d'utilisation.

Le tableau 1.4 présente une comparaison des principales caractéristiques de ces frameworks selon plusieurs critères techniques et organisationnels.

TABLE 1.4 – Comparaison des frameworks AI-DLC disponibles en 2025–2026

Critère	**GitHub Spec Kit**	**BMAD Method**	**GSD Framework**	**AWS Kiro**
Gestion du contexte	Artefacts Markdown versionné	Agents à contexte restreint	Sous-agents à contexte frais	Steering files persistants
Agents spécialisés	Non	Oui (12 agents)	Oui (orchestrateur + sous-agents)	Partiel (hooks automatiques)
Compatibilité	30+ intégrations	Claude, Cursor, Copilot	Claude Code, Codex CLI, OpenCode	VS Code (Code OSS)
Courbe d'apprentissage	Faible	Élevée	Moyenne	Faible à moyenne
Vérification intégrée	Checklists qualité	QA agent	Verify step dédié	Hooks automatiques
Open source	Oui	Oui	Oui	Non (propriétaire AWS)
Idéal pour	Initiation SDD, projets simples	Équipes entreprise, specs complexes	Projets multi-agents, solo dev	Projets AWS-centric

L'analyse de ce tableau montre que GitHub Spec Kit constitue une solution légère et

accessible pour initier une démarche de développement orientée spécifications. BMAD Method propose une approche plus complète basée sur des agents spécialisés, mais sa complexité peut représenter un frein pour un projet réalisé par un développeur unique. AWS Kiro offre un environnement intégré performant mais demeure fortement lié à l'écosystème AWS.

Le GSD Framework se distingue quant à lui par sa gestion efficace du contexte, sa compatibilité avec les principaux outils de développement assistés par IA et son adaptation aux projets développés de manière autonome. Ces caractéristiques en font une solution particulièrement adaptée aux besoins du présent projet.

1.6.4 Choix de l'environnement de développement

À l'issue de l'étude comparative présentée précédemment, le **GSD Framework** a été retenu comme cadre méthodologique du projet. Ce choix s'explique par sa gestion efficace du contexte, sa compatibilité avec les principaux outils de développement assistés par l'IA et sa capacité à structurer le travail sous forme de tâches atomiques. Ces caractéristiques répondent particulièrement aux besoins d'un projet complexe développé de manière autonome avec l'assistance de l'intelligence artificielle.

La mise en œuvre de cette méthodologie s'est déroulée en trois étapes principales. La première étape a consisté à définir les exigences fonctionnelles et non fonctionnelles de la plateforme, à identifier les cas d'usage prioritaires et à élaborer une feuille de route structurée. Le framework GSD a été utilisé pour organiser le projet en modules cohérents et en tâches de taille réduite afin de faciliter leur réalisation.

Dans un second temps, plusieurs outils de développement assisté par l'IA ont été évalués selon des critères tels que la qualité du code généré, le coût, les performances et la gestion du contexte. Les résultats de cette comparaison sont présentés dans le tableau 1.5.

TABLE 1.5 – Comparaison des principaux outils de développement assisté par l'IA

Outil	**Qualité du code**	**Coût**	**Performance**	**Gestion du contexte**
OpenCode	Moyenne	Gratuit	Lente	Basique
Cline	Bonne	Payant	Correcte	Partielle
Antigravity	Correcte	Gratuit	Correcte	Limitée
GitHub Copilot	Bonne	Payant	Bonne	Faible
Codex CLI	**Très bonne**	**Accessible**	**Bonne**	**AGENTS.md natif**

À l'issue de cette évaluation, **Codex CLI** a été retenu comme principal outil d'assistance au développement en raison de la qualité des résultats obtenus, de sa stabilité et de ses capacités avancées de gestion du contexte.

Enfin, la phase de réalisation de la plateforme a été conduite avec Codex CLI, complété par des configurations et instructions personnalisées permettant d'adapter l'assistance fournie aux besoins spécifiques du projet. Cette approche a facilité le développement progressif des différentes fonctionnalités tout en maintenant la cohérence globale de la solution.

1.7 Conclusion

Dans ce chapitre, nous avons présenté le contexte général du projet ainsi que l'environnement professionnel dans lequel il s'inscrit. L'analyse des solutions existantes a permis d'identifier leurs limites et de justifier la conception d'une plateforme centralisée dédiée au développement des compétences et à l'accompagnement intelligent des apprenants.

Nous avons également défini les exigences fonctionnelles et non fonctionnelles de la solution, puis présenté la méthodologie retenue, basée sur l'approche AI-DLC, le GSD Framework et l'outil Codex CLI.

Le chapitre suivant sera consacré à la présentation de l'architecture de la plateforme et des principaux choix techniques retenus pour sa mise en œuvre.

Chapitre 2

Concepts de base et étude préalable

Contents

2.1 Introduction 19

2.2 Fondements de l'intelligence artificielle 19

2.2.1 Les modèles de langage de grande taille (LLMs) 19

2.2.2 Les agents intelligents et les systèmes multi-agents 21

2.2.3 Le Retrieval-Augmented Generation (RAG) 22

2.2.4 Modèles d'Embeddings 23

2.2.5 Les prompts système des agents IA 25

2.2.6 Les agent skills 26

2.3 Système de mémoire persistante des agents IA 26

2.3.1 Présentation de Hindsight 27

2.3.2 Architecture générale de Hindsight 27

2.3.3 Fonctionnalités fondamentales utilisées 28

2.3.4 Structure des mémoires persistantes dans Hindsight 31

2.4 Conclusion 32

2.1 Introduction

Après avoir présenté le contexte général du projet, l'étude de l'existant, les exigences ainsi que la méthodologie de travail adoptée, ce chapitre introduit les fondements théoriques et les choix d'architecture de la solution proposée.

La plateforme repose sur plusieurs concepts clés de l'intelligence artificielle moderne, notamment les modèles de langage (LLMs), les systèmes multi-agents, le Retrieval-Augmented Generation (RAG), les embeddings, les prompts système et les agent skills, qui constituent la base du fonctionnement des agents intelligents.

Le chapitre présente également le système de mémoire persistante basé sur Hindsight, ainsi que l'architecture globale de la solution et ses principaux choix techniques, afin de préparer la phase d'implémentation.

2.2 Fondements de l'intelligence artificielle

La plateforme développée dans le cadre de ce projet repose sur plusieurs concepts fondamentaux de l'intelligence artificielle moderne qui constituent la base de son fonctionnement.

Les sections suivantes présentent les principaux fondements mobilisés, notamment les modèles de langage de grande taille, les agents intelligents et les systèmes multi-agents, les représentations vectorielles sémantiques, les prompts système et les agent skills.

2.2.1 Les modèles de langage de grande taille (LLMs)

Les modèles de langage de grande taille (LLMs) occupent une place essentielle dans les systèmes d'intelligence artificielle modernes. Leur compréhension est indispensable pour comprendre leur intégration et leur rôle au sein de la plateforme.

2.2.1.1 Définition des LLMs

Un grand modèle de langage **cloudflare_llm** (Large Language Model, LLM) est un modèle d'intelligence artificielle entraîné sur de très vastes corpus de données textuelles afin d'apprendre les structures statistiques et sémantiques du langage naturel. Il est capable de comprendre, générer et manipuler du texte avec un haut niveau de cohérence, en produisant des sorties adaptées au contexte d'entrée.

2.2.1.2 Utilisation dans le projet

Dans la plateforme, les LLMs sont utilisés comme moteur principal des fonctionnalités intelligentes. Ils interviennent notamment dans :

— la génération de contenus pédagogiques,

— l'analyse des requêtes des utilisateurs,

— la production de réponses contextualisées,

— la génération d'activités personnalisées.

Ces modèles ne sont pas exploités de manière isolée. Ils sont intégrés dans un pipeline applicatif enrichi par un contexte métier (cours, progression de l'apprenant, objectifs pédagogiques), et leurs sorties peuvent être structurées (ex. JSON) afin d'être exploitées par les différents modules du système.

2.2.1.3 Étude du choix du LLM

Le choix du modèle de langage repose sur plusieurs critères : qualité des réponses, capacité à gérer de longs contextes, coût d'utilisation, facilité d'intégration et compatibilité avec les besoins du projet.

Une comparaison de plusieurs modèles a été réalisée afin d'identifier la solution la plus adaptée aux contraintes de la plateforme (tableau 2.1).

TABLE 2.1 – Étude comparative des LLMs

Modèle	**Fournisseur**	**Nombre de paramètres**	**Fenêtre de contexte**	**Coût du LLM**
openai/gpt-oss-120b :free **openai_gpt_oss**	OpenRouter / OpenAI OSS	117 milliards	131K tokens **openrouter_gpt_oss_free**	0 $ / 1M tokens en entrée ; 0 $ / 1M tokens en sortie **openrouter_gpt_oss_free**
gemma-4-4b	Serveur interne de la société	4 milliards	Non communiqué publiquement	0 $ / 1M tokens en entrée ; 0 $ / 1M tokens en sortie
GPT-5.4 mini **openai_gpt54_mini_intro**	OpenAI	Non communiqué	400K tokens **openai_gpt54_mini_intro**	0,75 $ / 1M tokens en entrée ; 4,50 $ / 1M tokens en sortie **openai_api_pricing**
Claude Haiku 4.5 **anthropic_haiku**	Anthropic	Non communiqué	200K tokens **anthropic_haiku_system_card**	1 $ / 1M tokens en entrée ; 5 $ / 1M tokens en sortie **anthropic_pricing**
Gemini 3.1 Flash-Lite **cloudflare_gemini_31_flash_lite**	Google / Google	Non communiqué	1M tokens **cloudflare_gemini_31_flash_lite**	0,25 $ / 1M tokens en entrée ; 1,50 $ / 1M tokens en sortie **google_gemini_pricing**
Llama 3.1 8B Instant **groq_llama_31_8b_model**	Groq	8 milliards	131072 tokens **groq_llama_31_8b_model**	0,05 $ / 1M tokens en entrée ; 0,08 $ / 1M tokens en sortie **groq_pricing**
Mistral Small 4 **mistral_small_4_model_card**	Mistral AI	Non communiqué	256K tokens **mistral_small_4_model_card**	0,10 $ / 1M tokens en entrée ; 0,30 $ / 1M tokens en sortie **mistral_pricing**

2.2.1.4 Choix retenu

Le modèle retenu est *openai/gpt-oss-120b :free*, accessible via OpenRouter. Il est utilisé comme modèle principal pour la génération de contenus pédagogiques, l'assistance aux utilisateurs et la production de réponses contextualisées.

Ce choix s'explique par :

— sa grande fenêtre de contexte (131K tokens),
— son coût nul en version gratuite,
— sa capacité à produire des réponses structurées.

Un modèle interne de l'entreprise a également été considéré, mais son usage reste limité au réseau interne, ce qui réduit sa flexibilité lors du développement et des tests. Il est donc conservé comme solution complémentaire.

2.2.2 Les agents intelligents et les systèmes multi-agents

Les agents intelligents sont une brique essentielle des systèmes IA modernes, permettant de structurer des comportements autonomes basés sur les LLMs.

Cette section présente leur rôle ainsi que celui des systèmes multi-agents dans l'architecture de la plateforme.

2.2.2.1 Définition des agents intelligents

Un agent intelligent **google_ai_agents** peut être défini comme un composant logiciel fondé sur l'intelligence artificielle, conçu pour analyser un contexte, prendre des décisions et exécuter des actions afin d'atteindre un objectif donné. Contrairement à un programme déterministe classique, il peut s'appuyer sur des mécanismes de raisonnement, de planification, de mémoire et d'adaptation pour produire un comportement plus autonome.

Dans les systèmes récents basés sur les modèles de langage de grande taille, le LLM joue souvent le rôle de moteur de raisonnement. L'agent, quant à lui, est défini par son rôle, ses outils, sa mémoire, ses consignes et son intégration dans un processus applicatif.

2.2.2.2 Définition des systèmes multi-agents

Un système multi-agents **google_multi_agent_system** correspond à une architecture dans laquelle plusieurs agents spécialisés interviennent au sein d'un même environnement logiciel. Chaque agent prend en charge une responsabilité précise, échange des informations avec les autres composants du système et contribue à la réalisation d'un objectif global.

Cette approche permet de remplacer une logique centralisée par une organisation distribuée, dans laquelle chaque agent possède un rôle clair. Elle favorise ainsi la séparation des responsabilités, la modularité et l'évolution progressive du système.

2.2.2.3 Utilisation dans le projet

Dans le cadre de ce projet, une approche multi-agents a été adoptée afin de structurer les différentes fonctionnalités intelligentes de la plateforme. Elle permet de répartir les responsabilités entre plusieurs agents spécialisés, chacun intervenant sur un aspect précis du système.

Cette organisation permet d'éviter une logique centralisée unique et favorise la modularité ainsi que l'évolution indépendante des fonctionnalités IA.

Les principaux agents intégrés dans la plateforme sont : l'agent de création de cours, l'agent de coaching pédagogique, l'agent de mémoire apprenant, l'agent de recommandation et l'agent de défis personnalisés.

Ainsi, cette architecture multi-agents assure une meilleure spécialisation des traitements tout en maintenant une cohérence globale du système

2.2.3 Le Retrieval-Augmented Generation (RAG)

Le Retrieval-Augmented Generation (RAG) est un mécanisme important utilisé dans la plateforme pour améliorer les réponses des modèles de langage.

Cette section présente son principe général et son intégration dans le projet.

2.2.3.1 Définition du RAG

Le Retrieval-Augmented Generation (RAG) **aws_rag** est une approche qui consiste à enrichir la génération d'un LLM par des informations récupérées depuis une source de connaissances externe. Au lieu de produire une réponse uniquement à partir des connaissances apprises pendant son entraînement, le modèle reçoit d'abord des éléments pertinents issus d'une base documentaire, d'une base de données ou d'une mémoire spécialisée. Ces informations sont ensuite ajoutées au contexte de la requête afin de guider la génération de la réponse.

2.2.3.2 Workflow général

Le fonctionnement général d'un système RAG suit plusieurs étapes. Les données utiles sont d'abord préparées, découpées en fragments et transformées en représentations exploitables pour la recherche, généralement à l'aide d'embeddings. Lorsqu'un utilisateur formule une requête, le système recherche les fragments les plus pertinents dans la base de connaissances, puis les injecte dans le prompt transmis au LLM. Le modèle génère alors une réponse en s'appuyant à la fois sur la question de l'utilisateur et sur le contexte récupéré. La figure 2.1 illustre les différentes étapes de ce processus.

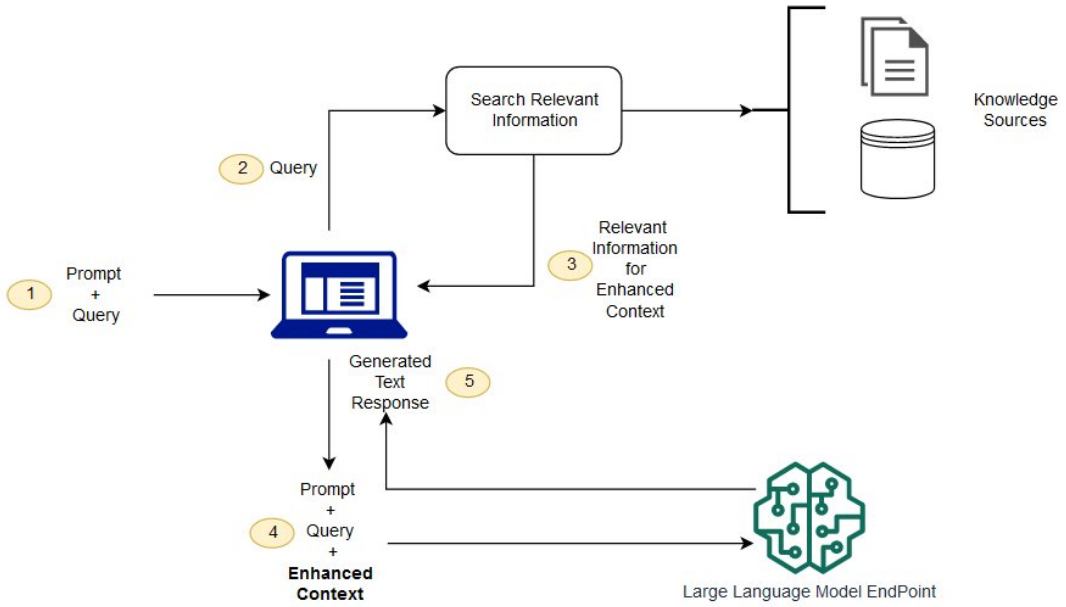


FIGURE 2.1 – Workflow général d'un système RAG **aws_rag**

2.2.3.3 Agentic RAG

L'*agentic RAG* **ibm_agentic_rag** désigne une évolution du RAG dans laquelle la récupération d'information n'est pas seulement déclenchée de manière automatique, mais pilotée par un ou plusieurs agents capables de décider quelles sources consulter, quels outils utiliser et comment intégrer les informations récupérées dans leur raisonnement. Cette approche rend le RAG plus flexible qu'un pipeline classique, car l'agent peut adapter la récupération au contexte de la requête.

2.2.3.4 Utilisation dans le projet

Dans la plateforme, l'Agentic RAG est utilisé pour les fonctionnalités nécessitant une forte contextualisation, notamment le coaching pédagogique, les recommandations, les défis personnalisés et l'exploitation de la mémoire des cours et des apprenants. Il permet aux agents de récupérer les informations pertinentes en fonction du contexte utilisateur et de l'objectif pédagogique.

Cette approche est plus adaptée qu'un RAG classique, car chaque agent (coaching, recommandation, défis) exploite un contexte différent. L'Agentic RAG permet ainsi d'adapter dynamiquement la récupération d'informations à chaque responsabilité, afin de produire des réponses plus cohérentes et personnalisées.

2.2.4 Modèles d'Embeddings

Les embeddings jouent un rôle central dans la recherche sémantique et le RAG.

Cette section en présente le principe et l'utilisation dans le projet.

2.2.4.1 Définition des embeddings

Les incorporations **ibm_embedding**, ou embeddings, désignent des représentations vectorielles denses de données textuelles dans un espace mathématique de haute dimension. Elles permettent de représenter des objets, tels que du texte, des images ou de l'audio, sous forme de points dans un espace vectoriel continu dont la position porte une signification sémantique. Dans le cas du texte, la proximité géométrique entre deux vecteurs reflète ainsi une similarité de sens entre les éléments représentés.

2.2.4.2 Embeddings et recherche sémantique

Dans les systèmes basés sur les Transformers, les embeddings représentent des passages entiers et non seulement des mots isolés. Ils permettent ainsi la recherche sémantique, où le système compare le sens des requêtes et des contenus plutôt que des mots-clés exacts. Dans un système RAG, cette représentation sert à retrouver les fragments de connaissances les plus proches de la requête de l'utilisateur.

2.2.4.3 Étude du choix du modèle d'embeddings

Le choix du modèle d'embeddings influence la qualité de la recherche sémantique dans le système RAG. Une comparaison des principaux modèles est présentée dans le tableau 2.2 selon plusieurs critères techniques et économiques.

TABLE 2.2 – Comparaison des modèles d'embeddings utilisables pour le système RAG

Modèle	**Fournisseur**	**Dimension**	**Coût et déploiement**
BAAI/bge-small-en-v1.5 **baai_bge_small**	Local / Sentence-Transformers	384	Gratuit à l'usage, exécution locale, modèle léger d'environ 130 Mo
text-embedding-3-small **openai_embedding_models**	OpenAI	1536	Service cloud payant : 0,02 $ / 1M tokens **openai_embedding_pricing**
mistral-embed **mistral_embed_models**	Mistral AI / LiteLLM	1024	Service cloud payant : 0,10 $ / 1M tokens en entrée **mistral_embed_model_card**
embed-english-v3.0 **cohere_embed_models**	Cohere	1024	Service cloud avec clé API ; prix public par token non précisé pour ce modèle dans la page officielle **cohere_pricing**
gemini-embedding-001 **google_vertex_embeddings**	Google / Vertex AI	3072 par défaut, dimension configurable	Service cloud : gratuit en free tier, puis 0,15 $ / 1M tokens en entrée **google_gemini_pricing**

2.2.4.4 Choix retenu

À partir de cette comparaison, le modèle *BAAI/bge-small-en-v1.5* a été retenu pour la génération des embeddings dans le système RAG du projet. Ce choix s'explique par son

exécution locale, son coût nul à l'usage et sa légèreté, puisqu'il produit des vecteurs de 384 dimensions.

Ce modèle offre un compromis adapté entre qualité de recherche sémantique, consommation mémoire et simplicité d'intégration. Les tests réalisés ont montré qu'il répond aux besoins de récupération d'informations de la plateforme. Il est également cohérent avec le système de mémoire utilisé dans le projet, qui supporte les embeddings locaux basés sur ce modèle **hindsight_models**.

2.2.5 Les prompts système des agents IA

Cette section présente les prompts système des agents IA ainsi que leur utilisation dans la plateforme.

2.2.5.1 Définition

Un prompt système **kern_system_prompt** correspond à un ensemble de consignes placées en amont de l'interaction avec le LLM. Il permet d'orienter le modèle avant même la demande de l'utilisateur, en précisant le rôle attendu, les règles de comportement, le style de réponse, les contraintes fonctionnelles et les limites à ne pas dépasser.

2.2.5.2 Rôle dans les agents IA

Dans une application basée sur des agents IA, le prompt système permet de spécialiser un modèle généraliste afin qu'il adopte un comportement cohérent avec un contexte métier précis. Chaque agent reçoit ainsi des consignes qui définissent son périmètre d'action, les informations à prendre en compte et la forme attendue de sa réponse.

2.2.5.3 Utilisation dans le projet

Dans ce projet, les prompts système sont utilisés pour construire et spécialiser les agents de coaching, de mémoire apprenant, de recommandation et de génération de défis. Ils permettent également d'intégrer les éléments dynamiques nécessaires au raisonnement des agents, comme l'historique de conversation, le profil de l'apprenant, le contexte du cours ou les mémoires récupérées.

Ces prompts imposent aussi des formats de sortie structurés, notamment en JSON, afin que les réponses générées soient directement exploitables par les services applicatifs de la plateforme.

La figure 2.2 présente un exemple de prompt système utilisé dans le projet pour encadrer l'analyse des difficultés de l'apprenant par l'Agent de recommandation.

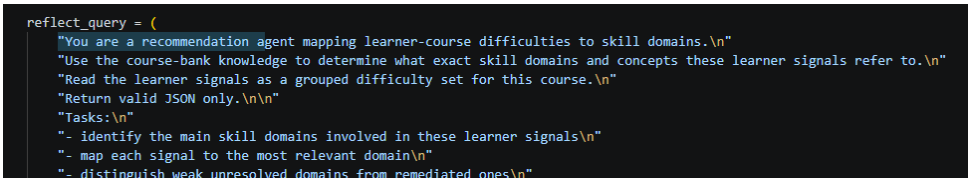


FIGURE 2.2 – Exemple de prompt système utilisé par l'Agent de recommandation

2.2.6 Les agent skills

Cette section présente les agent skills et leur intégration dans la plateforme.

2.2.6.1 Définition

Les agent skills **agent_skills_overview** désignent des blocs d'instructions spécialisés qu'un agent peut utiliser pour traiter une tâche précise. Contrairement au prompt système, qui définit le comportement général de l'agent, un skill apporte une logique plus ciblée : il précise une méthode de raisonnement, des règles de décision ou une procédure adaptée à un cas particulier.

2.2.6.2 Besoin des skills dans le projet

Dans le cadre de ce projet, l'utilisation des skills permet d'éviter de centraliser l'ensemble des règles de fonctionnement dans un seul prompt système. Cette approche rend les agents plus modulaires et facilite leur évolution.

Lorsqu'une tâche spécifique doit être exécutée, l'agent peut activer uniquement le skill correspondant, sans alourdir son contexte avec des instructions inutiles. Cela permet une meilleure séparation des responsabilités et une organisation plus claire du comportement des agents.

Ainsi, les skills contribuent à structurer les logiques de traitement de manière indépendante, tout en améliorant la maintenabilité et la flexibilité du système.

2.3 Système de mémoire persistante des agents IA

La mémoire persistante permet aux agents IA de conserver et réutiliser des informations au-delà d'une seule session. Dans la plateforme, elle sert à exploiter le parcours de l'apprenant, ses interactions et les contenus déjà traités.

Cette section présente la solution retenue pour la gestion de cette mémoire, son fonctionnement et son intégration dans l'architecture de la plateforme.

2.3.1 Présentation de Hindsight

Hindsight **hindsight_github** est un système de mémoire conçu pour les agents IA. Il fournit une couche dédiée à la mémorisation, à la récupération et à l'exploitation des informations retenues au fil des interactions, permettant ainsi de construire une mémoire durable et réutilisable.

Dans ce projet, Hindsight est retenu comme solution de mémoire persistante pour les agents IA, afin de conserver un contexte exploitable au fil des interactions et de renforcer la continuité des traitements.

2.3.2 Architecture générale de Hindsight

L'architecture de Hindsight repose sur deux niveaux principaux. Le premier correspond à la couche d'intégration, permettant aux agents de communiquer avec le système via une API, un SDK ou un client. Cette couche expose les opérations essentielles de gestion de mémoire telles que *retain*, *recall* et *reflect*. Le second niveau est la couche de mémoire, organisée en *memory banks* afin d'isoler les contextes selon l'utilisateur, le domaine ou le cours.

Au sein de chaque *memory bank*, les informations sont structurées sous forme d'unités enrichies contenant des entités, des relations et des données temporelles. Ces éléments sont ensuite consolidés en différentes formes de connaissances, allant de faits simples à des représentations contextuelles plus globales (Figure 2.3).

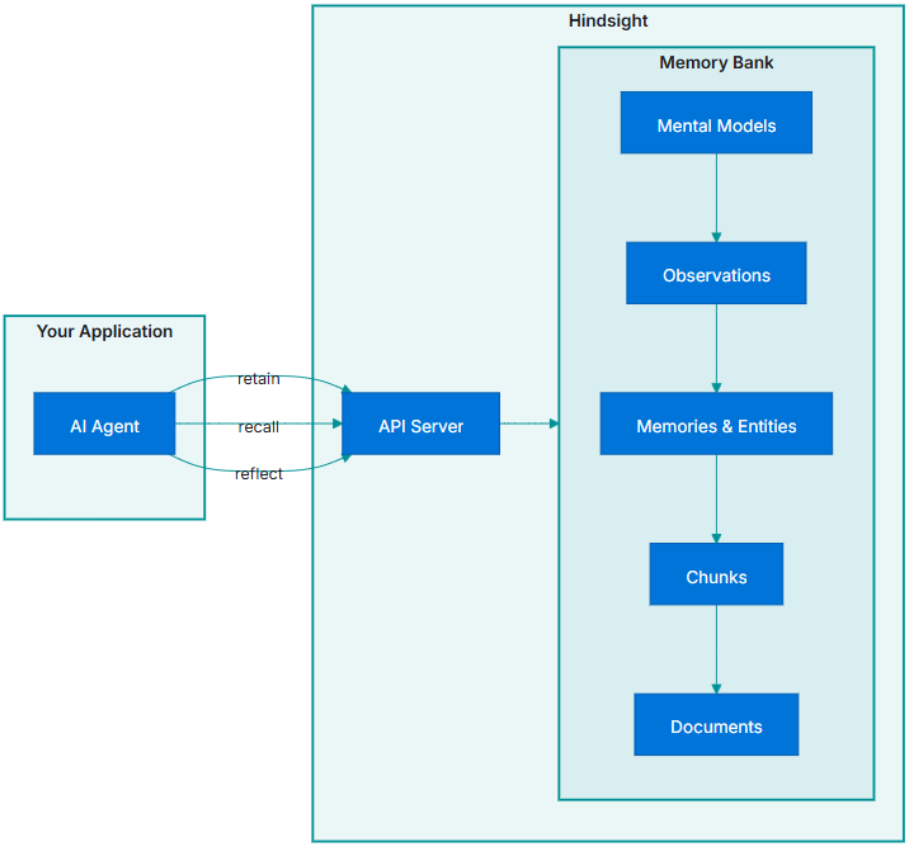


FIGURE 2.3 – Architecture conceptuelle de Hindsight **hindsight_homepage**

2.3.3 Fonctionnalités fondamentales utilisées

Dans le cadre du projet, Hindsight s'appuie sur trois opérations principales : *retain*, *recall* et *reflect*, couvrant l'ensemble du cycle de gestion de la mémoire.

Retain : cette opération correspond à l'enregistrement des informations dans la mémoire. Comme illustré à la Figure 2.4, le système ne stocke pas le texte brut, mais exploite un LLM pour extraire les informations importantes (faits, entités, contexte temporel), puis les normalise afin d'éviter les doublons. Ces données sont transformées en *memory units* enrichies par des métadonnées et des embeddings, puis organisées et classées en différentes catégories (*world*, *experience*, *opinion*, *observation*) avant stockage. Dans la plateforme, cette opération permet de conserver les interactions de l'apprenant, ses difficultés, ses erreurs récurrentes et ses préférences.

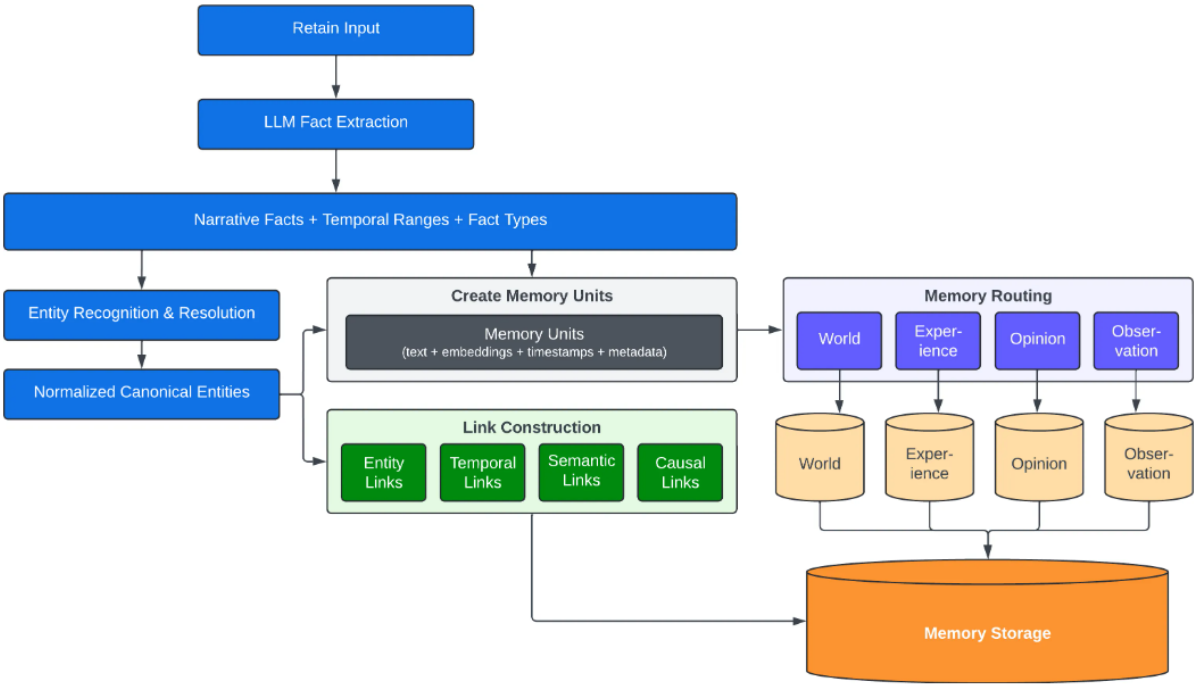


FIGURE 2.4 – Fonctionnement de l'opération *Retain* dans Hindsight **hindsight_github**

Recall : cette opération correspond à la récupération intelligente des mémoires déjà stockées. Comme l'illustre la figure 2.5, Hindsight ne renvoie pas toute la mémoire à l'agent : il lance plusieurs recherches en parallèle, notamment la recherche sémantique par similarité vectorielle, la recherche par mots-clés, l'exploration des liens entre entités et l'exploitation des informations temporelles. Les résultats obtenus sont ensuite fusionnés, réordonnés et filtrés selon le budget de tokens disponible, afin de constituer un ensemble de souvenirs contextualisés à transmettre au LLM **hindsight_recall**. Dans ce projet, *recall* permet donc de retrouver les informations les plus utiles sur l'apprenant, son historique et le cours avant la génération d'une réponse.

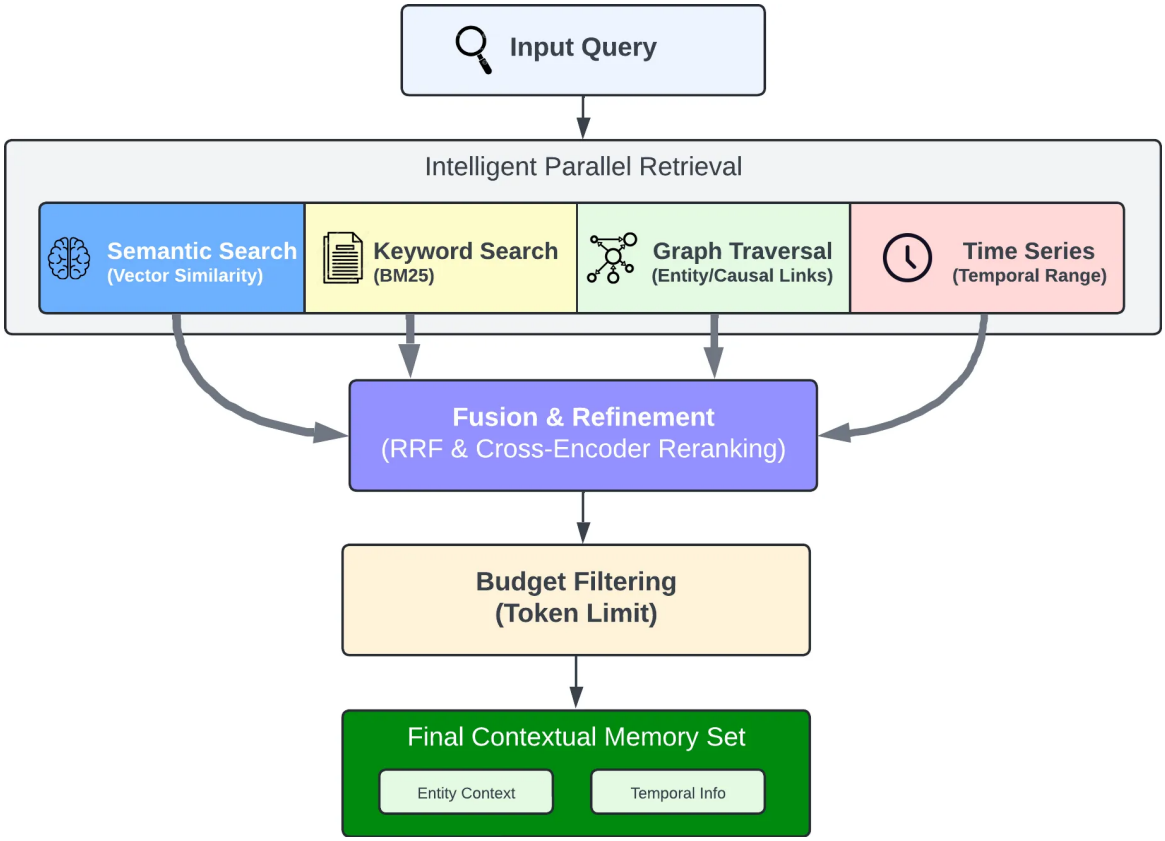


FIGURE 2.5 – Fonctionnement de l'opération *Recall* dans Hindsight **hindsight_github**

Reflect : cette opération correspond à la phase de réflexion et de mise à jour de la mémoire après une interaction. Comme l'illustre la figure 2.6, Hindsight récupère d'abord les mémoires pertinentes, construit un contexte, charge le profil de l'agent, puis utilise le LLM pour générer une réponse cohérente avec ce contexte. La réponse produite est ensuite analysée afin d'identifier de nouvelles observations ou de mettre à jour des opinions existantes, avec un niveau de confiance associé. Ces éléments sont réinjectés dans la mémoire persistante, ce qui permet à l'agent d'améliorer progressivement la cohérence de ses futures interactions **hindsight_reflect**. Dans ce projet, *reflect* est utile pour dégager des tendances sur le parcours d'un apprenant, consolider des observations pédagogiques et enrichir la mémoire des agents au fil des échanges.

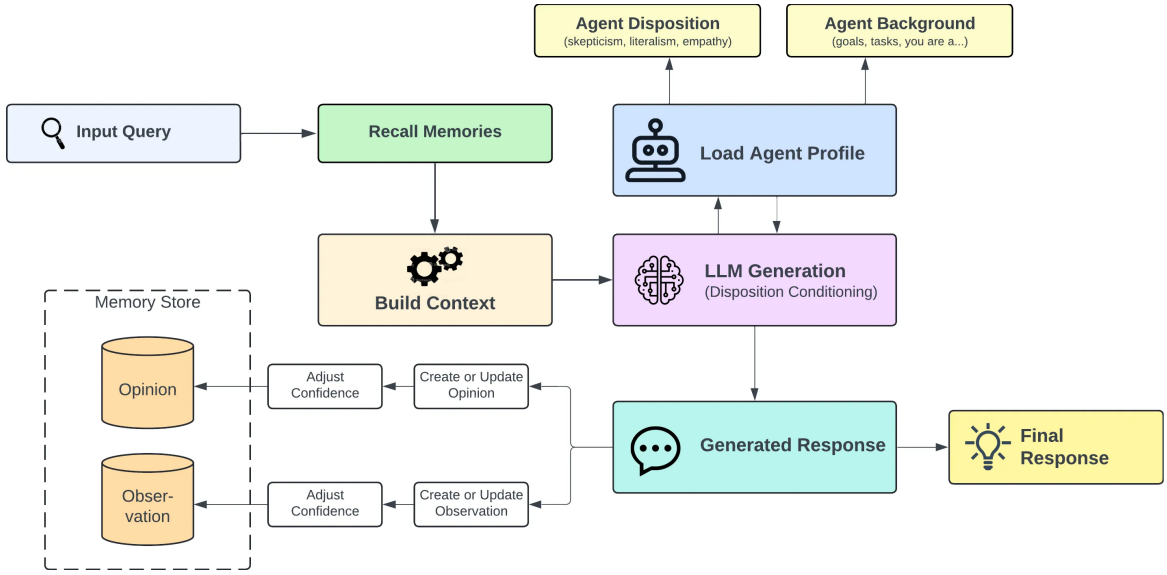


FIGURE 2.6 – Fonctionnement de l'opération *Reflect* dans Hindsight **hindsight_github**

En résumé, l'organisation de la mémoire Hindsight repose sur un cycle continu qui permet de conserver, d'exploiter et d'améliorer progressivement les informations utiles aux agents IA. Cette approche donne à la plateforme une mémoire durable, capable de maintenir le contexte au fil des interactions et de soutenir une personnalisation plus cohérente des réponses, des recommandations et des activités proposées.

2.3.4 Structure des mémoires persistantes dans Hindsight

Dans ce projet, Hindsight organise les informations sous forme de *memory banks* séparées, indexées à partir du *tenantId*, du *userId* et du *courseId*. Cette organisation permet d'isoler les contextes (organisation, apprenant, cours) et d'offrir aux agents une mémoire structurée et ciblée. Le préfixe `tenant:{tenantId}` garantit également la cohérence avec l'architecture multi-tenant et évite tout mélange entre environnements.

On distingue principalement quatre types de banques mémoire :

— **Banque de cours**
`tenant:{tenantId}:course:{courseId}`
Elle contient la mémoire pédagogique stable du cours (objectifs, leçons, quiz, supports, concepts). Elle est alimentée après la publication du cours et utilisée par les agents de coaching, recommandation et défis.

— **Banque apprenant-cours**
`tenant:{tenantId}:user:{userId}:course:{courseId}`
Elle regroupe l'historique de l'apprenant dans un cours (progression, résultats, erreurs, difficultés, interactions et retours).

— **Banque générale de l'apprenant**
`tenant:{tenantId}:user:{userId}`
Elle stocke les informations transversales comme les préférences pédagogiques, le profil

et les connaissances générales.

— **Banque de profil de compétences**
`tenant:{tenantId}:user:{userId}:skill-profile`
Elle contient une synthèse des compétences et des écarts, utilisée principalement par l'Agent de recommandation pour éviter les recalculs.

Ainsi, cette structuration sépare clairement les connaissances liées au cours, au parcours utilisateur et aux compétences. Elle améliore la lisibilité de la mémoire, limite les ambiguïtés et permet aux agents de sélectionner directement le contexte pertinent selon leur objectif.

2.4 Conclusion

Ce chapitre a permis de poser les bases théoriques nécessaires à la compréhension de la solution proposée. Ces fondements constituent le socle sur lequel repose l'ensemble des mécanismes d'intelligence et d'interaction de la plateforme.

Ils offrent ainsi une vision claire des principes qui guident la conception et la mise en œuvre du système dans la suite du projet.

Chapitre 3

Conception architecturale de la plateforme

Contents

3.1 Introduction 34

3.2 Architecture de la plateforme 34

3.2.1 Vue d'ensemble de l'architecture 34

3.2.2 Architecture microservices du backend 36

3.2.3 Architecture multi-tenant 38

3.2.4 Modèle de données 39

3.2.5 Architecture des agents IA 40

3.3 Choix technologiques et justification 46

3.3.1 Stack frontend et backend 46

3.3.2 Bases de données, IA et infrastructure 47

3.4 Conclusion 48

3.1 Introduction

Les concepts présentés dans le chapitre précédent ont permis d'établir les fondements théoriques nécessaires à la conception de la plateforme. À partir de ces bases, il est désormais possible de définir l'architecture de la solution proposée.

Ce chapitre présente l'architecture globale de la plateforme, notamment son organisation microservices, son modèle multi-tenant, son modèle de données ainsi que l'intégration des agents d'intelligence artificielle. Il expose également les principaux choix technologiques retenus et les raisons ayant motivé leur adoption.

3.2 Architecture de la plateforme

Cette section présente l'architecture globale de la plateforme. Elle décrit la structuration du système en différentes couches, en mettant en évidence la séparation entre l'interface utilisateur, la logique métier, les composants d'intelligence artificielle, ainsi que la gestion des données et de la mémoire.

3.2.1 Vue d'ensemble de l'architecture

La plateforme repose sur une architecture en couches afin de structurer le système de manière claire et évolutive. Cette vue d'ensemble permet de présenter les principales responsabilités de la solution ainsi que les échanges entre ses composants.

3.2.1.1 Organisation générale des couches

L'architecture est structurée autour de six couches principales, comme l'illustre la figure 3.1. Elles sont présentées de haut en bas selon le parcours d'une requête dans le système :

1. **Couche de présentation :** elle correspond à l'interface web utilisée par les différents profils de la plateforme. Elle permet d'afficher les données, de déclencher les actions utilisateur et de communiquer avec le backend à travers des appels API.
2. **Couche API Gateway :** elle constitue le point d'entrée unique entre l'interface web et les services internes. Elle reçoit les requêtes du frontend, les redirige vers le service approprié et centralise l'accès aux fonctionnalités backend.
3. **Couche des microservices :** elle regroupe les services responsables des principaux domaines fonctionnels de la plateforme, tels que l'identité, l'administration, la gestion des cours, le suivi de progression et la gamification. Elle applique les règles métier et prépare les données nécessaires aux traitements du système.
4. **Couche IA :** elle regroupe les agents spécialisés responsables des traitements intelligents de la plateforme, comme la création assistée de cours, le coaching, la mémorisation, la recommandation et la génération de défis personnalisés.

5. **Couche Hindsight :** elle constitue la couche de mémoire persistante utilisée par les agents IA. Elle permet de conserver et de récupérer les informations utiles à la personnalisation des traitements.
6. **Couche de données :** elle regroupe les systèmes de stockage utilisés par la plateforme, notamment PostgreSQL et les composants nécessaires à la persistance des données métier, des historiques et des résultats produits par le système.

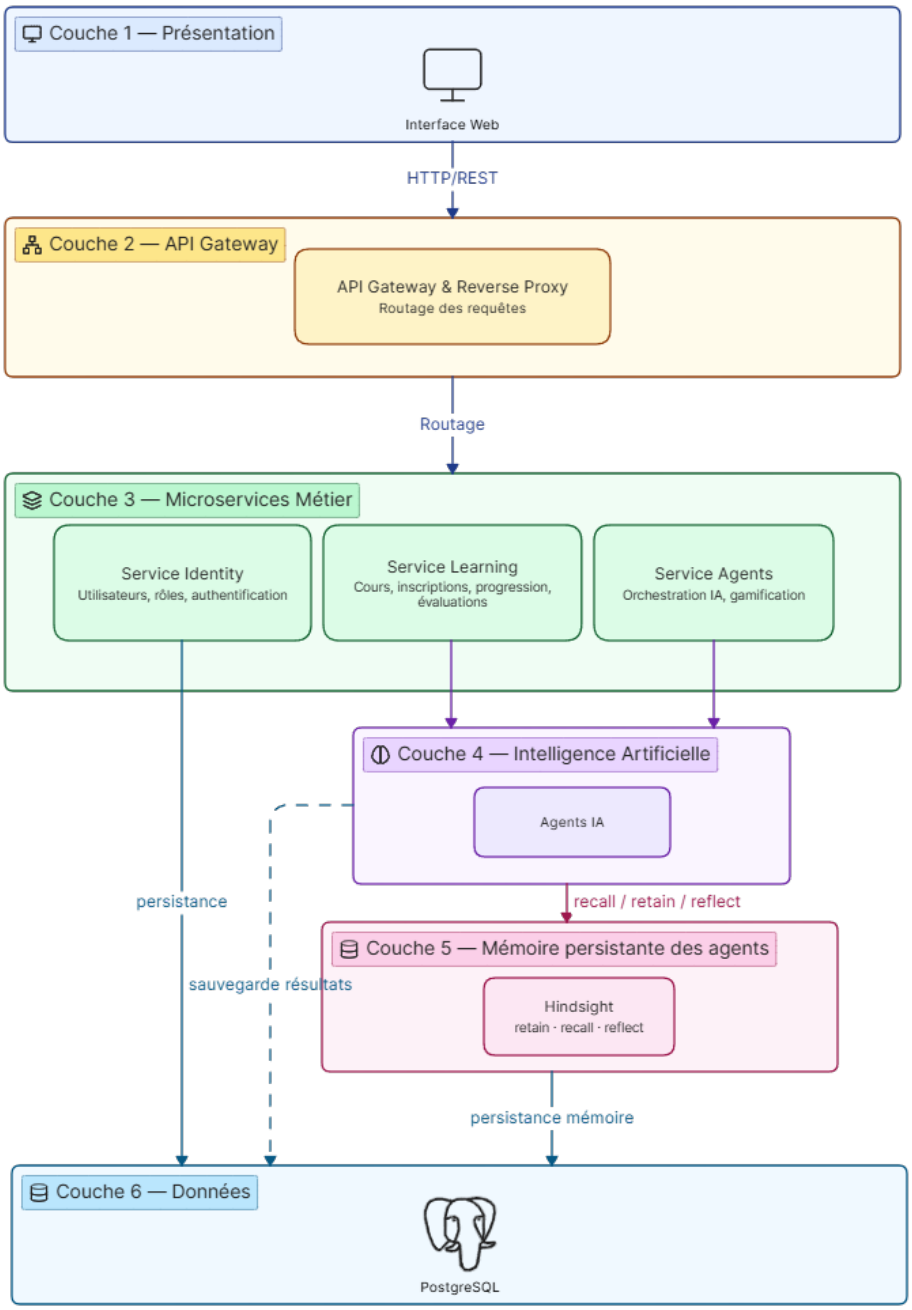


FIGURE 3.1 – Vue d'ensemble de l'architecture en couches de la plateforme

3.2.1.2 Articulation entre les couches

Ces six couches s'articulent de manière progressive. L'utilisateur interagit avec la couche de présentation, qui envoie ses requêtes vers l'*API Gateway*. Celle-ci transmet les appels aux microservices concernés. Lorsque le traitement nécessite une personnalisation ou une génération intelligente, les microservices sollicitent la couche IA. Les agents peuvent alors récupérer ou enrichir le contexte à travers Hindsight, puis retourner le résultat vers les services métier. Les données nécessaires au suivi applicatif sont ensuite stockées dans la couche de données, tandis que les traces utiles à la personnalisation sont conservées dans la mémoire persistante.

3.2.1.3 Séparation entre logique métier et logique IA

Cette organisation met en évidence une séparation importante entre la logique métier et la logique IA. Les microservices restent responsables des règles fonctionnelles de la plateforme, alors que les agents IA sont responsables des traitements intelligents liés au contenu, à l'accompagnement et à la personnalisation. Cette séparation rend l'architecture plus lisible, facilite l'évolution des agents et limite l'impact d'une modification IA sur le fonctionnement métier de la plateforme.

Les sous-sections suivantes détaillent ensuite les deux parties principales de cette architecture : l'organisation microservices du backend, puis l'architecture des agents IA et leurs workflows.

3.2.2 Architecture microservices du backend

L'architecture backend de la plateforme repose sur une approche microservices. Ce choix permet d'éviter un backend monolithique dans lequel l'authentification, la gestion pédagogique, le suivi des apprenants et les traitements IA seraient regroupés dans une seule application. La plateforme couvre plusieurs domaines fonctionnels distincts ; il est donc plus adapté de séparer ces responsabilités afin de faciliter la maintenance, l'évolution et le déploiement progressif des fonctionnalités.

Dans ce projet, le backend est structuré autour de quatre services principaux : *Identity*, *Learning*, *Agents* et *API Gateway*. Ce découpage permet d'introduire les principaux composants backend qui seront détaillés dans les sous-sections suivantes.

3.2.2.1 API Gateway

L'accès aux microservices est centralisé à travers une couche *API Gateway*. Traefik, utilisé comme reverse proxy **traefik_official**, est chargé de recevoir les requêtes entrantes et de les rediriger vers le microservice approprié selon les règles de routage définies. Cette couche reçoit les requêtes provenant du frontend, applique les règles de routage et transmet chaque appel vers le service approprié. Elle permet donc au frontend de communiquer avec un point d'entrée unique au lieu de connaître directement les adresses internes des services. Elle facilite aussi

l'organisation des routes API, l'isolation des services dans le réseau Docker et l'évolution de l'architecture lorsqu'un nouveau service est ajouté.

3.2.2.2 Microservices réels et modules fonctionnels internes

Dans l'implémentation de la plateforme, le backend n'est pas découpé en microservices pour chaque fonctionnalité. Il repose sur trois microservices principaux : *identity*, *learning* et *agents* (Figure 3.2). Les différentes fonctionnalités sont organisées sous forme de modules internes rattachés à ces services.

— **Microservice identity :** Ce microservice couvre tout le domaine lié à l'identité et à l'accès à la plateforme. Il inclut l'authentification, la gestion des utilisateurs, des rôles, des tenants ainsi que les journaux d'audit. Il représente le point central de contrôle des accès et des permissions.

— **Microservice learning :** Ce microservice regroupe le domaine pédagogique de la plateforme, incluant les cours, les leçons, la progression, les quiz, la gamification ainsi que les recommandations et les défis. Ces fonctionnalités sont gérées comme des modules internes et peuvent interagir avec la couche IA lorsque nécessaire.

— **Microservice agents :** Ce microservice est dédié aux agents IA et adopte une granularité plus fine. Les agents ne sont pas des services indépendants, mais des composants logiques orchestrés au sein du même service. Chaque agent dispose de son propre prompt, de ses skills et de ses outils.

Le microservice agents joue un rôle d'orchestrateur central : il reçoit les requêtes, sélectionne l'agent approprié, initialise son contexte et retourne le résultat généré.

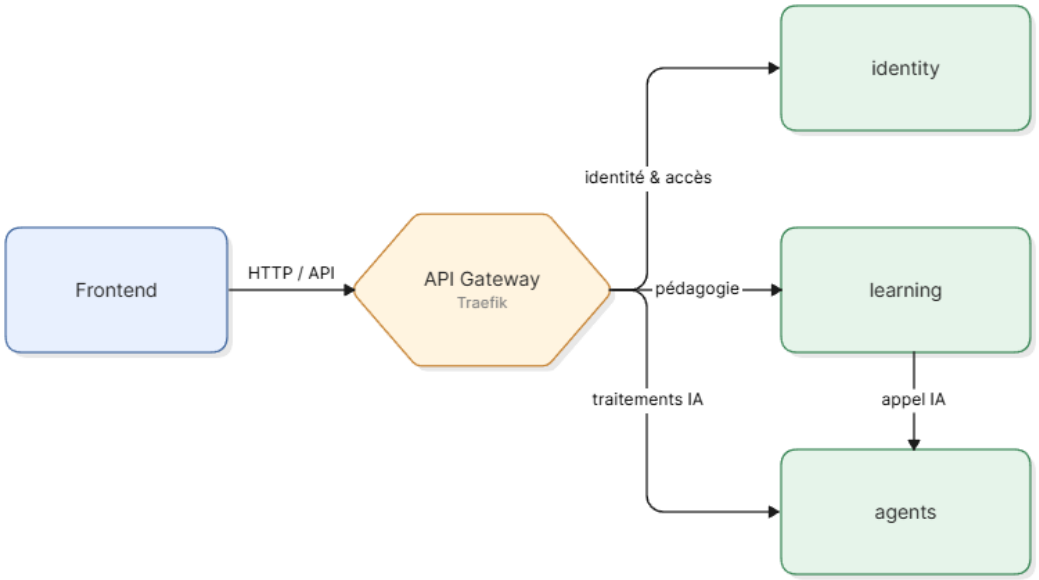


FIGURE 3.2 – Organisation des microservices du backend

3.2.3 Architecture multi-tenant

Une architecture multi-tenant permet à plusieurs organisations de partager une même plateforme tout en assurant une séparation logique de leurs données et de leurs utilisateurs **medimagh_multitenant**.

Dans ce projet, cette approche répond au contexte du Groupe 3S, où plusieurs sociétés utilisent la même plateforme de formation tout en conservant leurs propres utilisateurs, cours et données de suivi.

L'isolation des données est assurée par l'utilisation d'un identifiant de tenant (*tenant_id*) associé aux entités métier. Ce mécanisme permet de restreindre l'accès aux données de chaque organisation et de garantir une séparation stricte entre les différents tenants.

La figure 3.3 présente l'organisation générale de l'architecture multi-tenant mise en place dans la plateforme. Elle illustre le partage de l'infrastructure applicative entre plusieurs entreprises tout en assurant l'isolation logique des données de chaque tenant.

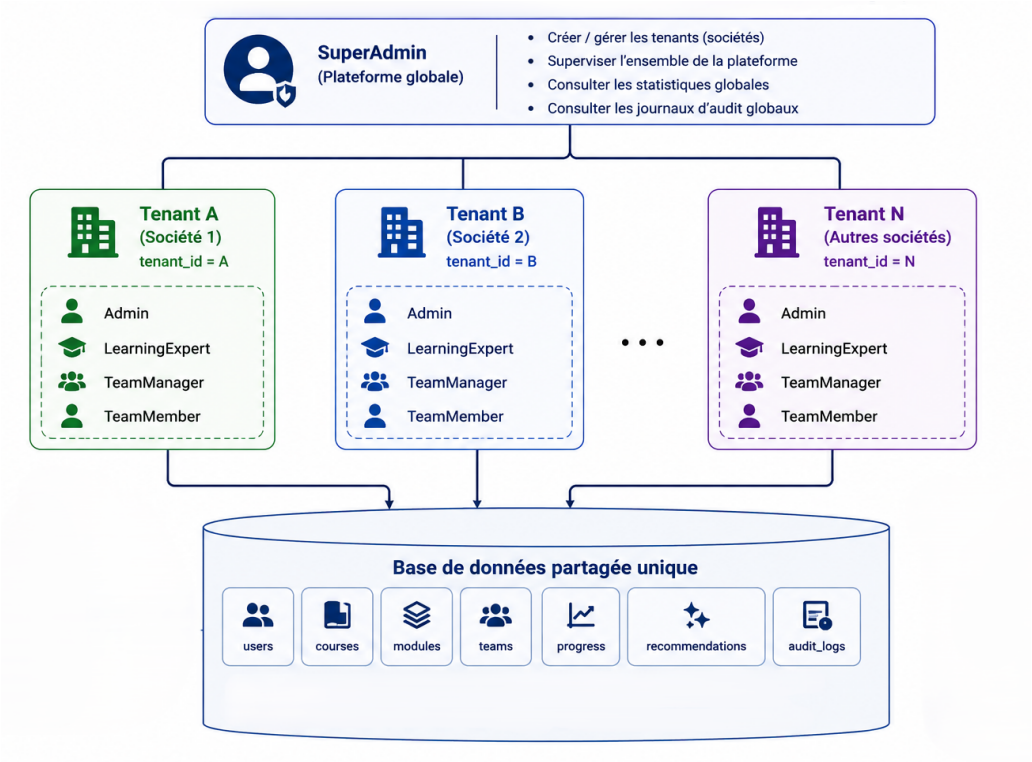


FIGURE 3.3 – Architecture multi-tenant de la plateforme

La gestion des accès est également organisée au niveau du tenant. Chaque organisation dispose de ses propres utilisateurs et de ses propres rôles. Les utilisateurs peuvent accéder uniquement aux ressources appartenant à leur tenant, tandis qu'un rôle Super Admin dispose d'une visibilité globale sur l'ensemble des tenants du système.

La figure 3.4 illustre les différents acteurs et leurs interactions avec les fonctionnalités de la plateforme à l'intérieur d'un tenant.

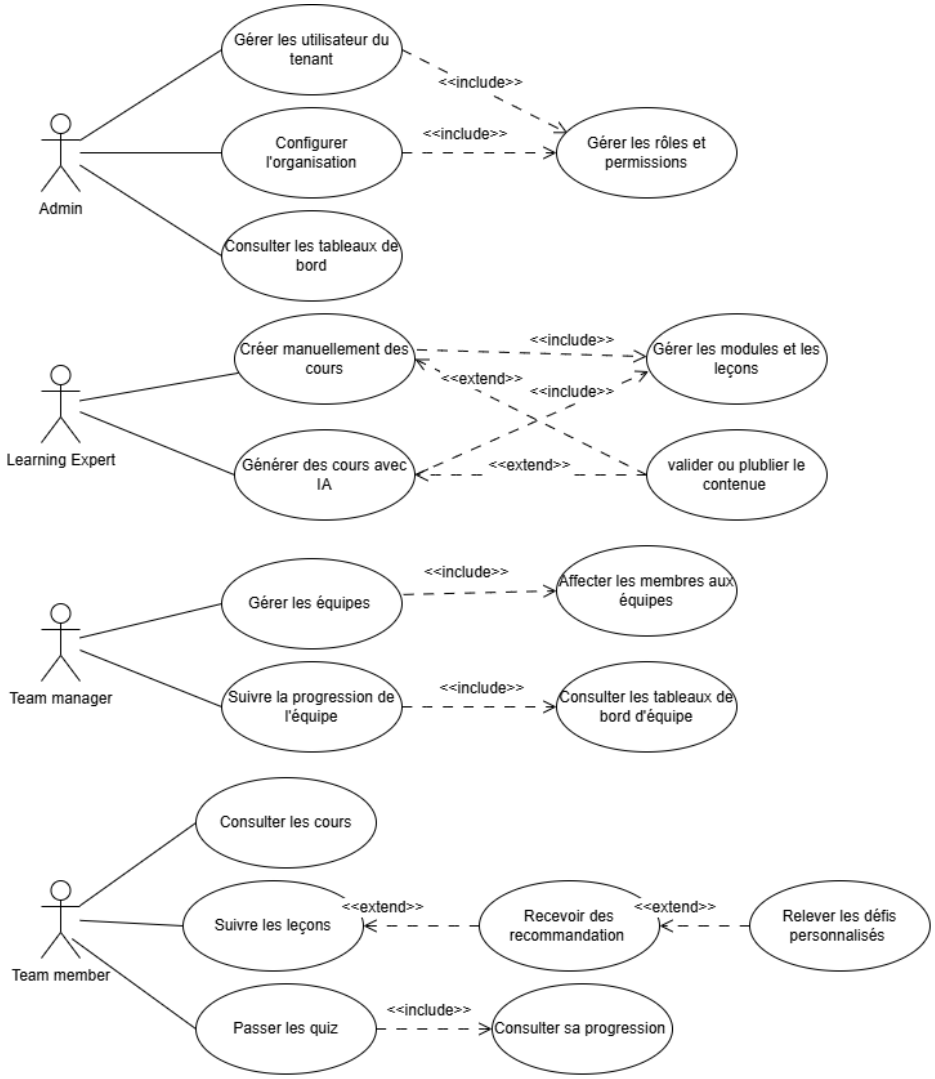


FIGURE 3.4 – Diagramme de cas d'utilisation UML des acteurs au sein d'un tenant

3.2.4 Modèle de données

Le modèle de données repose sur une base relationnelle PostgreSQL, utilisée pour le stockage des principales informations métier de la plateforme, notamment les utilisateurs, les organisations, les cours, les inscriptions, la progression, les évaluations ainsi que les fonctionnalités intelligentes telles que les recommandations et les défis personnalisés. Ce choix garantit la cohérence des données et leur intégrité dans un contexte multi-tenant.

Les données de la plateforme peuvent être regroupées en plusieurs catégories fonctionnelles, incluant les informations d'identité et d'administration des organisations, les contenus pédagogiques (cours, modules, leçons et évaluations), les données de suivi de l'apprentissage (inscriptions, progression et résultats), ainsi que les données liées aux fonctionnalités intelligentes.

Par ailleurs, la plateforme adopte une approche de stockage hybride. Les données structurées et les métadonnées sont stockées dans PostgreSQL, tandis que les ressources pédagogiques volumineuses (vidéos, images, documents et supports de cours) sont externalisées dans MinIO.

La base de données conserve uniquement les références vers ces ressources, ce qui permet d'optimiser les performances et de simplifier la gestion des contenus.

Ainsi, ce modèle de données combine la robustesse d'une base relationnelle avec la flexibilité d'un stockage objet, en adéquation avec les besoins fonctionnels et techniques de la plateforme.

3.2.5 Architecture des agents IA

La couche IA de la plateforme est organisée autour de plusieurs agents spécialisés, chacun associé à une responsabilité pédagogique précise. L'objectif n'est pas de construire un seul agent généraliste chargé de toutes les tâches, mais de répartir les traitements intelligents entre des agents plus ciblés : agent de création de cours, agent de coaching pédagogique, agent de mémoire apprenant, agent de recommandation et agent de défis personnalisés. Cette séparation permet de mieux contrôler le comportement de chaque agent et d'adapter ses consignes au contexte fonctionnel dans lequel il intervient.

3.2.5.1 Agent de création de cours

Cet agent assure la génération assistée des cours à travers une orchestration autour d'OpenMAIC. À partir d'une consigne fournie par l'expert pédagogique, éventuellement accompagnée d'un document PDF, il prépare la demande, suit l'exécution du processus et récupère le brouillon produit. OpenMAIC prend en charge la génération principale du contenu pédagogique, notamment les scènes de cours, les diapositives, les scripts du professeur, les quiz et, lorsque c'est pertinent, les activités interactives. Le résultat n'est pas un fichier statique, mais un brouillon structuré et éditable, ensuite sauvegardé dans la plateforme afin d'être révisé, validé puis transformé en cours officiel. Après la validation finale, le cours peut être enrichi par la génération audio TTS et transmis au Course Memory Agent pour son intégration dans la mémoire persistante. Le déroulement détaillé de cet agent est illustré par la figure 3.5.

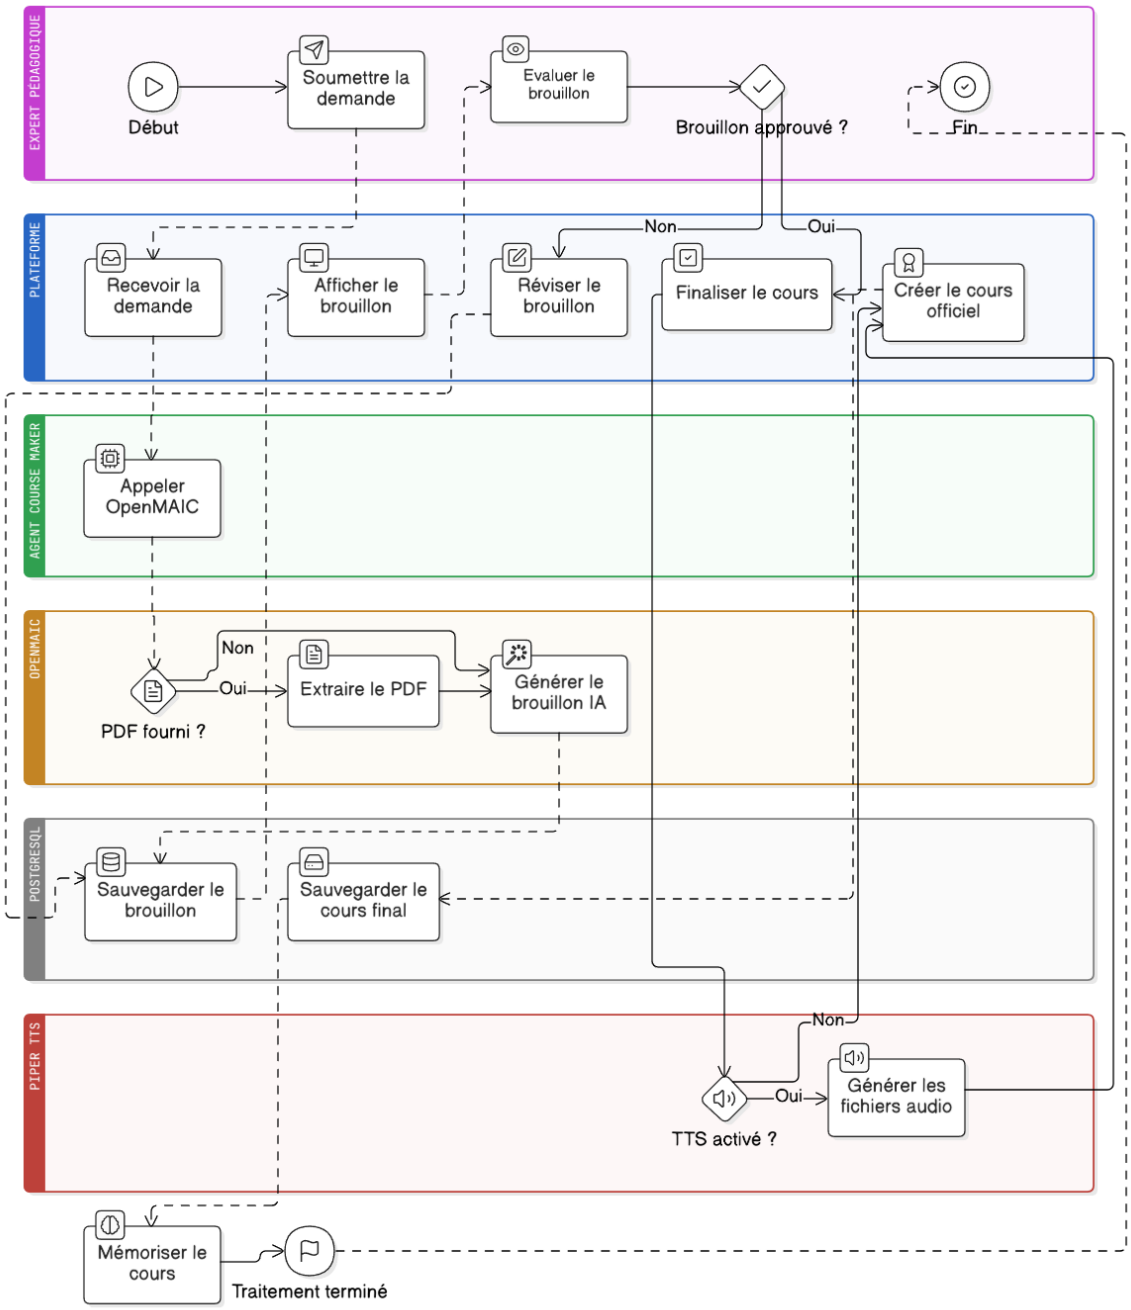


FIGURE 3.5 – Diagramme d'activité UML de l'agent de création de cours

3.2.5.2 Agent de coaching pédagogique

Cet agent accompagne l'apprenant pendant son parcours en répondant à ses questions à partir du contexte du cours et de sa mémoire personnelle. Lorsqu'une question est posée, la plateforme transmet la demande à l'agent *AI Coaching Agent*. Celui-ci récupère d'abord les informations pertinentes du cours à travers l'opération *recall* de Hindsight, tout en déclenchant la mémorisation de la question de l'apprenant via l'agent de mémoire apprenant. Les éléments rappelés sont ensuite utilisés pour construire une requête enrichie, puis Hindsight exécute une

opération *reflect* sur la mémoire propre à l'apprenant et au cours. La réponse produite est ainsi contextualisée, liée au contenu pédagogique et adaptée à l'historique de l'utilisateur. Le déroulement de cet agent est illustré par la figure 3.6.

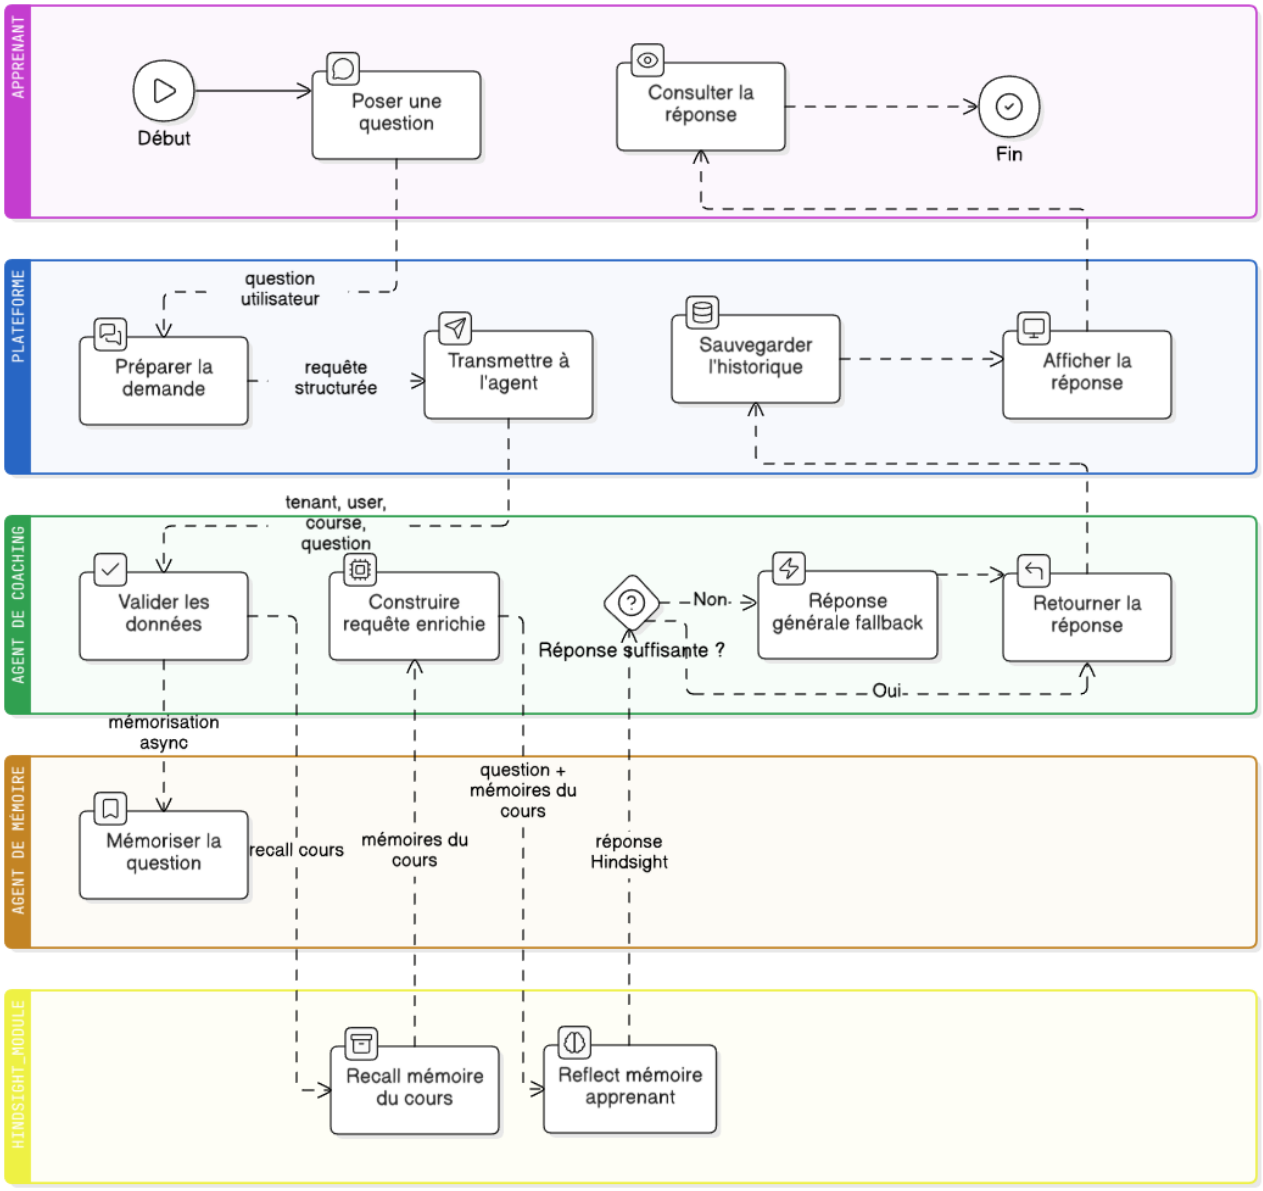


FIGURE 3.6 – Diagramme d'activité UML de l'agent de coaching pédagogique

3.2.5.3 Agent de mémoire apprenant

Cet agent alimente la mémoire persistante du suivi pédagogique. Il est déclenché par plusieurs événements du parcours apprenant, comme l'envoi d'un message au *AI Coaching Agent*, la complétion d'une leçon, le passage d'un quiz, la progression dans une vidéo, la détection d'une difficulté, la réponse à un défi personnalisé ou la complétion d'un cours. Après validation des données reçues, il prépare le contenu à mémoriser. Pour les messages de coaching,

il vérifie les mémoires similaires avec *recall* afin d'éviter les doublons, puis conserve les nouvelles informations avec *retain*. Pour les autres événements d'apprentissage, il enregistre une trace structurée dans la banque mémoire de l'apprenant et du cours. Ces informations peuvent ensuite être rappelées par les autres agents pour personnaliser leurs réponses. Le fonctionnement de cet agent est illustré par la figure 3.7.

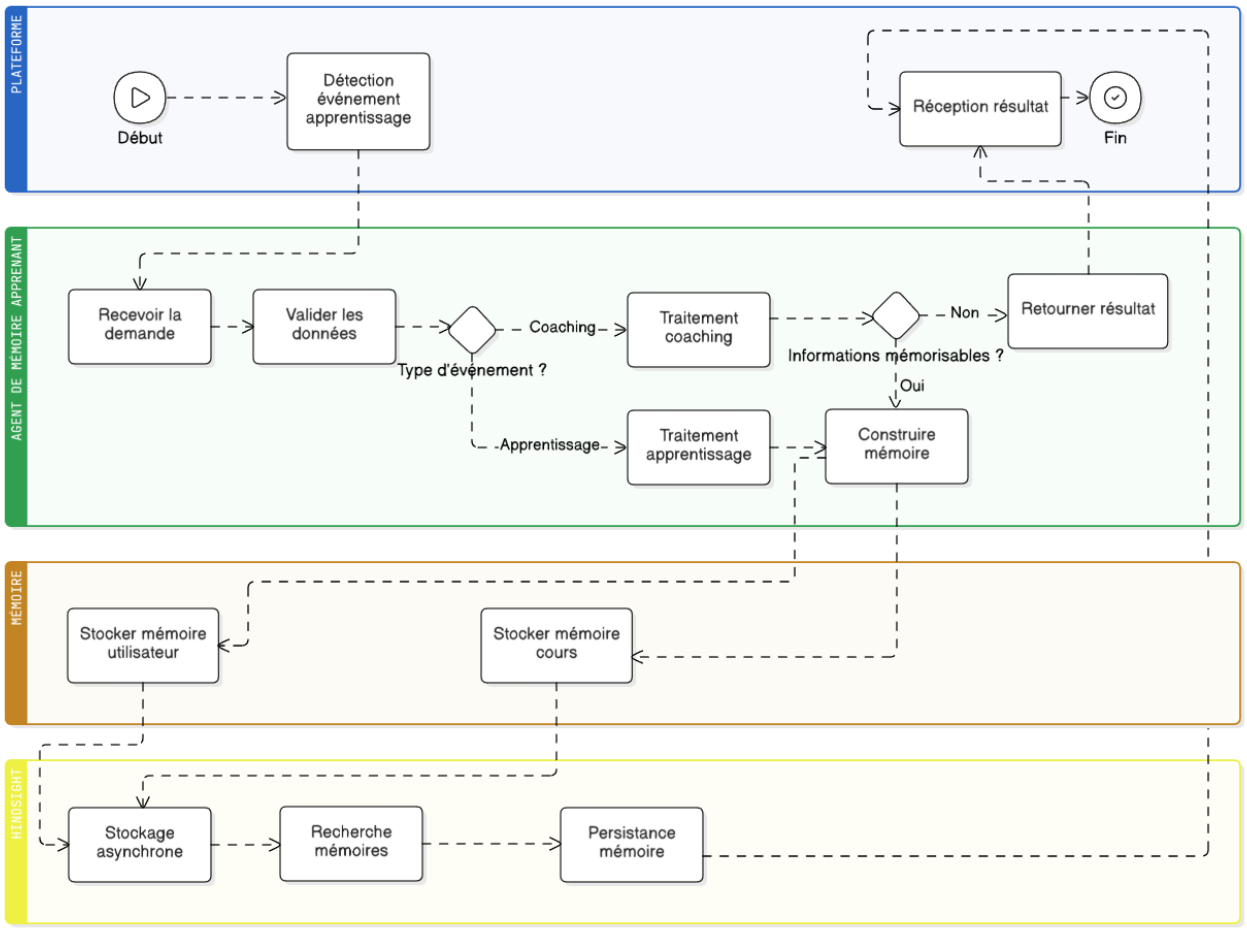


FIGURE 3.7 – Diagramme d'activité UML de l'agent de mémoire apprenant

3.2.5.4 Agent de recommandation

Cet agent a pour objectif de personnaliser le parcours d'apprentissage en proposant à chaque apprenant les actions les plus adaptées à son état actuel. Il s'appuie d'abord sur les mémoires liées aux cours suivis par l'apprenant afin de construire un *skill gap radar*, c'est-à-dire une synthèse des domaines de compétences maîtrisés, partiellement maîtrisés ou encore faibles. Les compétences faibles sont ensuite comparées avec le catalogue des cours publiés. Cette comparaison ne repose pas uniquement sur une décision manuelle : Hindsight et le LLM interviennent pour transformer les signaux d'apprentissage en domaines de compétences, tandis que l'agent applique ensuite une logique de correspondance par mots-clés entre ces compétences et les informations des cours, comme le titre, la description, la catégorie et le niveau. Pour

chaque cours candidat, un score de pertinence est calculé selon le nombre de mots-clés communs, l'état de la compétence détectée et la situation de l'apprenant dans le cours. Par exemple, une compétence non maîtrisée reçoit une priorité plus forte, tandis qu'un cours déjà terminé est moins favorisé. Si le score obtenu dépasse le seuil défini, l'agent génère une recommandation de cours, de leçon ou de révision selon le contexte. Dans le cas contraire, il propose simplement un sujet à retravailler. Le déroulement détaillé de cet agent est présenté dans la figure 3.8.

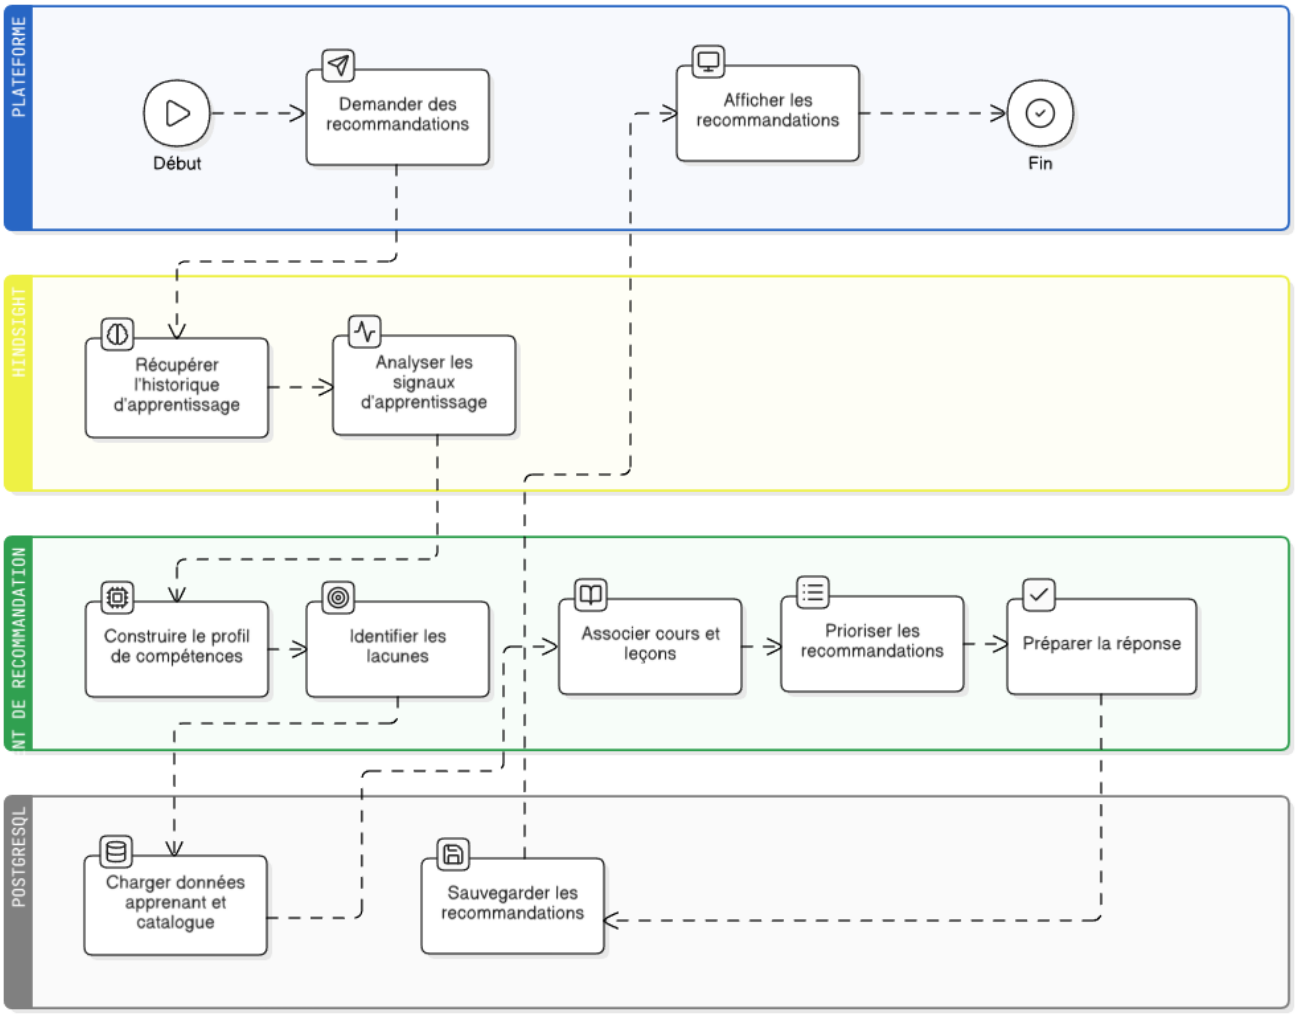


FIGURE 3.8 – Diagramme d'activité UML de l'agent de recommandation

3.2.5.5 Agent de défis personnalisés

Cet agent, appelé *Solo Challenge Agent*, est déclenché automatiquement lors de la connexion de l'utilisateur afin de générer une activité personnalisée visant à renforcer une notion liée à son parcours d'apprentissage. Au démarrage, la plateforme lui transmet les informations d'identification de l'utilisateur, notamment le *tenantId*, le *userId* et le rôle.

L'agent sélectionne ensuite le cours ou le contexte pédagogique le plus pertinent, en privilégiant le dernier cours suivi ou un contenu associé à une difficulté récente non

résolue. Il interroge ensuite Hindsight via l'opération *recall* afin de récupérer les informations pertinentes liées à l'apprenant et à son historique d'apprentissage (difficultés, erreurs et signaux pédagogiques).

Sur cette base, l'agent détermine le type de défi à générer. Cette logique est encadrée par des skills spécialisés qui permettent de structurer le comportement de génération sans alourdir le prompt principal. Ces skills sont chargés dynamiquement en fonction du contexte afin d'adapter le défi au profil et à la situation de l'apprenant.

Le résultat généré est une question structurée comprenant un titre, un énoncé, des choix multiples, une réponse correcte et une explication. Avant son affichage, la tentative est enregistrée dans la base de données, et la correction est effectuée lors de la soumission de l'utilisateur. Les résultats sont ensuite réinjectés dans le système de mémoire afin d'améliorer les futures recommandations et générations de défis. Le déroulement détaillé de cet agent est illustré dans la Figure 3.9.

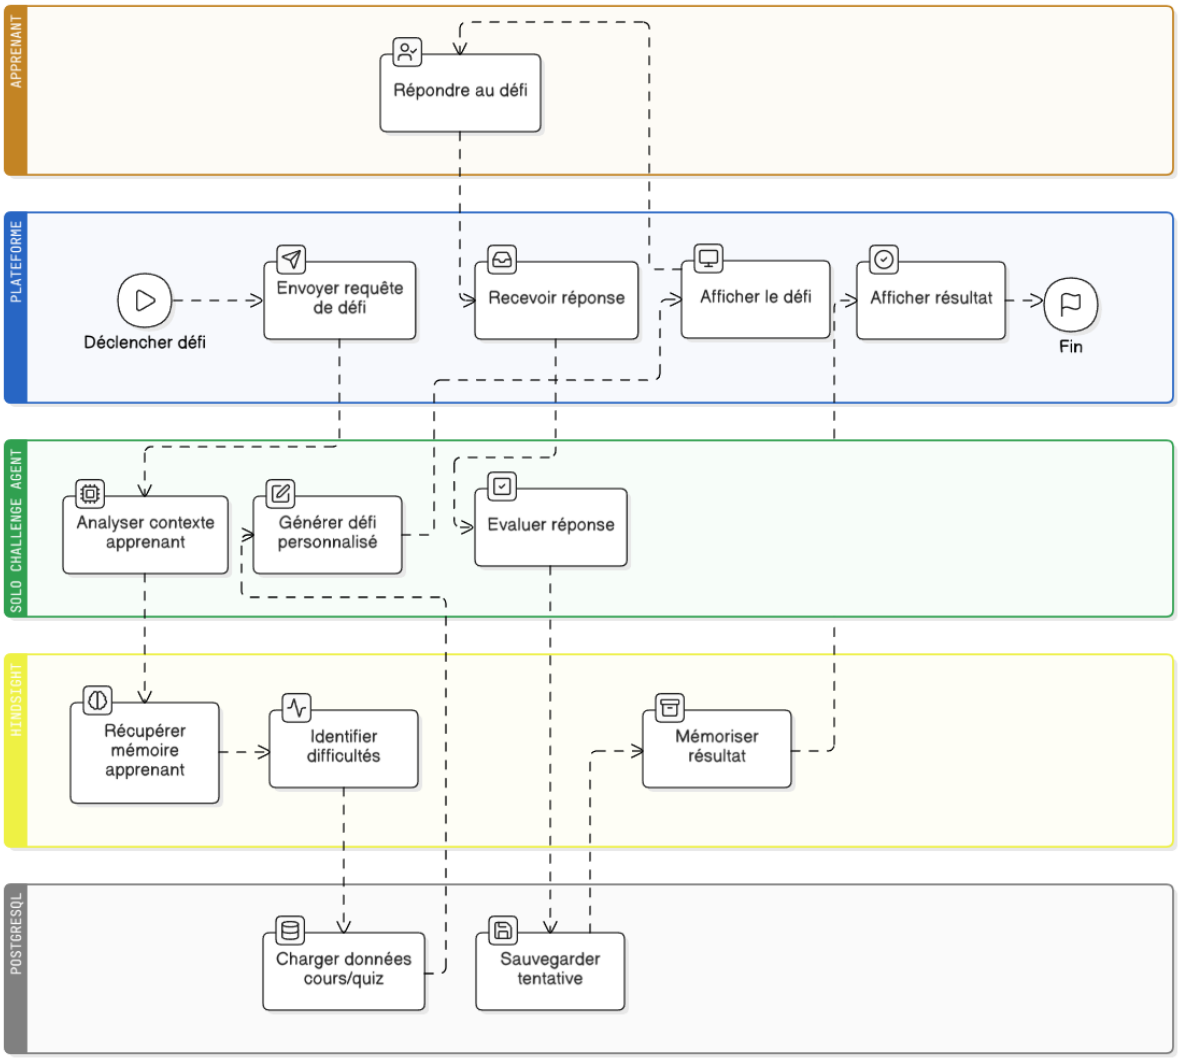


FIGURE 3.9 – Diagramme d'activité UML de l'agent de défis personnalisés

En conclusion, cette architecture met en place une couche IA organisée autour de workflows

spécialisés et complémentaires. Chaque agent est déclenché dans un contexte précis et produit des résultats exploitables par la plateforme.

Cette séparation permet d'éviter une centralisation de la logique d'intelligence artificielle et garantit un meilleur contrôle du comportement de chaque agent. Elle favorise également une personnalisation progressive du parcours d'apprentissage en s'appuyant sur les interactions réelles de l'utilisateur.

Ainsi, l'IA est intégrée comme une couche fonctionnelle du système, contribuant à l'adaptation et à l'évolution du parcours pédagogique.

3.3 Choix technologiques et justification

Cette section présente les principales technologies retenues pour la réalisation de la plateforme. L'objectif n'est pas seulement de lister les outils utilisés, mais de justifier leur choix par rapport aux besoins techniques du projet et aux alternatives possibles.

3.3.1 Stack frontend et backend

La plateforme s'appuie sur une stack technologique adaptée à une architecture microservices intégrant des fonctionnalités d'IA.

Le tableau 3.1 présente les technologies retenues ainsi que leur justification.

TABLE 3.1 – Tableau comparatif des technologies frontend et backend retenues

Technologie	**Rôle dans le projet**	**Justification**
React	Construction des composants de l'interface utilisateur.	React permet de construire des interfaces modulaires à partir de composants réutilisables, ce qui facilite l'organisation des écrans et la maintenance de l'interface.
Next.js	Framework frontend basé sur React pour organiser les pages et les routes.	Next.js apporte une structure applicative au-dessus de React, avec un routage intégré et une meilleure organisation des pages, alors qu'une application React seule nécessite davantage de configuration.
FastAPI	Développement des microservices backend.	FastAPI s'intègre directement avec l'écosystème Python utilisé par les services IA et offre une définition rapide d'API REST typées, alors que NestJS aurait introduit une stack backend Node.js séparée.
Traefik	Routage des requêtes vers les services backend.	Traefik s'intègre facilement avec Docker et permet de centraliser le routage vers les différents services backend à partir de règles déclarées dans l'environnement de déploiement.

3.3.2 Bases de données, IA et infrastructure

Les choix liés au stockage, à la mémoire persistante, aux modèles d'IA et au déploiement ont été réalisés en fonction des contraintes du projet : cohérence des données, isolation par tenant, recherche sémantique, simplicité de déploiement et maîtrise des coûts.

Le tableau 3.2 synthétise les choix retenus pour les données, l'IA et l'infrastructure.

TABLE 3.2 – Tableau comparatif des technologies de données, IA et infrastructure

Technologie	**Rôle dans le projet**	**Justification**
PostgreSQL	Stockage des données relationnelles de la plateforme.	PostgreSQL est adapté aux données fortement liées, comme les utilisateurs, cours, inscriptions et progressions, car il garantit la cohérence relationnelle nécessaire au suivi pédagogique.
pgvector	Stockage et recherche des représentations vectorielles.	pgvector permet d'ajouter la recherche par similarité directement dans PostgreSQL, ce qui simplifie l'infrastructure et évite de maintenir un service de stockage vectoriel indépendant.
MinIO	Stockage objet des fichiers pédagogiques volumineux.	MinIO permet de gérer efficacement les vidéos, images, PDF et supports de cours, tandis que PostgreSQL conserve uniquement les métadonnées et les références vers ces ressources.
Hindsight	Mémoire persistante exploitée par les agents IA.	Hindsight fournit des opérations dédiées à la mémorisation et à la récupération sémantique, ce qui permet d'exploiter une mémoire plus structurée qu'un simple historique de conversation.
Agno OS	Orchestration des agents IA et structuration de leurs workflows.	Agno OS permet de développer et d'orchestrer des agents IA sous forme de services spécialisés. Cette approche favorise la modularité, la maintenabilité et l'intégration des fonctionnalités IA dans la plateforme.
OpenRouter / LLM	Accès au modèle de langage principal utilisé par les fonctionnalités IA.	OpenRouter permet d'utiliser un modèle performant et accessible hors réseau interne, tout en conservant le modèle local de l'entreprise comme solution de secours lorsque le contexte le permet.
RabbitMQ	Gestion des échanges asynchrones entre certains services.	RabbitMQ permet de traiter des événements métier sans bloquer directement le parcours utilisateur, ce qui convient aux notifications et aux traitements déclenchés en arrière-plan.

Technologie	Rôle dans le projet	Justification
Redis	Stockage temporaire de contextes préparés pour certains agents IA.	Redis est adapté aux données intermédiaires et temporaires, tandis que PostgreSQL reste réservé aux données métier persistantes nécessitant une cohérence relationnelle.
Piper	Génération audio locale pour la synthèse vocale des contenus.	Piper permet de produire des voix de synthèse dans l'environnement de déploiement, ce qui limite la dépendance à un service externe pour la génération audio.
Docker / Docker Compose	Conteneurisation et orchestration locale des services de la plateforme.	Docker isole les services dans des conteneurs reproductibles, tandis que Docker Compose facilite leur lancement coordonné dans un même environnement.

3.4 Conclusion

Ce chapitre a présenté la conception de la plateforme ainsi que les principaux choix architecturaux et technologiques retenus. Il a permis de décrire l'organisation générale du système, son architecture microservices, son approche multi-tenant, son modèle de données et l'intégration des agents d'intelligence artificielle.

Cette conception constitue le cadre de référence pour la mise en œuvre de la solution. Le chapitre suivant est consacré à la réalisation de la plateforme, à la présentation des différents modules développés ainsi qu'à son déploiement et son hébergement.

Chapitre 4

Réalisation

Contents

4.1 Introduction 50

4.2 Réalisation et présentation des modules 50

4.2.1 Module Identity : gestion des identités, des accès et du multi-tenant . 50

4.2.2 Gestion des formations, cours et progression 55

4.2.3 Mentorat et gamification 63

4.2.4 Modules IA – les 5 agents 65

4.3 Déploiement et hébergement de la plateforme 68

4.4 Conclusion 69

4.1 Introduction

La conception et l'architecture présentées dans le chapitre précédent ont servi de base à la réalisation de la plateforme. Ce chapitre présente les principaux modules développés, en mettant en évidence les fonctionnalités implémentées et leur intégration au sein du système.

Une attention particulière est accordée aux modules d'intelligence artificielle, qui constituent un élément central de la solution. Le chapitre décrit également les choix retenus pour le déploiement et l'hébergement de la plateforme afin d'assurer son exécution dans un environnement opérationnel.

4.2 Réalisation et présentation des modules

Cette section présente les principaux modules réalisés dans la plateforme, en montrant comment les choix de conception ont été traduits en fonctionnalités opérationnelles et accessibles depuis les interfaces développées.

4.2.1 Module Identity : gestion des identités, des accès et du multi-tenant

Le module *Identity* constitue le socle de gestion des identités et des accès de la plateforme. Il centralise les comptes utilisateurs, les sessions, les rôles et le contexte multi-tenant afin de sécuriser les interactions entre le frontend et les autres modules. Cette sous-section détaille les mécanismes mis en place pour initialiser la plateforme, gérer les tenants, authentifier les utilisateurs et contrôler les accès.

4.2.1.1 Initialisation de la plateforme et création du SuperAdmin

Lors du premier lancement, la plateforme propose un processus d'initialisation permettant de créer l'environnement global. Cette étape permet de définir les informations principales de l'organisation, comme le nom de la plateforme et les premiers paramètres nécessaires au démarrage. Elle permet aussi de créer le compte *SuperAdmin*, qui possède une portée globale sur la plateforme.

Le *SuperAdmin* n'est pas rattaché à une entreprise particulière. Il dispose d'un accès transversal pour gérer les tenants, configurer les paramètres de la plateforme et créer les premiers administrateurs d'entreprise. L'interface de création de ce compte est présentée dans la figure 4.1.

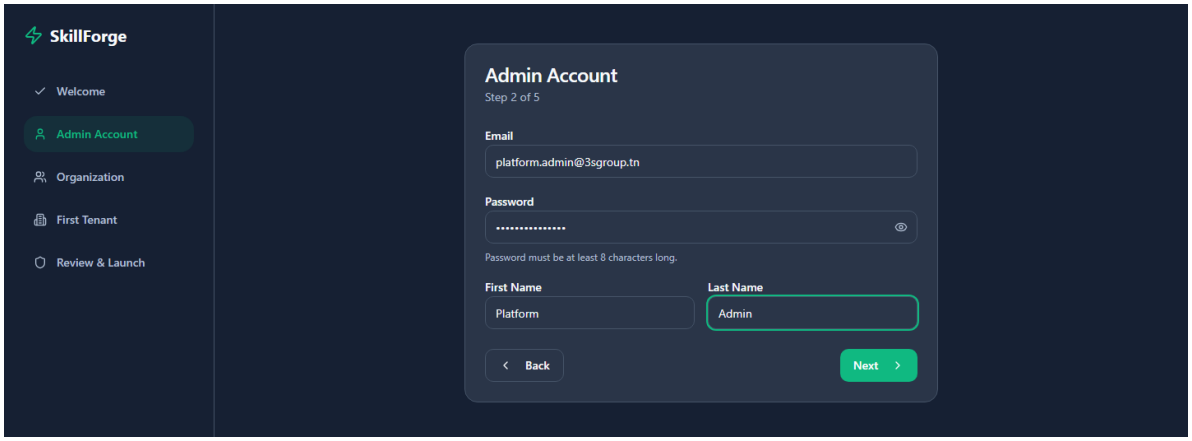


FIGURE 4.1 – Interface d'initialisation de la plateforme et création du compte SuperAdmin

4.2.1.2 Gestion des tenants et isolation multi-tenant

La plateforme adopte une architecture multi-tenant permettant à plusieurs entreprises de partager la même infrastructure tout en conservant une séparation logique de leurs données. Chaque entreprise est représentée par un tenant disposant de sa propre configuration.

L'isolation est assurée par l'attribut `tenant_id`, associé aux utilisateurs et transmis dans les jetons d'accès. Les services backend utilisent cet identifiant pour restreindre l'accès aux ressources de chaque organisation (utilisateurs, cours, équipes, progression, etc.).

Le SuperAdmin dispose d'une vue globale lui permettant de gérer les différents tenants, notamment leur création, leur activation et leur configuration, comme l'illustre la figure 4.2.

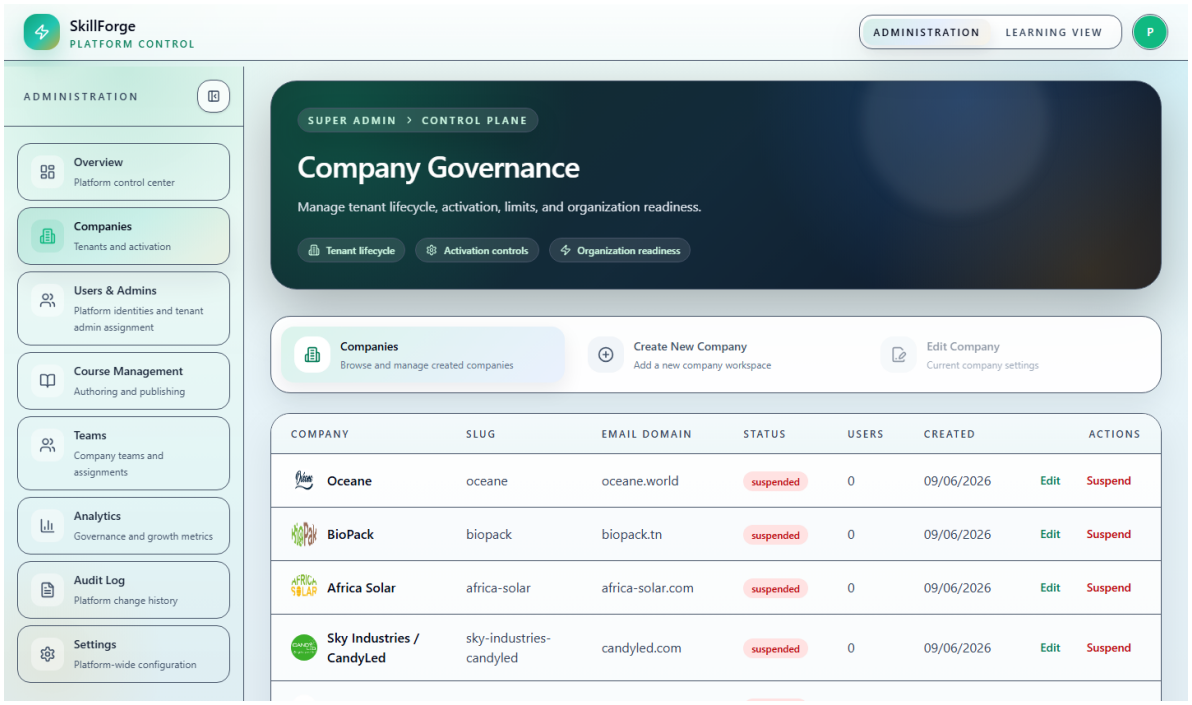


FIGURE 4.2 – Gestion multi-tenant des entreprises depuis l'espace SuperAdmin

La création d'un nouveau tenant se fait à partir d'un formulaire dédié permettant de renseigner les informations principales de l'entreprise, notamment son domaine e-mail, sa limite de sièges et ses paramètres d'identité, comme le montre la figure 4.3.

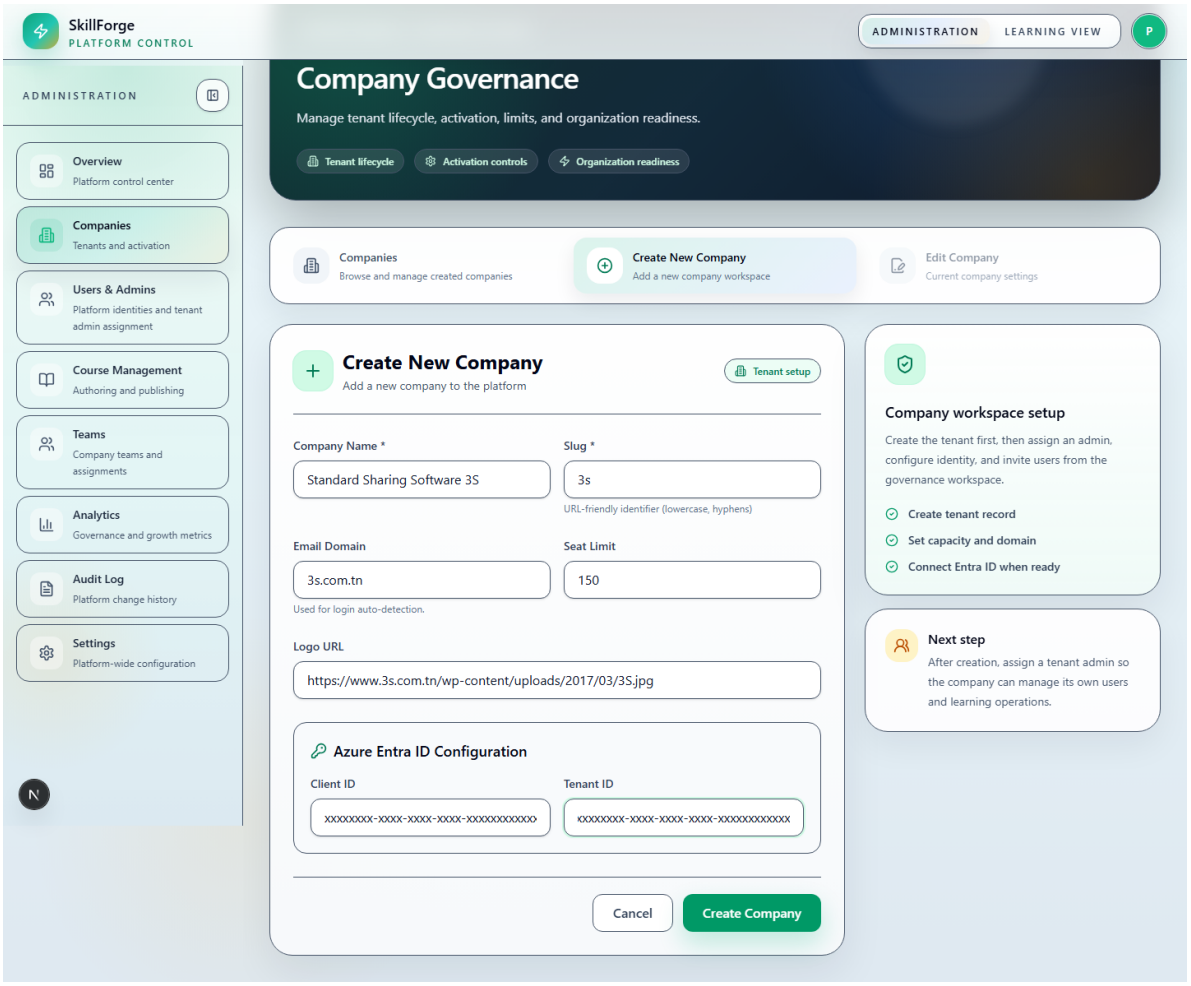


FIGURE 4.3 – Création d'un tenant avec domaine d'entreprise, limite de sièges et paramètres d'identité

4.2.1.3 Gestion des utilisateurs et des comptes

Le module *Identity* permet de gérer les comptes utilisateurs rattachés aux tenants. Cette gestion est assurée par le *SuperAdmin* au niveau global de la plateforme et par l'*Admin* au niveau de son entreprise. Ces rôles peuvent créer des comptes, définir le département, attribuer un rôle et suivre le statut des utilisateurs dans leur périmètre d'accès.

La figure 4.4 illustre l'interface de gestion des utilisateurs dans l'espace d'administration d'un tenant.

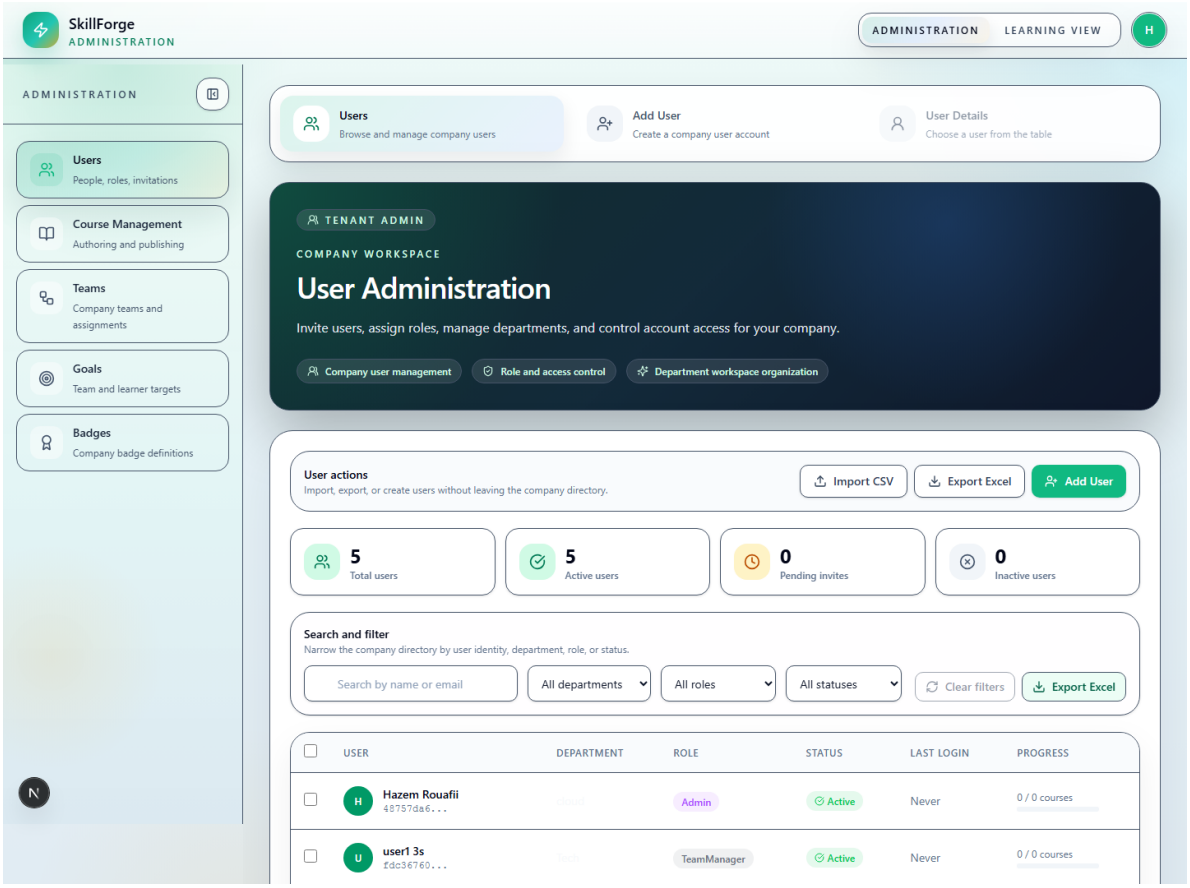


FIGURE 4.4 – Gestion des utilisateurs et des comptes dans l'espace d'administration d'un tenant

4.2.1.4 Mécanisme d'authentification

Le mécanisme d'authentification permet aux utilisateurs rattachés à une entreprise de se connecter à l'aide d'identifiants propres à la plateforme ou, lorsque le tenant est configuré, avec Azure Entra ID via un accès SSO (Single Sign-On, c'est-à-dire une connexion unique avec le compte de l'entreprise). Cette interface de connexion est illustrée par la figure 4.5.

Après la connexion, la plateforme détermine le contexte d'accès de l'utilisateur : identité, rôle, statut et tenant associé. Ce contexte permet de rediriger chaque profil vers son espace et d'appliquer les autorisations côté backend à travers des gardes comme `require_role`. Les rôles principaux gérés sont SuperAdmin, Admin, LearningExpert, TeamManager et TeamMember.

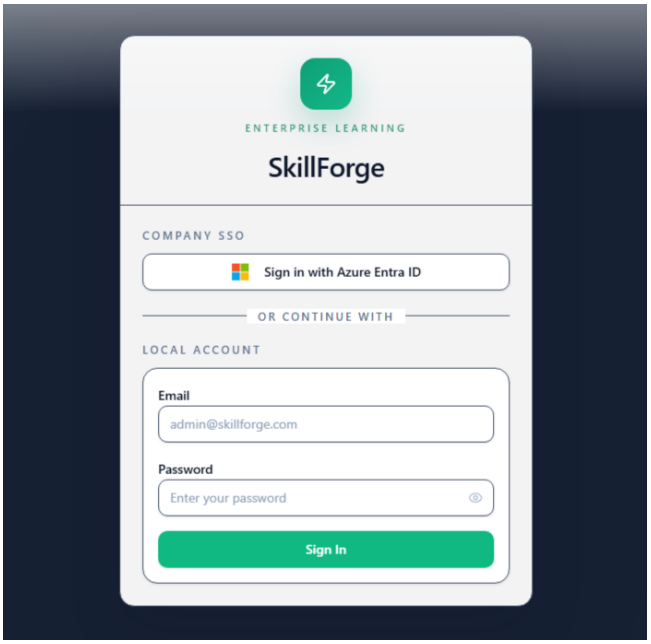


FIGURE 4.5 – Interface de connexion avec authentification applicative et option Azure Entra ID

4.2.1.5 Gestion des sessions et des jetons d'accès

Lors d'une connexion réussie, le module *Identity* génère un *access token* et un *refresh token*. L'*access token* autorise les appels aux API protégées et transporte le contexte minimal de sécurité, notamment l'utilisateur, son rôle et son tenant.

Le *refresh token* permet de renouveler la session sans demander une nouvelle connexion à chaque expiration de l'*access token*. Cette séparation maintient l'expérience utilisateur tout en limitant la durée de validité du jeton utilisé pour accéder aux ressources sensibles.

4.2.1.6 Traçabilité et audit des actions d'administration

Afin de renforcer la gouvernance de la plateforme, le module Identity conserve des traces des actions sensibles réalisées dans les espaces d'administration. Ces traces permettent de suivre les opérations liées aux tenants, aux comptes utilisateurs, aux changements de statut et aux actions effectuées par les administrateurs.

Cette traçabilité est importante dans un contexte multi-tenant, car elle permet de distinguer les actions globales du SuperAdmin des actions propres à une entreprise. La figure 4.6 illustre l'interface utilisée pour consulter ces traces.

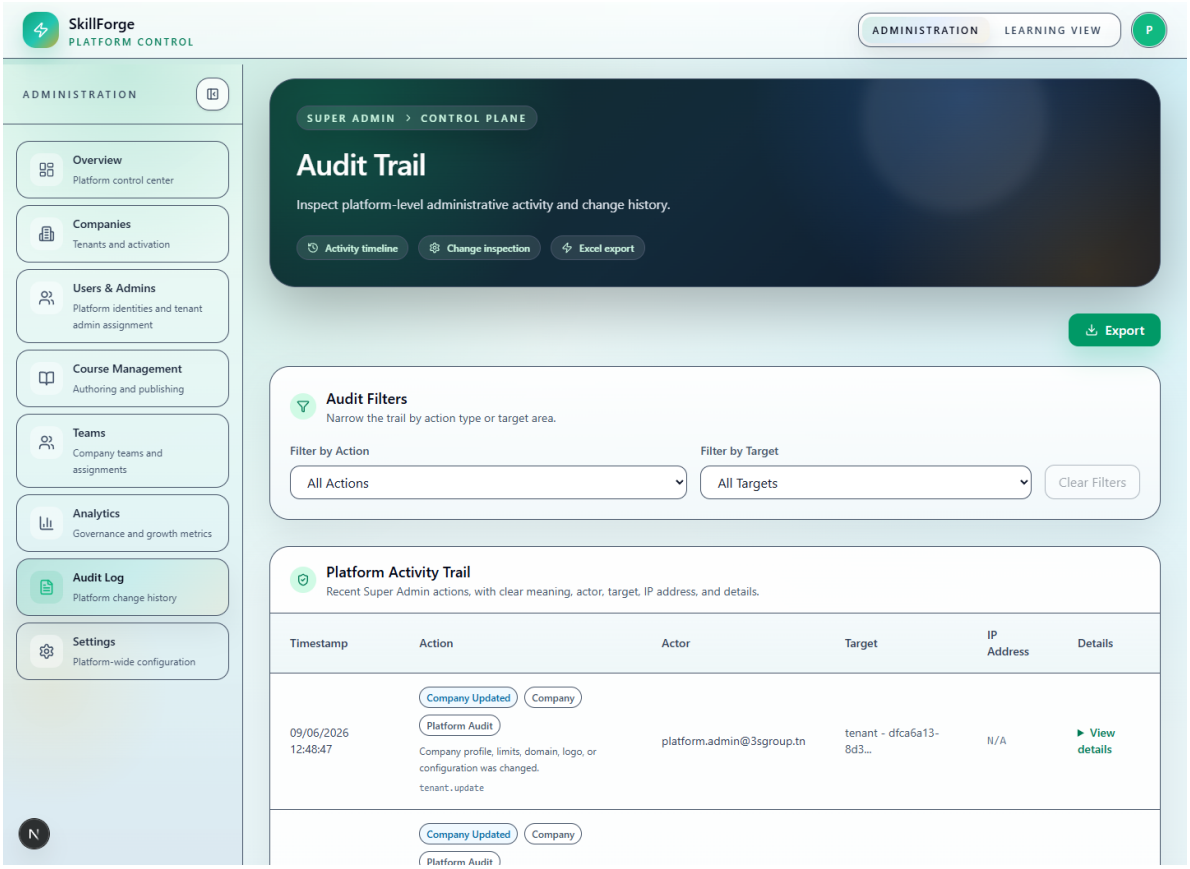


FIGURE 4.6 – Consultation des traces d'audit des actions d'administration

4.2.2 Gestion des formations, cours et progression

Le module *Learning* regroupe les fonctionnalités liées au parcours pédagogique des utilisateurs. Il couvre la création et l'organisation des cours, l'inscription des apprenants, le suivi de la progression et la mise à jour des objectifs d'apprentissage. Les données produites par ce module alimentent aussi d'autres parties de la plateforme, notamment la gamification, les notifications et les agents IA.

4.2.2.1 Gestion administrative et création des cours

Les utilisateurs autorisés, notamment le *SuperAdmin*, l'*Admin* et le *LearningExpert*, disposent d'interfaces pour créer et gérer les cours. Le *SuperAdmin* peut intervenir à l'échelle globale de la plateforme, tandis que l'*Admin* et le *LearningExpert* agissent dans le périmètre de leur tenant. Cette gestion permet de renseigner les informations principales du cours, de modifier son contenu, de suivre son état et de le publier lorsqu'il est prêt à être consulté par les apprenants.

Deux modes de création sont pris en charge :

— **Mode traditionnel :** le responsable crée manuellement le cours en renseignant ses informations principales, telles que le titre, la description, le niveau, la catégorie ainsi

que le nombre de points attribués à l'apprenant après sa complétion, comme l'illustre la figure 4.7.

Il définit ensuite la structure pédagogique du cours en organisant les leçons, les ressources et les évaluations. Chaque leçon peut contenir du contenu pédagogique, des supports vidéo ainsi que des ressources complémentaires. Le responsable peut également ajouter des quiz afin d'évaluer la compréhension des apprenants et d'assurer un suivi mesurable de leur progression. Cette organisation est illustrée par la figure 4.8.

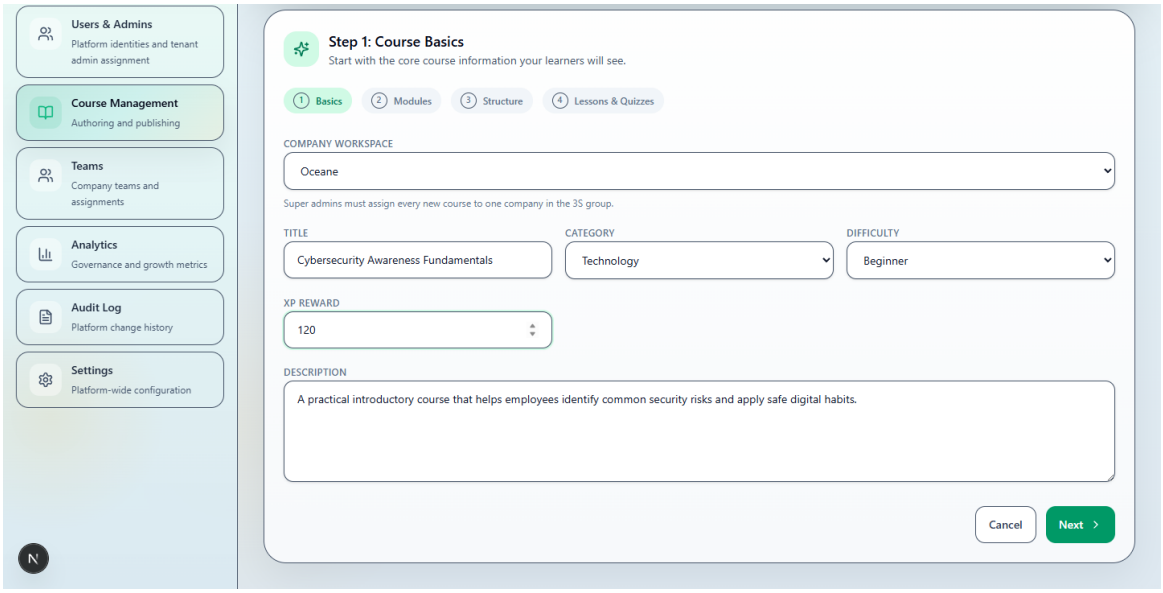


FIGURE 4.7 – Formulaire de création d'un cours traditionnel dans l'espace d'administration

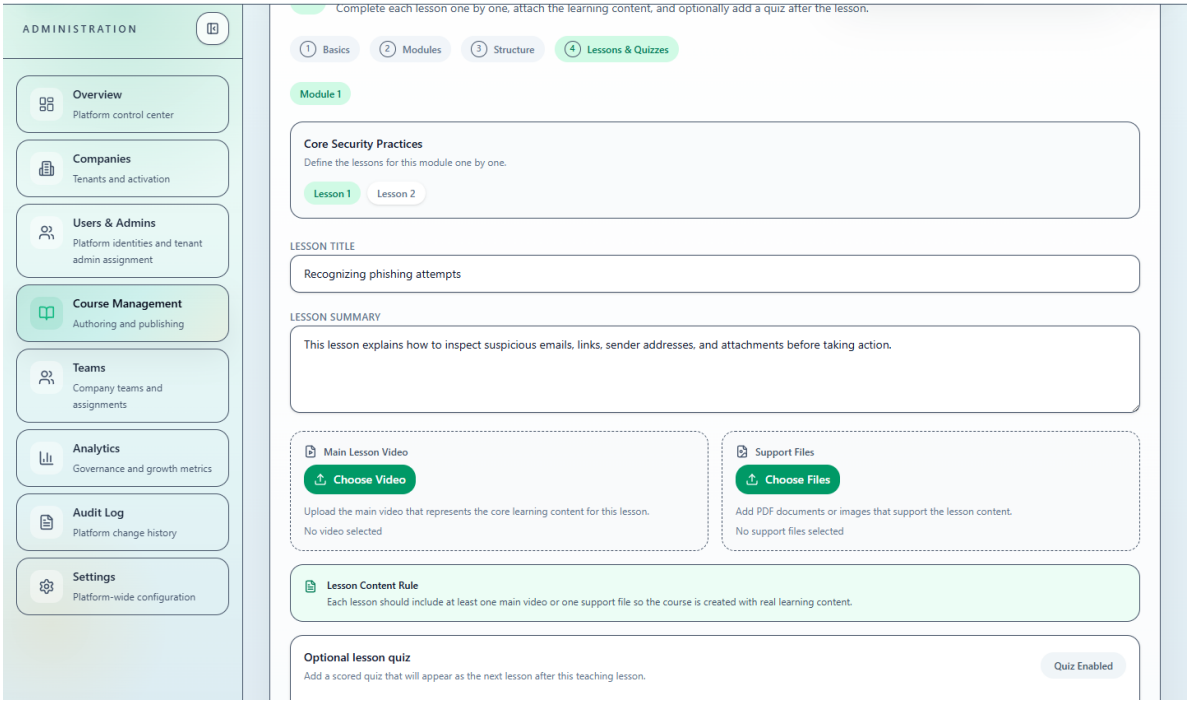


FIGURE 4.8 – Organisation d'un cours avec ses leçons, vidéos, ressources et quiz

— **Mode *AI generated* :** le responsable pédagogique démarre la création assistée en décrivant le besoin de formation à couvrir. Il renseigne les informations nécessaires à la génération, notamment le sujet du cours, le public cible, le niveau attendu, les objectifs d'apprentissage, les compétences à développer, la durée souhaitée, le nombre de leçons ainsi que, éventuellement, la langue ou certaines consignes spécifiques. La figure 4.9 illustre l'interface utilisée pour saisir ce besoin.

À partir de ces informations, la plateforme génère automatiquement un brouillon structuré du cours comprenant le plan global, les objectifs pédagogiques, les leçons proposées, le contenu initial ainsi que des questions de quiz lorsque cela est pertinent.

Afin de faciliter l'adaptation du contenu, la plateforme intègre un assistant IA de révision permettant au responsable pédagogique de demander des modifications en langage naturel via une interface conversationnelle. Il peut ainsi reformuler une section, approfondir une notion, simplifier un passage, ajouter des exemples ou adapter le contenu à un public spécifique. Les modifications sont appliquées directement au brouillon, ce qui réduit les manipulations manuelles et accélère le processus de création.

Le cours généré reste entièrement éditable et sous le contrôle du responsable pédagogique, qui peut vérifier le contenu, effectuer des ajustements complémentaires et valider la cohérence pédagogique avant publication. La figure 4.10 illustre le résultat généré ainsi que les éléments modifiables du cours produit.

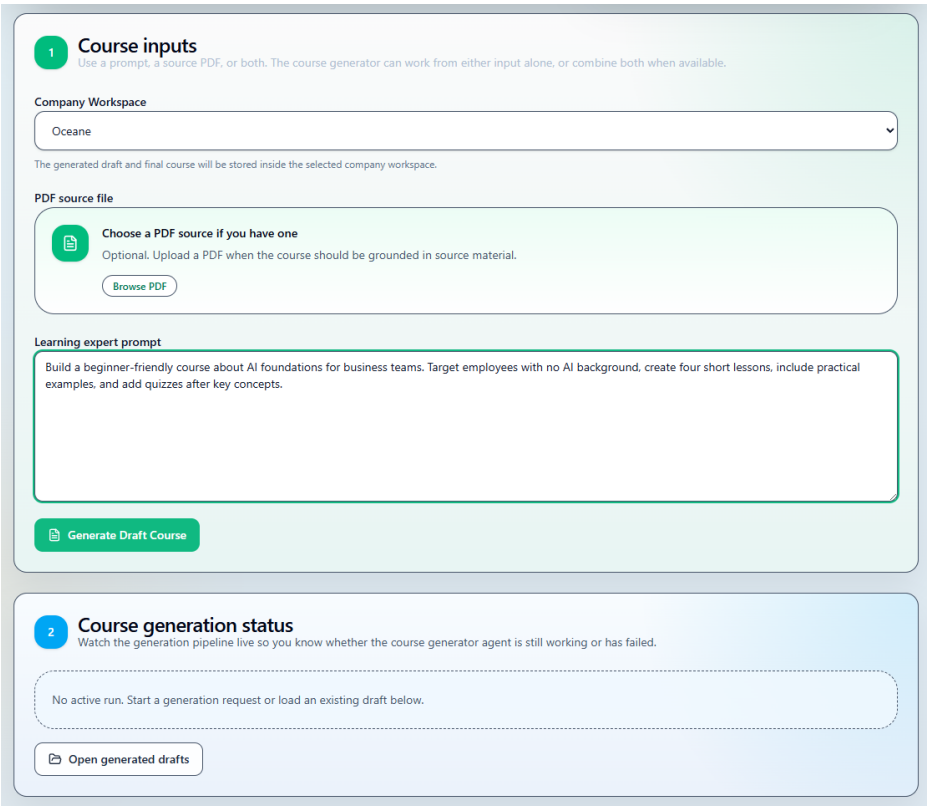


FIGURE 4.9 – Interface de création d'un cours généré par IA avec les champs de saisie du besoin pédagogique

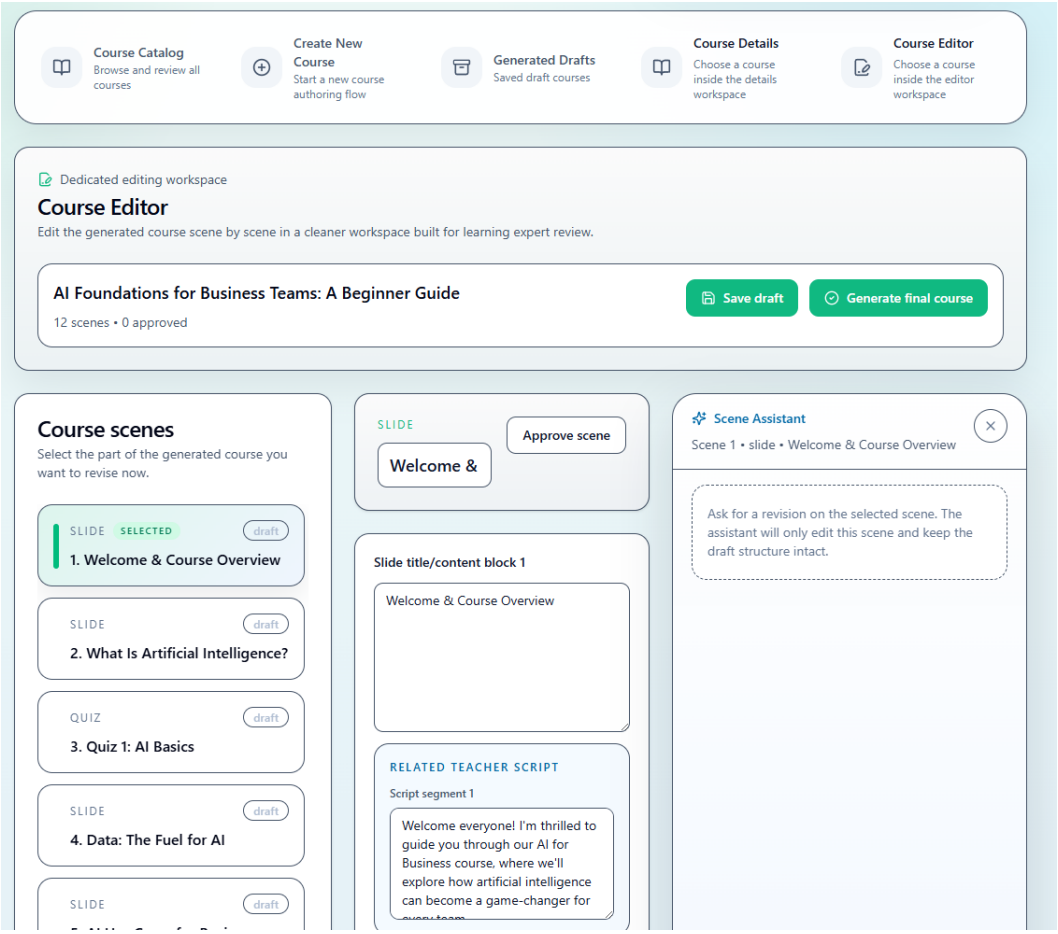


FIGURE 4.10 – Résultat de génération affichant le brouillon du cours, ses leçons et ses éléments éditables

4.2.2.2 Inscription des apprenants aux cours

Les apprenants peuvent accéder aux cours publiés dans le périmètre de leur tenant depuis le catalogue de cours, présenté dans la figure 4.11. Cette interface permet de consulter les formations disponibles, de filtrer les résultats et d'ouvrir la page détaillée d'un cours.

L'inscription se fait depuis la page de détail du cours, où l'apprenant retrouve les informations principales de la formation, sa durée, son niveau, le nombre de modules et le bouton d'inscription, comme l'illustre la figure 4.12. Une fois inscrit, le cours apparaît dans l'espace *My Learning*, qui regroupe les formations en cours et les formations terminées, comme le montre la figure 4.13.

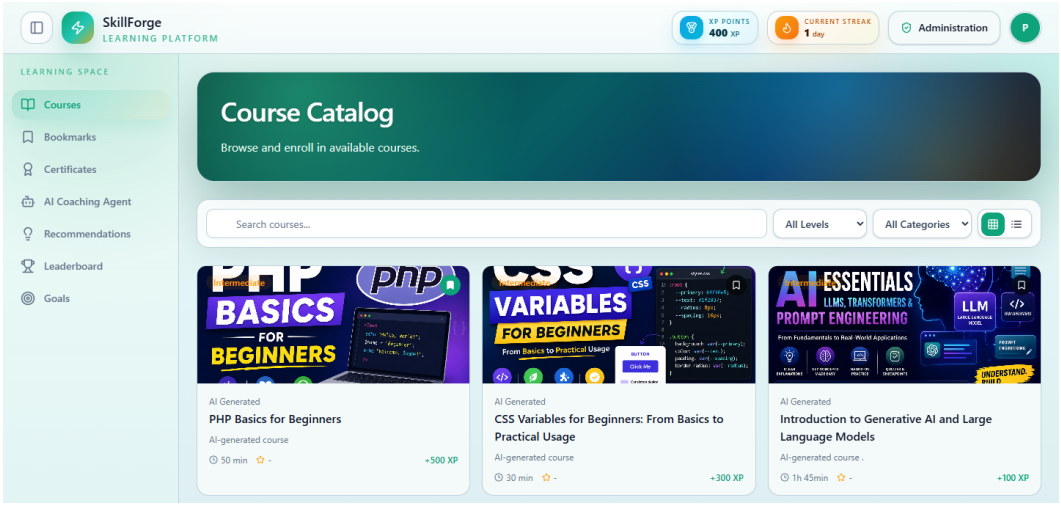


FIGURE 4.11 – Catalogue des cours disponibles pour l'apprenant



FIGURE 4.12 – Page de détail d'un cours avec l'action d'inscription

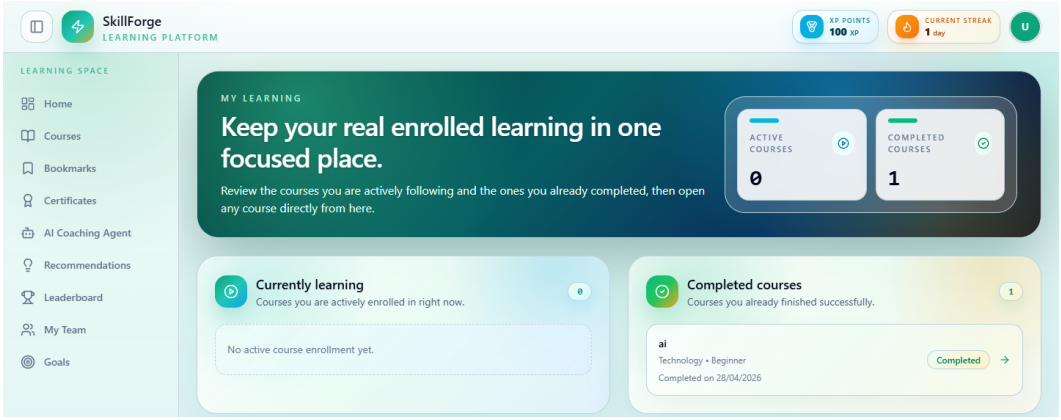


FIGURE 4.13 – Espace My Learning affichant les cours inscrits de l'apprenant

4.2.2.3 Suivi de la progression individuelle

Le suivi de progression repose sur les activités réalisées par l'apprenant, comme la consultation des leçons, leur complétion et l'avancement global dans un cours. Ces informations sont affichées dans la page de progression individuelle, qui regroupe les indicateurs principaux : points d'expérience (XP), niveau, série d'apprentissage, leçons terminées, cours complétés et activités récentes, comme le montre la figure 4.14.

La progression est aussi visible depuis l'espace *My Learning*, comme illustré en figure 4.13. Cette page distingue les cours en cours des cours terminés, ce qui permet à l'apprenant de reprendre rapidement son parcours ou de consulter les formations déjà finalisées.

Au niveau d'une leçon, la plateforme affiche l'état d'avancement du cours, le nombre de leçons complétées et le statut de chaque leçon. La figure 4.15 illustre ce suivi détaillé dans l'interface de lecture.

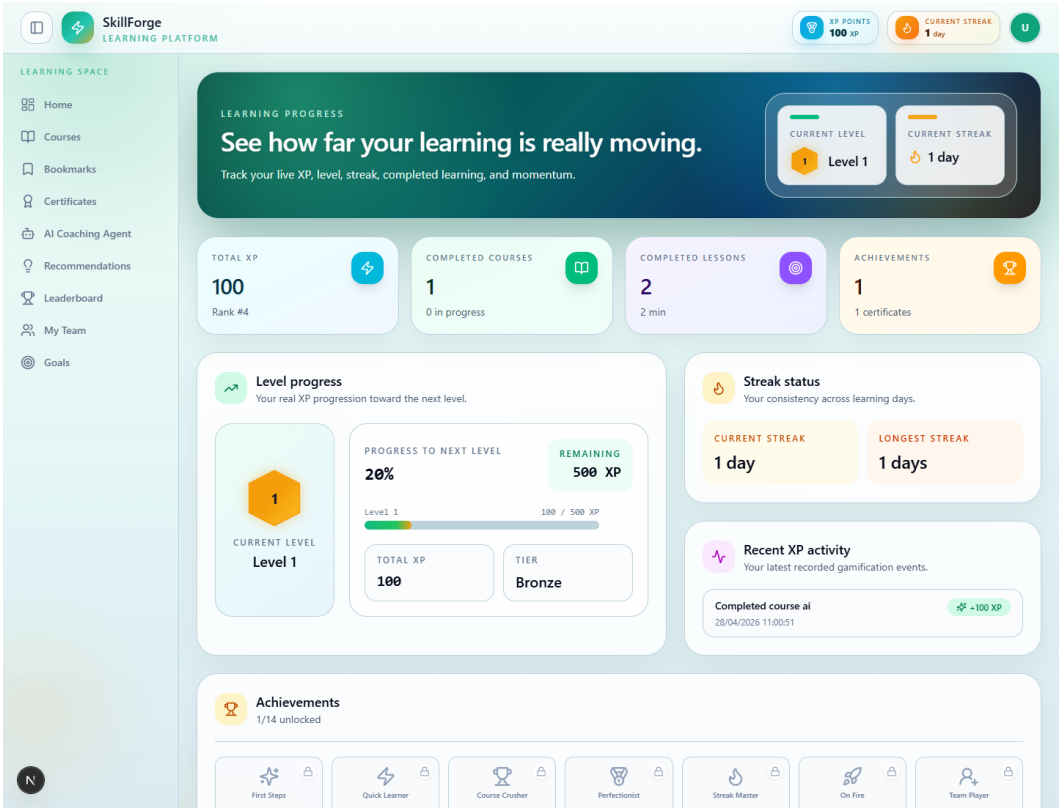


FIGURE 4.14 – Tableau de progression individuelle affichant les indicateurs d'apprentissage de l'utilisateur

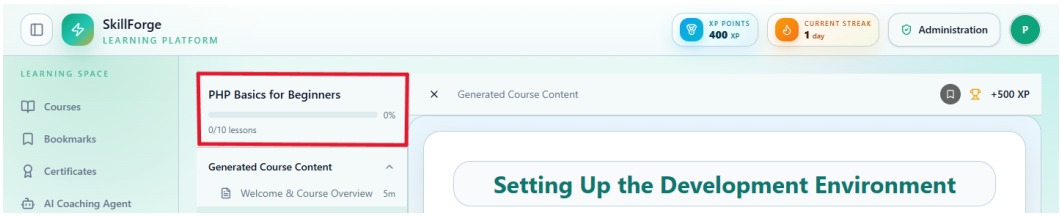


FIGURE 4.15 – Suivi détaillé de la progression dans une leçon

4.2.2.4 Objectifs d'apprentissage personnels et collectifs

La plateforme permet aussi de gérer des objectifs d'apprentissage personnels et collectifs. Les objectifs personnels ciblent un utilisateur précis, tandis que les objectifs d'équipe concernent plusieurs membres d'une même équipe. Leur progression peut être mise à jour automatiquement à partir des activités réelles, par exemple le nombre de leçons terminées ou le temps d'étude réalisé, comme le montre la figure 4.16.

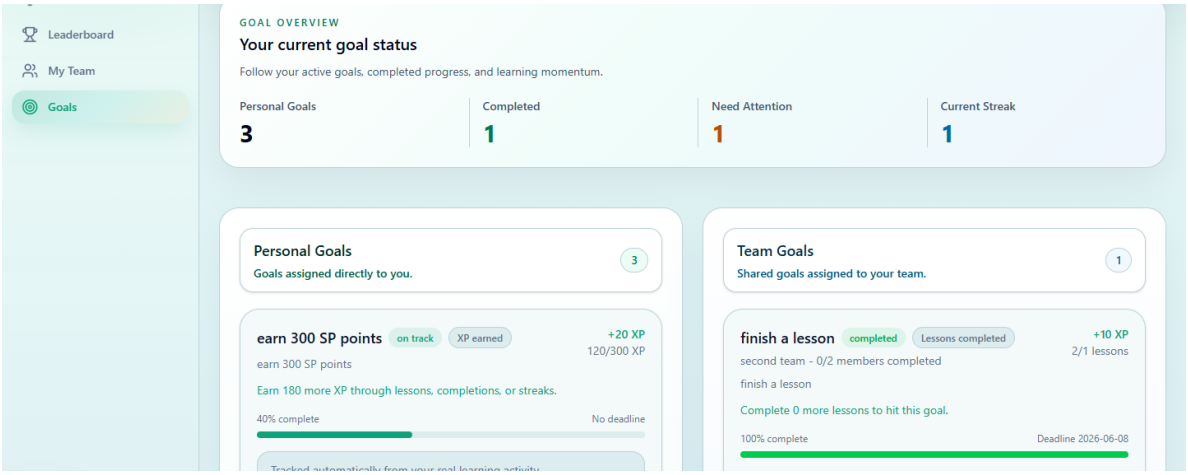


FIGURE 4.16 – Interface de suivi des objectifs personnels et des objectifs d'équipe

4.2.2.5 Certificats de fin de cours et vérification

À la fin d'un cours, la plateforme délivre un certificat à l'apprenant lorsque les conditions de complétion sont satisfaites, à savoir la validation de l'ensemble des leçons et la réussite des quiz associés avec un score minimum de 90 %. Ce certificat constitue une preuve officielle de réussite et de validation du parcours suivi. Il est accessible depuis l'espace personnel de l'utilisateur et contient les informations essentielles liées à l'apprenant, au cours et à la date d'obtention.

La plateforme propose également un espace dédié à la consultation des certificats, permettant de visualiser l'ensemble des certificats obtenus après la complétion des cours (voir figure 4.17). Chaque certificat peut être consulté en détail (voir figure 4.18), et une interface de vérification permet d'en contrôler l'authenticité à partir de son identifiant ou de son lien de vérification.

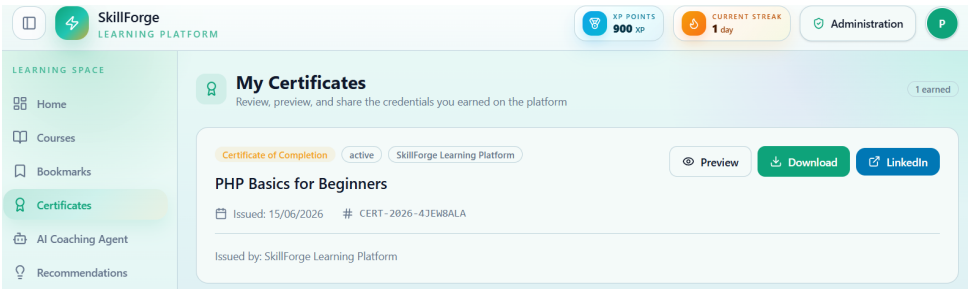


FIGURE 4.17 – Liste des certificats obtenus par l'apprenant



FIGURE 4.18 – Détail d'un certificat délivré

Mécanisme de sécurité et de vérification Afin de garantir l'intégrité des certificats, la plateforme repose sur une signature numérique basée sur l'algorithme **RS256** (RSA avec SHA-256) :

- **Hachage SHA-256 :** les données du certificat sont sérialisées et hashées pour produire un *content_hash*.
- **Signature RS256 :** le contenu du certificat est signé avec une clé privée RSA, et la signature est stockée en base.
- **Vérification :** lors de la consultation, le système recalcule le hash, vérifie la signature via la clé publique et contrôle l'état du certificat (validité, révocation).
- **QR code :** chaque certificat est associé à un QR code pointant vers une URL de vérification (`/verify/{id}`), permettant un contrôle rapide de son authenticité. La figure 4.19 illustre le processus de vérification après scan du QR code ainsi que l'affichage du résultat de validation du certificat.

Ainsi, toute modification des données invalide automatiquement la signature, empêchant toute falsification. La clé privée est sécurisée via une variable d'environnement (`CERT_PRIVATE_KEY`).

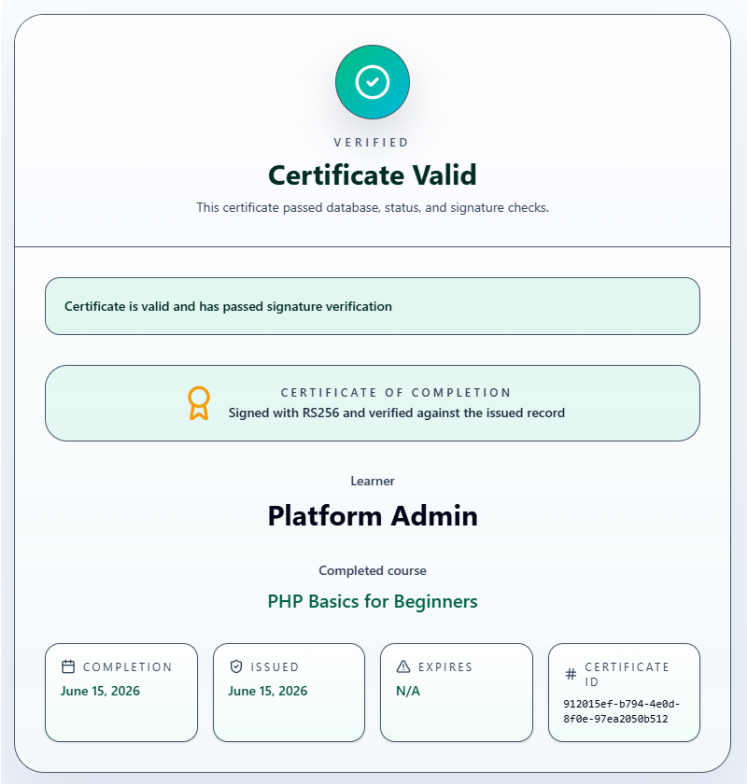


FIGURE 4.19 – Page de vérification publique d'un certificat après scan du QR code

4.2.3 Mentorat et gamification

Le module de mentorat et de gamification complète le module *Learning* en transformant les activités d'apprentissage en indicateurs de suivi et en éléments de motivation. Il permet de suivre la progression des apprenants, de valoriser leurs réussites et d'encourager leur engagement à travers les points XP, les niveaux, les badges, les objectifs et les classements.

— **Suivi de la progression et du niveau de l'apprenant**

La plateforme affiche un tableau de progression permettant à l'utilisateur de suivre son niveau actuel, ses points XP (figure 4.20), sa série d'apprentissage ainsi que l'état d'avancement vers le niveau suivant. Le tableau de progression présenté en figure 4.14, constitue également la base du système de gamification, car les indicateurs affichés sont utilisés pour calculer les niveaux, les récompenses et la progression globale de l'apprenant.

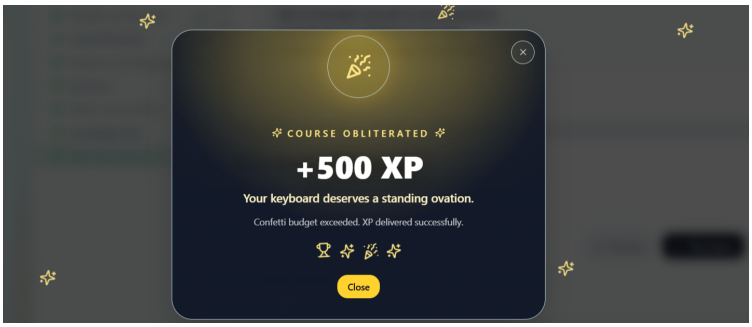


FIGURE 4.20 – Illustration de l'obtention des points XP

— **Badges et reconnaissance des réussites**

Les badges matérialisent les réussites obtenues par les utilisateurs. Ils peuvent être liés à la complétion d'un cours, à l'atteinte d'un objectif, à une performance particulière ou à la participation à un challenge. L'apprenant peut consulter les badges obtenus et ceux qui restent à débloquer depuis son espace de progression, comme l'illustre la figure 4.21.

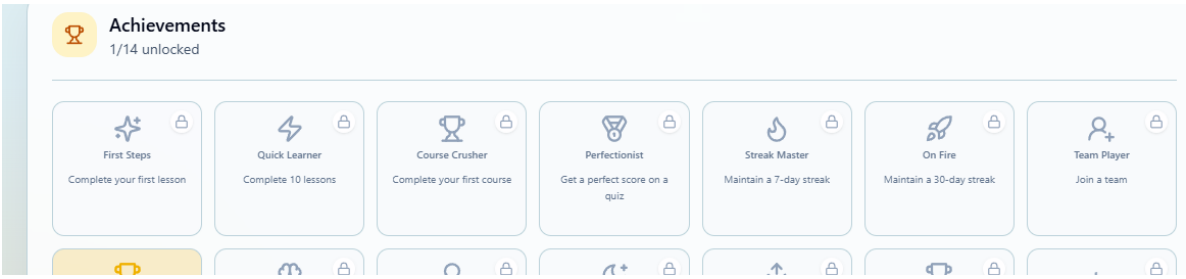


FIGURE 4.21 – Affichage des badges obtenus et non encore débloqués

— **Création et gestion des badges personnalisés**

Les badges personnalisés peuvent être créés par les rôles autorisés, notamment l'administrateur, le *Learning Expert* et le *Team Manager*. Chaque badge est rattaché au tenant de l'entreprise, ce qui garantit que les badges créés dans une société ne sont pas visibles par les autres sociétés. L'interface de gestion des badges permet de définir le nom, le niveau, la condition d'obtention et le contexte d'utilisation du badge, comme le montre la figure 4.22.

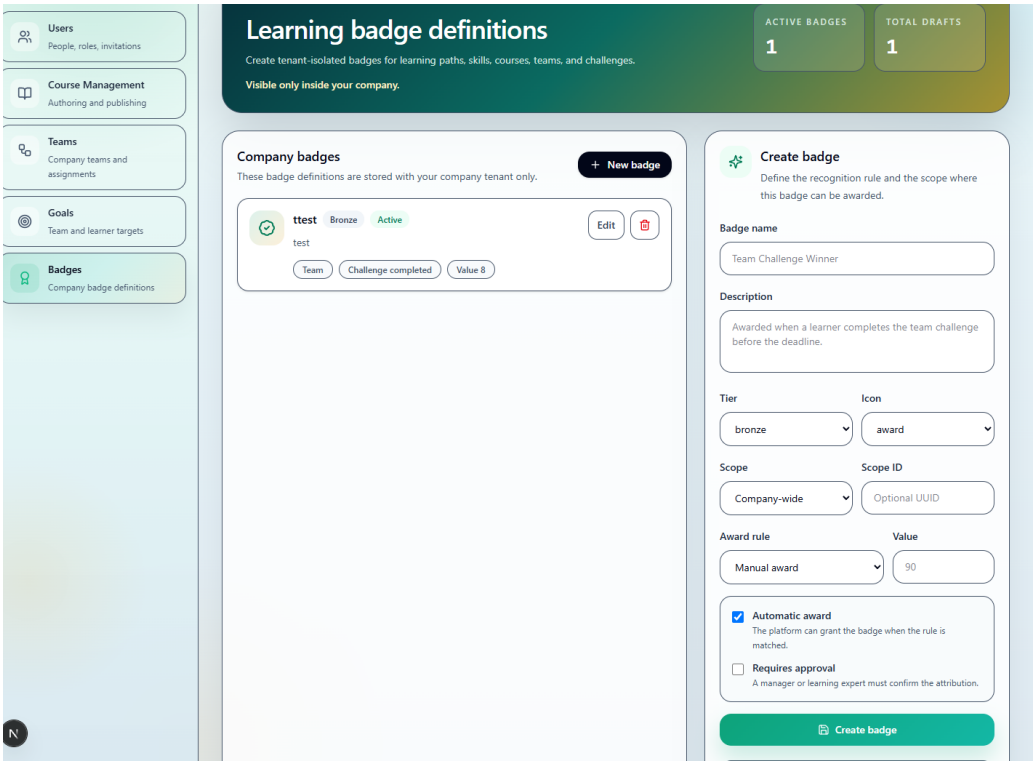


FIGURE 4.22 – Interface de gestion des badges personnalisés

— **Classement des apprenants**

Le classement permet de comparer la progression des utilisateurs selon leurs points XP, leur niveau et leur activité d'apprentissage. Il offre une vue synthétique de la dynamique d'engagement au sein de la plateforme et peut être utilisé pour suivre la progression globale des apprenants ou des équipes, comme le présente la figure 4.23.

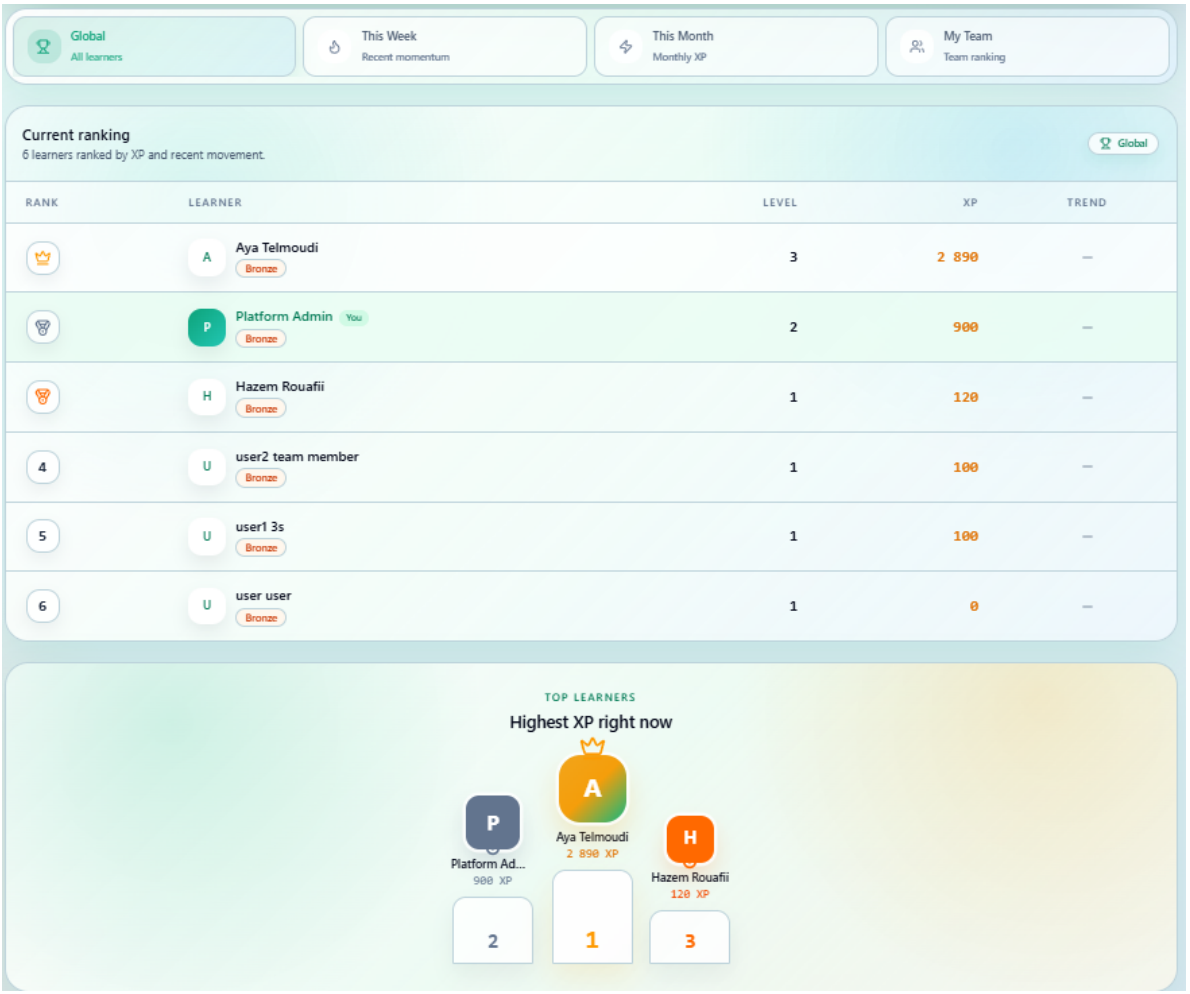


FIGURE 4.23 – Classement des apprenants selon leur progression

4.2.4 Modules IA – les 5 agents

Les modules IA constituent la partie intelligente de la plateforme. Ils interviennent à différents moments du parcours : création de cours, mémorisation des signaux d'apprentissage, accompagnement personnalisé, recommandation de contenus et génération de challenges. Ces agents sont intégrés à l'application à travers des routes API dédiées et des services AgentOS séparés. Ils s'appuient sur les données du module *Learning*, sur le contexte du tenant et sur le système de mémoire persistante afin de produire des réponses adaptées au profil de l'utilisateur.

— **Agent de génération de cours**

L'agent de génération de cours assiste les responsables pédagogiques dans la création d'un brouillon de cours à partir d'un besoin exprimé. Il reçoit les informations saisies

dans l'interface, comme le sujet, le public cible, le niveau, les objectifs et les contraintes pédagogiques, puis transmet ces éléments au workflow de génération. Le résultat produit est un brouillon structuré composé d'un plan, de leçons et d'éléments éditables. Ce contenu n'est pas publié automatiquement : il doit être relu, corrigé et validé par un utilisateur autorisé avant son intégration dans le catalogue.

Le résultat éditable produit par cet agent a déjà été présenté dans la figure 4.10, qui montre le brouillon généré, ses leçons et ses éléments modifiables.

— **Agent de mémoire apprenant**

L'agent de mémoire apprenant conserve les informations utiles issues des activités réelles de l'utilisateur. Il peut exploiter des événements tels que la complétion d'une leçon, le résultat d'un quiz, une difficulté exprimée dans une discussion ou une réponse donnée lors d'un challenge. Ces informations sont transformées en traces durables et rattachées au bon contexte : utilisateur, tenant, cours et leçon. Cette mémoire permet ensuite aux autres agents de personnaliser leurs réponses au lieu de se limiter à une interaction isolée.

— **Agent de coaching IA**

L'agent de coaching IA accompagne l'apprenant pendant son parcours. Il peut être utilisé depuis la page de leçon ou depuis l'espace dédié au coaching. Lorsqu'un utilisateur pose une question, l'agent reçoit le contexte du tenant, du cours, de la leçon et de la session de discussion. Il interroge ensuite la mémoire disponible afin de produire une réponse contextualisée, liée au contenu du cours et aux difficultés déjà observées chez l'apprenant (figure 4.24).

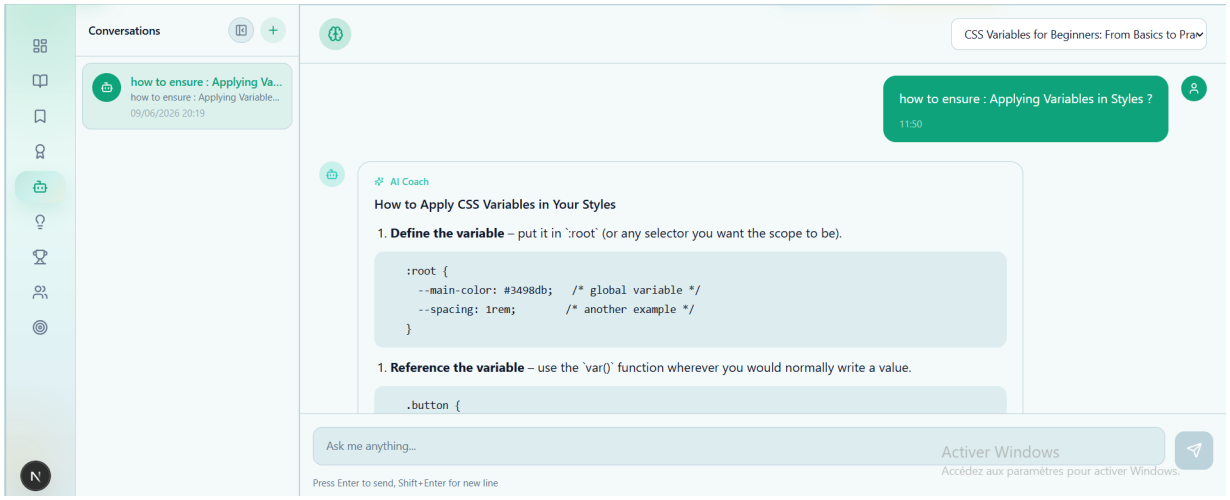


FIGURE 4.24 – Interaction entre l'apprenant et l'agent de coaching IA

— **Agent de recommandation**

L'agent de recommandation analyse le profil d'apprentissage de l'utilisateur, ses inscriptions, sa progression, les cours disponibles et les signaux de mémoire pour proposer les prochaines actions pertinentes. Il peut produire des recommandations de cours ou de

leçons, mais aussi contribuer à l'identification des écarts de compétences. Son objectif est d'orienter l'apprenant vers les contenus les plus utiles selon son historique et ses objectifs.

La figure 4.25 devra présenter l'interface des recommandations personnalisées générées pour un apprenant.

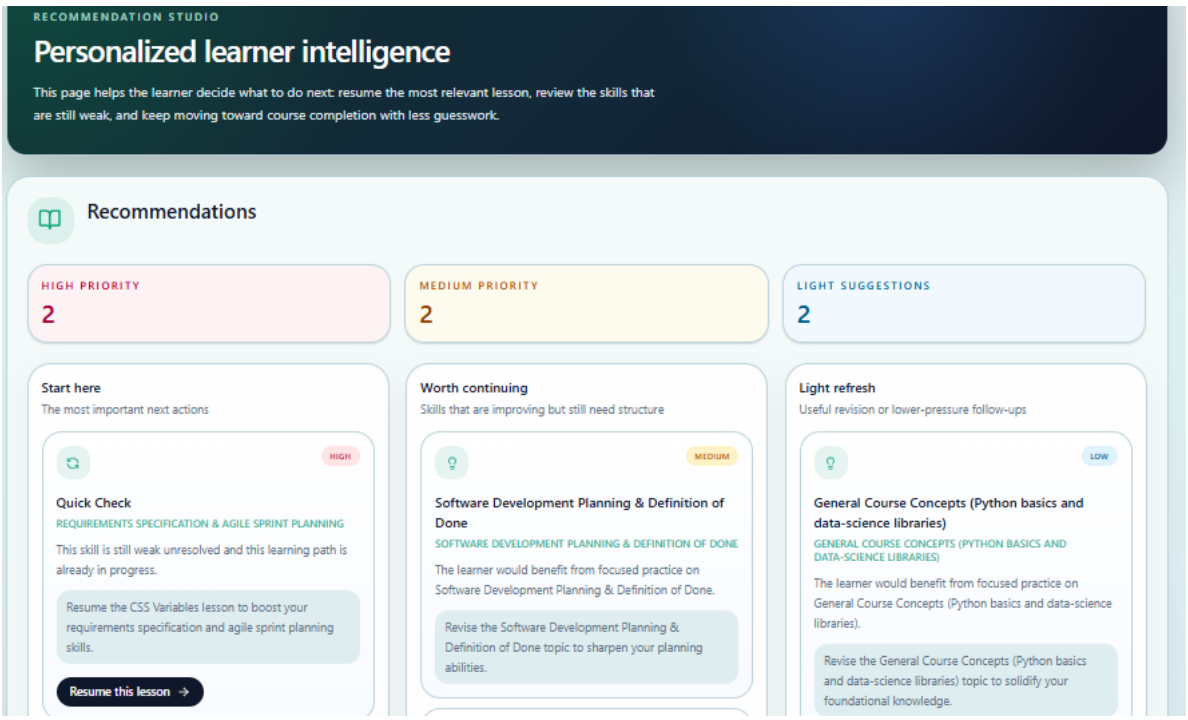


FIGURE 4.25 – Recommandations personnalisées proposées par l'agent IA

— **Agent de challenge personnalisé**

L'agent de challenge personnalisé génère une question ou une activité courte adaptée au contexte d'apprentissage de l'utilisateur. Il peut s'appuyer sur les erreurs de quiz, les difficultés mémorisées ou le cours suivi récemment afin de proposer un exercice ciblé. Après la réponse de l'apprenant, le résultat peut être utilisé pour mettre à jour la progression, attribuer des récompenses et enrichir la mémoire apprenant.

La figure 4.26 devra illustrer l'affichage d'un challenge personnalisé et son retour après réponse.

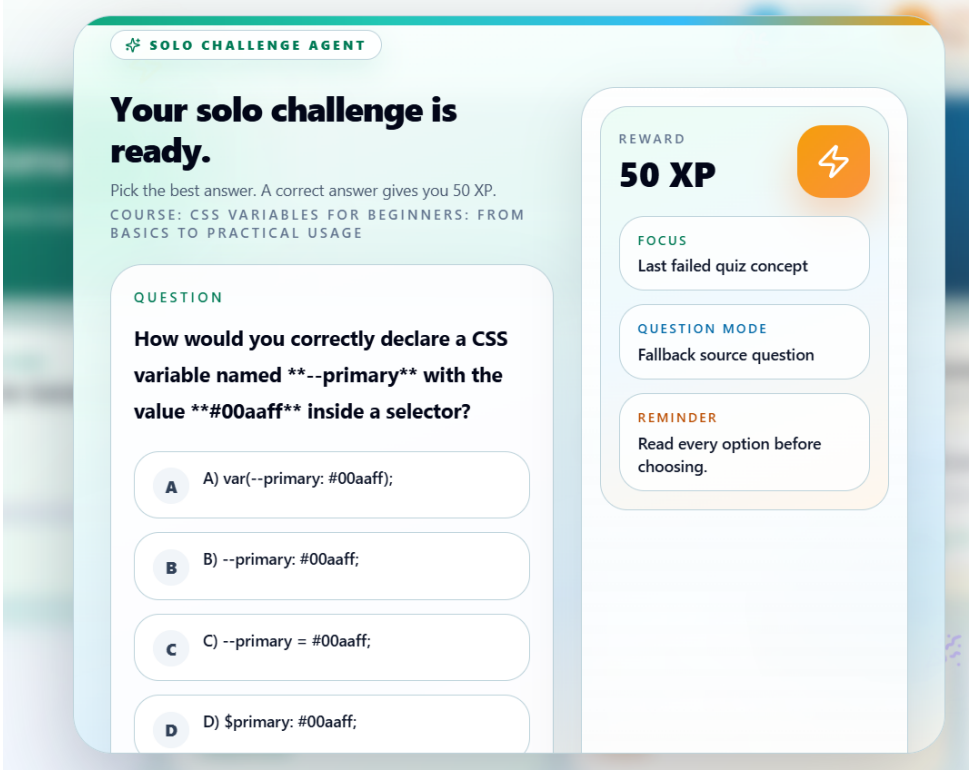


FIGURE 4.26 – Challenge personnalisé généré par l'agent IA

En complément de ces cinq agents, un workflow de mémoire de cours est utilisé pour préparer les connaissances liées aux cours publiés. Il transforme les contenus pédagogiques, les leçons et les quiz en documents exploitables par la mémoire persistante. Ce mécanisme sert de support aux agents, notamment au coach IA, à l'agent de recommandation et à l'agent de challenge, car il leur fournit une base de connaissances structurée sur le contenu réel des cours.

4.3 Déploiement et hébergement de la plateforme

Le déploiement de la plateforme a été réalisé sur une machine virtuelle Linux mise à disposition par la société, afin d'assurer un environnement stable et proche des conditions de production. L'accès à la VM se fait via SSH, et l'ensemble des opérations d'administration (vérification système, déploiement et exécution) est effectué directement en ligne de commande.

La machine virtuelle dispose d'une configuration adaptée aux besoins du projet, avec environ 8 vCPU, 15 Go de mémoire RAM et un espace disque d'environ 23 Go (dont une partie libre pour le déploiement). Cette configuration est suffisante pour le fonctionnement de la plateforme dans un contexte de démonstration et de tests fonctionnels, tout en nécessitant une surveillance de l'espace disque lors de l'exécution des services conteneurisés.

Le déploiement repose sur une approche entièrement conteneurisée via Docker et Docker Compose, garantissant la cohérence entre l'environnement de développement et l'environnement d'hébergement. L'ensemble des services de la plateforme est orchestré sous forme de conteneurs, notamment : le frontend Next.js, les services backend, PostgreSQL avec extension pgvector,

RabbitMQ, MinIO, ainsi que les services liés aux agents IA.

Le processus de déploiement comprend la récupération du code source depuis le dépôt Git, la configuration des variables d'environnement (JWT, base de données, URLs des services, clés d'accès et paramètres IA), puis le lancement de l'ensemble des services via Docker Compose. Cette approche permet de garantir une installation reproductible et centralisée de la plateforme.

Une fois les conteneurs démarrés, la plateforme est accessible via l'adresse IP de la VM, soit directement à travers le port exposé du frontend, soit via le point d'entrée configuré par le reverse proxy.

Enfin, l'architecture de déploiement reste évolutive et permet une migration future vers un environnement cloud plus robuste, tout en conservant les mêmes artefacts Docker et la même configuration, ce qui facilite la portabilité et la maintenance de la solution.

4.4 Conclusion

Ce chapitre a présenté la réalisation concrète des principaux modules de la plateforme, couvrant la gestion des identités, des formations, du mentorat, de la gamification et des agents d'intelligence artificielle. L'architecture décrite dans le chapitre précédent a été traduite en fonctionnalités opérationnelles, accessibles depuis les interfaces développées. Le déploiement a été préparé autour d'une approche conteneurisée, prête pour un hébergement sur VM. Les tests, l'évaluation des résultats et l'analyse des limites sont détaillés dans le chapitre suivant.

Chapitre 5

Tests et validation

Contents

5.1 Introduction 71

5.2 Tests et validation 71

5.2.1 Tests unitaires 71

5.2.2 Tests fonctionnels 73

5.2.3 Tests de performance 73

5.2.4 Évaluation qualitative des modules IA 75

5.3 Évaluation et discussion des résultats 77

5.3.1 Tableau de traçabilité exigences – réalisation 77

5.3.2 Limites identifiées et perspectives 78

5.4 Conclusion 79

5.1 Introduction

Ce chapitre présente la phase de tests et de validation de la plateforme développée. L'objectif est de vérifier le bon fonctionnement des différents modules, de s'assurer de la conformité par rapport aux exigences définies, et d'évaluer la stabilité globale du système.

Les tests ont été organisés en plusieurs niveaux complémentaires, allant des tests unitaires sur les composants internes jusqu'aux tests fonctionnels simulant des scénarios réels d'utilisation. Une attention particulière est également portée aux performances ainsi qu'à l'évaluation des modules d'intelligence artificielle.

Enfin, une analyse des résultats obtenus permet de mettre en évidence les points forts de la solution ainsi que les limites identifiées.

5.2 Tests et validation

La phase de tests et validation vise à garantir la fiabilité et la robustesse de la plateforme avant sa mise en production. Elle permet de vérifier que chaque composant fonctionne correctement de manière isolée, mais également que l'ensemble du système répond aux exigences fonctionnelles et non fonctionnelles définies en amont.

Pour cela, plusieurs types de tests ont été réalisés, notamment les tests unitaires, les tests fonctionnels, les tests de performance, ainsi qu'une évaluation qualitative des modules d'intelligence artificielle.

5.2.1 Tests unitaires

Les tests unitaires ont pour objectif de vérifier le comportement des fonctions et des composants critiques de manière isolée. Dans la plateforme, ils concernent principalement les services backend Python, les modèles partagés, les mécanismes d'authentification, la gestion des rôles, la progression, les objectifs, les badges et les notifications.

Les tests backend sont réalisés avec *pytest*. Ils sont organisés au niveau des services et du paquet commun afin de valider les règles métier indépendamment de l'interface utilisateur. Les fichiers de tests couvrent notamment le module *Identity*, le module *Learning* et les utilitaires communs utilisés par les microservices. Le périmètre des parties testées est synthétisé dans le tableau 5.1.

TABLE 5.1 – Périmètre des tests unitaires réalisés

Partie testée	**Éléments vérifiés**
Authentification et jetons	Génération, validation et renouvellement des jetons d'accès et de rafraîchissement.
Contrôle d'accès	Hiérarchie des rôles, accès autorisés et refusés selon le profil utilisateur.
Gestion des utilisateurs	Création de comptes, validation du domaine e-mail, import CSV et rattachement au tenant.
Cours et inscriptions	Consultation des cours, inscription, protection contre les doublons et isolation par tenant.
Progression et gamification	Complétion de leçons, attribution XP, badges, objectifs et classement.

Ces tests permettent de sécuriser les règles sensibles avant de passer aux scénarios fonctionnels complets. Par exemple, les tests du module *Identity* valident qu'un utilisateur ne peut pas accéder à des ressources qui ne correspondent pas à son rôle ou à son tenant. Les tests du module *Learning* vérifient que les actions d'apprentissage réelles, comme la complétion d'une leçon, déclenchent correctement la progression, les événements et les récompenses associées. La figure 5.1 illustre l'exécution d'un ensemble représentatif de tests unitaires avec *pytest*.

```
PS D:\PFE\OpenMAIC\upskilling_platform> python -m pytest services/identity/tests/test_jwt.py services/identity/tests
est_rbac.py services/learning/tests/test_xp.py services/notifications/tests/test_realtime.py -q

.................................                                    [100%]
============================== warnings summary ===============================
services\notifications\main.py:402
  D:\PFE\OpenMAIC\upskilling_platform\services\notifications\main.py:402: DeprecationWarning:
          on_event is deprecated, use lifespan event handlers instead.

          Read more about it in the
          [FastAPI docs for Lifespan Events](https://fastapi.tiangolo.com/advanced/events/).

    @app.on_event("startup")

C:\Users\ayate\AppData\Local\Programs\Python\Python311\Lib\site-packages\fastapi\applications.py:4599
  C:\Users\ayate\AppData\Local\Programs\Python\Python311\Lib\site-packages\fastapi\applications.py:4599: Deprecatior
rning:
          on_event is deprecated, use lifespan event handlers instead.

          Read more about it in the
          [FastAPI docs for Lifespan Events](https://fastapi.tiangolo.com/advanced/events/).

    return self.router.on_event(event_type)

-- Docs: https://docs.pytest.org/en/stable/how-to/capture-warnings.html
37 passed, 2 warnings in 3.01s
```

FIGURE 5.1 – Exécution des tests unitaires avec pytest et affichage du résultat dans le terminal

5.2.2 Tests fonctionnels

Les tests fonctionnels complètent les tests unitaires en validant le comportement de bout en bout des fonctionnalités de la plateforme. Ils vérifient que les actions utilisateur produisent les résultats attendus à travers l'interface web et les API, en couvrant l'ensemble des couches du système : frontend, backend, base de données et authentification.

Les scénarios testés couvrent les parcours principaux, de la connexion jusqu'à l'obtention d'un certificat, en passant par la gestion des cours, la progression, la gamification et les évaluations. Le tableau 5.2 synthétise ces tests.

Ces tests ont été automatisés à l'aide de Playwright CLI, permettant de simuler des interactions réelles utilisateur et de valider les flux end-to-end de manière fiable et reproductible dans un environnement proche de la production.

TABLE 5.2 – Scénarios de tests fonctionnels réalisés

Module	**Scénario testé**
Authentification	Connexion avec identifiants applicatifs et redirection vers l'espace approprié.
Multi-tenant	Isolation des données utilisateur entre deux entreprises distinctes.
Gestion de cours	Création, modification, publication et consultation d'un cours complet (leçons, quiz).
Inscription	Inscription d'un apprenant à un cours et vérification de l'accès au contenu.
Progression	Complétion d'une leçon, mise à jour du score de progression et déclenchement des événements.
Objectifs	Création, modification, complétion d'objectifs.
Certificats	Génération d'un certificat après complétion complète du cours.
Badges	Attribution d'un badge après déverrouillage d'un palier de progression.
Évaluations	Participation à un quiz et enregistrement des réponses.
Classement	Consultation du classement d'équipe et mise à jour après des actions gagnant de l'XP.
Coach IA	Obtention d'une recommandation contextuelle via l'interface du coach.
Gestion des équipes	Création d'une équipe, attribution de membres, définition du TeamManager.

5.2.3 Tests de performance

Les tests de performance ont pour objectif de mesurer le temps de réponse des différents composants de la plateforme et de vérifier le comportement du système sous une charge simulée. Ils permettent d'identifier les goulots d'étranglement potentiels et d'évaluer si la plateforme

peut supporter une utilisation avec plusieurs utilisateurs simultanés dans les conditions d'une démonstration PFE ou d'un déploiement limité.

5.2.3.1 Temps de réponse des API et capacité sous charge

Les mesures ont été réalisées avec *Locust*, un outil de tests de charge en Python. Les tests ont ciblé les API les plus sollicitées de la plateforme : authentification, consultation des cours, progression, classement et endpoints liés aux agents IA.

Le tableau 5.3 présente les latences moyennes mesurées pour chaque endpoint avec 1, 10 et 25 utilisateurs simultanés.

TABLE 5.3 – Latence moyenne des API selon le nombre d'utilisateurs simultanés

Endpoint	**1 utilisateur**	**10 utilisateurs**	**25 utilisateurs**
POST /auth/login	0,045 s	0,120 s	0,210 s
GET /courses	0,030 s	0,095 s	0,180 s
GET /progress	0,025 s	0,080 s	0,160 s
GET /leaderboard	0,035 s	0,110 s	0,200 s
POST /ai/coach	2,8 s	4,2 s	6,5 s
POST /ai/recommend	2,1 s	3,5 s	5,8 s
POST /ai/challenge	3,4 s	5,1 s	8,2 s

Les résultats montrent que les API classiques (authentification, cours, progression) ont des temps de réponse faibles, même avec 25 utilisateurs. En revanche, les endpoints liés aux agents IA présentent des latences plus élevées, ce qui est attendu compte tenu des appels aux modèles de langage et à la mémoire Hindsight. Pour une utilisation en production avec une charge importante, il serait nécessaire d'ajouter une file d'attente, un cache ou un traitement asynchrone pour ces endpoints.

5.2.3.2 Progression et gamification

Les tests de performance ont également mesuré le temps nécessaire pour effectuer différentes actions de progression et de gamification dans la plateforme. Le tableau 5.4 présente ces mesures avec 1, 10 et 25 utilisateurs simultanés.

TABLE 5.4 – Temps de réponse des actions de progression et gamification

Action	**1 utilisateur**	**10 utilisateurs**	**25 utilisateurs**
Complétion d'une leçon	0,120 s	0,320 s	0,580 s
Attribution d'un badge	0,085 s	0,250 s	0,460 s
Mise à jour du classement	0,095 s	0,280 s	0,510 s
Création d'un objectif	0,060 s	0,180 s	0,340 s
Génération d'un certificat	0,200 s	0,500 s	0,950 s

Les actions de progression et de gamification restent réactives jusqu'à 25 utilisateurs simultanés, avec des temps de réponse inférieurs à la seconde. La génération de certificat est l'action la plus lente, car elle implique la création d'un fichier PDF avec les informations de l'utilisateur et du cours. Pour un nombre plus important d'utilisateurs, il serait pertinent d'ajouter un mécanisme de génération asynchrone des certificats.

5.2.4 Évaluation qualitative des modules IA

5.2.4.1 Objectif de l'évaluation

Au-delà des tests fonctionnels, une évaluation qualitative a été réalisée afin de mesurer la pertinence et la qualité des réponses produites par les agents IA de la plateforme. Cette évaluation vise à vérifier que les réponses générées sont cohérentes avec le contexte fourni et adaptées aux besoins des utilisateurs.

5.2.4.2 Méthodologie avec RAGAS

L'évaluation a été réalisée à l'aide de la bibliothèque *RAGAS*, qui permet de quantifier la qualité des réponses produites par un système RAG à travers plusieurs métriques objectives :

- **Fidélité contextuelle (*faithfulness*)** : mesure dans quelle mesure la réponse générée reste fidèle aux informations contenues dans les documents de contexte récupérés. Une réponse avec une fidélité élevée ne contient pas d'affirmations qui ne sont pas supportées par le contexte.
- **Pertinence de la réponse (*answer relevancy*)** : évalue si la réponse répond bien à la question posée, en prenant en compte sa complétude et sa spécificité.
- **Pertinence du contexte (*context relevancy*)** : mesure si les documents de contexte récupérés par le système RAG sont réellement pertinents par rapport à la requête.
- **Rappel du contexte (*context recall*)** : évalue si le contexte récupéré contient suffisamment d'informations pour répondre correctement à la question.

— **Précision du contexte (*context precision*)** : mesure la proportion de documents de contexte pertinents parmi tous les documents récupérés.

Chacune de ces métriques produit un score normalisé entre 0 et 1, où 1 représente le meilleur résultat possible. Le score de *faithfulness* est particulièrement important pour les agents destinés aux apprenants, car il garantit que les conseils ou les réponses fournies ne contiennent pas d'inventions ou d'hallucinations.

5.2.4.3 Jeu de données d'évaluation

Le jeu de données d'évaluation a été construit manuellement à partir de scénarios représentatifs de l'utilisation des agents dans la plateforme. Chaque scénario comprend une question ou une tâche adressée à l'agent, un ensemble de documents de contexte récupérés depuis la mémoire persistante, et une réponse générée par l'agent. Les documents de contexte sont issus des cours suivants :

— **Gestion de projet** : Cours de 3 leçons sur les fondamentaux de la gestion de projet.
— **Python avancé** : Cours de 5 leçons sur les concepts avancés du langage Python.
— **Fondamentaux du management** : Cours de 4 leçons sur les bases du management.
— **Réseaux** : Cours de 3 leçons sur les fondamentaux des réseaux.
— **Sécurité informatique** : Cours de 4 leçons sur les bases de la sécurité informatique.
— **IA Générative** : Cours de 5 leçons sur l'intelligence artificielle générative.

Un total de 20 scénarios de test a été constitué, couvrant les cinq agents. Chaque scénario a été soumis à l'évaluation RAGAS sur les cinq métriques présentées précédemment.

5.2.4.4 Résultats obtenus avec RAGAS

Le tableau 5.5 présente les scores obtenus pour chaque agent sur les métriques RAGAS.

TABLE 5.5 – Scores RAGAS par agent

Agent	**Faithfulness**	**Answer relevancy**	**Context relevancy**	**Context recall**	**Context precision**
Coach IA	0,85	0,78	0,82	0,75	0,80
Recommandation	0,80	0,82	0,85	0,78	0,83
Défis personnalisés	0,78	0,75	0,80	0,72	0,77

Les résultats obtenus montrent que les agents IA génèrent globalement des réponses pertinentes et cohérentes avec le contexte pédagogique fourni. Les scores de *faithfulness* indiquent que les réponses restent majoritairement fidèles aux informations issues des cours et des mémoires Hindsight.

L'agent de recommandation obtient les meilleurs résultats grâce à l'exploitation des données de progression et des mémoires apprenant. L'agent de défis personnalisés présente des scores

légèrement inférieurs en raison de la complexité de la personnalisation des défis en fonction du parcours et des difficultés de chaque apprenant.

Les scores de *context recall* restent les plus faibles, ce qui suggère que certaines informations pertinentes ne sont pas toujours récupérées. Une amélioration future consisterait à optimiser les mécanismes de récupération et d'exploitation des mémoires afin de renforcer la personnalisation des réponses.

5.3 Évaluation et discussion des résultats

Cette section met en perspective les résultats obtenus en les confrontant aux exigences définies dans le cahier des charges. Elle dresse un bilan des fonctionnalités réalisées et identifie les limites de la solution actuelle avant d'esquisser des perspectives d'amélioration.

5.3.1 Tableau de traçabilité exigences – réalisation

Le tableau 5.6 établit la correspondance entre les exigences fonctionnelles définies dans le tableau 1.2 et leur réalisation dans la plateforme. Ce tableau de traçabilité permet de vérifier que l'ensemble des besoins exprimés a bien été couvert.

TABLE 5.6 – Tableau de traçabilité exigences fonctionnelles – réalisation

Référence	**Exigence**	**Statut**
EF-01	Authentification des utilisateurs avec gestion des rôles.	Réalisée
EF-02	Isolation des données par entreprise (multi-tenant).	Réalisée
EF-03	Gestion des profils utilisateurs.	Réalisée
EF-04	Gestion des cours (création, organisation).	Réalisée
EF-05	Suivi de progression individuelle.	Réalisée
EF-06	Objectifs d'apprentissage personnels.	Réalisée
EF-07	Certificats de fin de cours.	Réalisée
EF-08	Mentorat entre apprenants.	Réalisée
EF-09	Système de gamification.	Réalisée
EF-10	Coach IA contextuel.	Réalisée

Référence	Exigence	Statut
EF-11	Quiz et évaluations IA.	Réalisée
EF-12	Notification des événements.	Réalisée
EF-13	Gestion des équipes.	Réalisée
EF-14	Personnalisation des parcours.	Réalisée

5.3.2 Limites identifiées et perspectives

Malgré les résultats globalement satisfaisants obtenus au cours du projet, certaines limites ont été identifiées et ouvrent la voie à des améliorations futures.

La première limite concerne les modules d'intelligence artificielle. Les évaluations réalisées à l'aide de RAGAS ont permis d'obtenir des résultats globalement positifs en termes de pertinence, de cohérence et de fidélité contextuelle des réponses générées. Toutefois, certains scénarios ont mis en évidence des cas où le contexte récupéré par le système RAG reste partiel ou insuffisamment précis, ce qui peut influencer la qualité des recommandations fournies par les agents intelligents. Cette limitation souligne la nécessité d'améliorer le mécanisme de recherche et de sélection des documents, notamment à travers des techniques de reranking plus avancées, ainsi qu'une structuration plus riche et évolutive de la mémoire des apprenants.

Par ailleurs, l'évaluation qualitative des agents IA a été réalisée sur un ensemble de scénarios représentatifs mais relativement limité. Bien que ces cas couvrent les principaux usages de la plateforme, une évaluation à plus grande échelle, basée sur des données réelles et un volume plus important d'interactions, permettrait d'obtenir une analyse plus fine et plus fiable des performances du système dans un contexte réel d'utilisation.

Les perspectives d'évolution de la plateforme s'articulent autour de plusieurs axes complémentaires. Sur le plan fonctionnel, l'enrichissement des parcours d'apprentissage par des mécanismes de personnalisation avancée, ainsi que l'amélioration des capacités d'analyse des données pédagogiques, permettraient d'optimiser davantage l'expérience utilisateur. Sur le plan technique, le renforcement des capacités des agents IA, notamment via des modèles plus performants et une meilleure exploitation des données historiques, constitue une piste d'amélioration importante.

Enfin, une perspective essentielle consiste à réaliser des tests de performance et de scalabilité dans un environnement proche de la production. Ces tests permettraient de valider le comportement du système sous charge réelle et de confirmer les résultats observés en phase de développement, notamment en termes de stabilité, de latence et de robustesse globale de la plateforme.

5.4 Conclusion

Dans l'ensemble, les résultats des tests montrent que la plateforme est fonctionnelle, cohérente et globalement performante. Elle répond aux exigences du cahier des charges et démontre la viabilité de l'architecture proposée.

Cependant, ces résultats constituent également un point de départ pour des évolutions futures. Des améliorations peuvent être envisagées en matière de scalabilité, d'optimisation des modèles d'intelligence artificielle et de renforcement des mécanismes de récupération de contexte.

À plus long terme, la plateforme pourrait évoluer vers un système pleinement industrialisé, capable de supporter une utilisation à grande échelle en environnement de production, tout en intégrant des capacités d'adaptation et d'apprentissage continu plus avancées.

Conclusion et perspectives

Ce projet de fin d'études a permis de concevoir et de développer une plateforme web intelligente de formation et de mentorat destinée à la gestion et à l'évolution des compétences des collaborateurs du Groupe 3S. L'objectif principal était de dépasser les limites des plateformes de formation traditionnelles grâce à une approche basée sur l'intelligence artificielle générative et les systèmes multi-agents, afin d'offrir un accompagnement personnalisé et adaptatif.

L'architecture microservices multi-tenant mise en place assure la modularité, la scalabilité et l'intégration efficace des différents modules de la plateforme. Les agents intelligents développés prennent en charge la génération de contenus pédagogiques, le coaching personnalisé, la recommandation de ressources et le suivi des apprenants.

L'intégration des modèles de langage avancés, du mécanisme de Retrieval-Augmented Generation (RAG) agentique et du système de mémoire persistante Hindsight constitue l'un des principaux apports du projet. Ces technologies permettent d'améliorer la personnalisation des interactions et la pertinence des recommandations. Les mécanismes de gamification et de certification numérique contribuent également à renforcer l'engagement des utilisateurs. Les fonctionnalités développées ont été validées à travers des tests fonctionnels, techniques et liés à l'intelligence artificielle.

Parmi les perspectives d'évolution, il serait intéressant d'améliorer davantage les capacités des agents intelligents, d'intégrer des modèles plus performants et d'exploiter l'analyse prédictive afin d'anticiper les besoins de formation. Le déploiement de la plateforme dans un environnement industriel réel permettrait également de valider ses performances à grande échelle et d'évaluer son comportement sous des charges plus importantes.

En définitive, ce projet constitue une première étape vers une nouvelle génération de plateformes de formation intelligentes, où l'intelligence artificielle joue un rôle central dans l'accompagnement des apprenants et le développement des compétences en entreprise.

Bibliographie

Webographie

Plateforme de formation et de mentorat assistée par l'intelligence artificielle

Aya Telmoudi

خلاصة : تم تنفيذ هذا المشروع في إطار مشروع نهاية الدراسة داخل شركة Standard Sharing Software (3S) بهدف الحصول على شهادة المهندس في علوم الإعلامية. كان الهدف الرئيسي هو تصميم وتطوير منصة ويب ذكية للتكوين والتوجيه المهني، تتيح مركزة إدارة مهارات الموظفين داخل المؤسسة. تقوم هذه المنصة بجمع ومعالجة بيانات التعلم، وتقديم توجيه شخصي عبر وكلاء ذكاء اصطناعي، مع دمج آليات التلعيب (نقاط الخبرة، الشارات، لوحات الترتيب)، بالإضافة إلى إنشاء شهادات رقمية مؤمنة. تساهم هذه المنصة في دعم التطور المستمر للمهارات وتوفر متابعة دقيقة للمتعلمين ولمسؤولي التكوين.

Résumé : Ce projet a été réalisé dans le cadre du projet de fin d'études au sein de la société Standard Sharing Software (3S) en vue de l'obtention du diplôme national d'ingénieur en informatique. L'objectif principal était la conception et le développement d'une plateforme web intelligente de formation et de mentorat permettant de centraliser la gestion des compétences des employés. La plateforme collecte et traite les données d'apprentissage, propose un coaching personnalisé via des agents d'intelligence artificielle, intègre des mécanismes de gamification (XP, badges, classements), et génère des certificats numériques sécurisés. Elle favorise une montée en compétences continue et offre un suivi détaillé aux apprenants ainsi qu'aux gestionnaires de formation.

Abstract : This project was carried out as part of the end-of-studies project at Standard Sharing Software (3S) in order to obtain the national degree in computer engineering. The main objective was the design and development of an intelligent web platform for training and mentoring to centralize employee skills management. The platform collects and processes learning data, provides personalized coaching through artificial intelligence agents, integrates gamification mechanisms (XP, badges, leaderboards), and generates secure digital certificates. It promotes continuous skill development and offers detailed tracking for learners as well as training managers.

المفاتيح : منصة تدريب، ذكاء اصطناعي، وكيل ذكي، توجيه، التلعيب، التعلم الإلكتروني، الخدمات المصغرة FastAPI، Next.js، PostgreSQL، pgvector، Hindsight، Docker .

Mots clés : Plateforme de formation, Intelligence artificielle, Agent IA, Mentorat, Gamification, Apprentissage en ligne, Microservices, FastAPI, Next.js, PostgreSQL, pgvector, Hindsight, Docker.

Key-words : Training platform, Artificial intelligence, AI Agent, Mentoring, Gamification, E-learning, Microservices, FastAPI, Next.js, PostgreSQL, pgvector, Hindsight, Docker.