République Tunisienne
Ministère de l'Enseignement Supérieur
Et de la Recherche Scientifique
Université de Sfax
École Nationale d'Ingénieurs de Sfax

Cycle de Formation d'Ingénieurs
dans la Discipline
Génie informatique
ST-EN07/00
Projet de Fin d'Études
N° d'ordre : 2026/DIMA-0

MEMOIRE

Présenté à

L'École Nationale d'Ingénieurs de Sfax
Département de Génie informatique et mathématiques appliquées

En vue de l'obtention

Du Diplôme National d'Ingénieur en *Génie Informatique*

Réalisé par

Aya TELMOUDI

Plateforme de formation et de mentorat assistée par l'intelligence artificielle

Soutenu le 20 juin 2026, devant la commission d'examen :

Mme. Afef MDHAFFAR	**Présidente**
Mme. Mariem LAHAMI	**Rapportrice**
Mme. Sihem LOUKIL	**Encadrante académique**
M. Hazem RAOUAFI	**Encadrant industriel**

Année Universitaire : 2025/2026

Table des matières

1 Contexte général et étude de l'existant **1**

1.1 Introduction . . . 2
1.2 Présentation de la société . . . 2
1.2.1 Présentation générale . . . 2
1.2.2 Domaines d'activité de 3S . . . 2
1.3 Contexte du projet . . . 3
1.3.1 Problématique . . . 3
1.3.2 Objectif . . . 4
1.3.3 Solution proposée . . . 4
1.4 Étude et analyse de l'existant . . . 5
1.4.1 Solutions commercialisées . . . 5
1.4.1.1 Google Skills . . . 5
1.4.1.2 Duolingo . . . 6
1.4.1.3 360Learning . . . 6
1.4.1.4 CYPHER Learning . . . 6
1.4.2 Solutions non commercialisées . . . 7
1.4.2.1 OpenMAIC . . . 7
1.4.2.2 Moodle . . . 7
1.4.3 Synthèse comparative . . . 7
1.4.4 Améliorations et innovations . . . 8
1.5 Spécification des exigences . . . 10
1.5.1 Exigences fonctionnelles . . . 10
1.5.2 Exigences non fonctionnelles . . . 11
1.6 Méthodologie de travail . . . 13
1.6.1 Analyse des approches de développement . . . 13
1.6.1.1 Méthodes agiles traditionnelles . . . 13
1.6.1.2 Inadéquation structurelle avec le développement assisté par l'IA 13
1.6.1.3 Le vibe coding : une réponse insuffisante . . . 14
1.6.2 Approche AI-Driven Development Lifecycle (AI-DLC) . . . 14
1.6.2.1 Présentation . . . 14

1.6.2.2 Principes fondamentaux 15
1.6.2.3 Phases de l'AI-DLC 15
1.6.3 Frameworks d'Implémentation de l'AI-DLC 16
1.6.3.1 GitHub Spec Kit 16
1.6.3.2 BMAD Method 16
1.6.3.3 GSD Framework 16
1.6.3.4 AWS Kiro 17
1.6.4 Étude Comparative des Frameworks 17
1.6.5 Choix de l'environnement de développement 18
1.6.5.1 Démarche adoptée : approche hybride progressive 18
1.6.6 Synthèse 19
1.7 Conclusion 20

2 Fondements IA, conception et architecture de la solution 21
2.1 Introduction 22
2.2 Fondements de l'intelligence artificielle utilisée 22
2.2.1 Les modèles de langage de grande taille (LLMs) 22
2.2.1.1 Définition des LLMs 22
2.2.1.2 Utilisation dans le projet 23
2.2.1.3 Étude du choix du LLM 23
2.2.1.4 Choix retenu 24
2.2.2 Les agents intelligents et les systèmes multi-agents 24
2.2.2.1 Définition des agents intelligents 24
2.2.2.2 Définition des systèmes multi-agents 24
2.2.2.3 Utilisation dans le projet 25
2.2.3 Le Retrieval-Augmented Generation (RAG) 26
2.2.3.1 Définition du RAG 26
2.2.3.2 Workflow général 26
2.2.3.3 Agentic RAG 26
2.2.3.4 Utilisation dans le projet 27
2.2.4 Modèles d'Embeddings 27
2.2.4.1 Définition des embeddings 27
2.2.4.2 Embeddings et recherche sémantique 27
2.2.4.3 Étude du choix du modèle d'embeddings 27
2.2.4.4 Choix retenu 28
2.2.5 Les prompts système des agents IA 28
2.2.5.1 Définition 28
2.2.5.2 Rôle dans les agents IA 28
2.2.5.3 Utilisation dans le projet 29
2.2.6 Les agent skills 29

2.2.6.1 Définition . . . 29
2.2.6.2 Besoin des skills dans le projet . . . 29
2.2.6.3 Skills ajoutés dans la plateforme . . . 30
2.3 Système de mémoire persistante des agents IA . . . 30
2.3.1 Présentation de Hindsight . . . 31
2.3.2 Architecture générale de Hindsight . . . 31
2.3.3 Fonctionnalités fondamentales utilisées . . . 32
2.3.4 Infrastructure et configuration de Hindsight dans le projet . . . 35
2.3.4.1 Position dans l'architecture . . . 35
2.3.4.2 Stockage et persistance . . . 35
2.3.4.3 Configuration des embeddings . . . 36
2.3.4.4 Configuration du LLM . . . 36
2.3.5 Structure des mémoires persistantes dans Hindsight . . . 36
2.4 Architecture de la plateforme . . . 37
2.4.1 Vue d'ensemble de l'architecture . . . 37
2.4.1.1 Organisation générale des couches . . . 37
2.4.1.2 Articulation entre les couches . . . 39
2.4.1.3 Séparation entre logique métier et logique IA . . . 40
2.4.2 Architecture microservices du backend . . . 40
2.4.2.1 API Gateway . . . 40
2.4.2.2 Microservices réels et modules fonctionnels internes . . . 40
2.4.2.3 Communication entre les services . . . 42
2.4.3 Architecture multi-tenant . . . 42
2.4.3.1 Isolation des données au niveau des services . . . 42
2.4.3.2 Gestion des rôles par tenant . . . 42
2.4.4 Modèle de données . . . 44
2.4.4.1 Organisation générale des données . . . 44
2.4.4.2 Stockage hybride des ressources . . . 44
2.4.5 Architecture des agents IA . . . 45
2.4.5.1 Agent de création de cours . . . 45
2.4.5.2 Agent de coaching pédagogique . . . 46
2.4.5.3 Agent de mémoire apprenant . . . 47
2.4.5.4 Agent de recommandation . . . 49
2.4.5.5 Agent de défis personnalisés . . . 50
2.5 Choix technologiques et justification . . . 53
2.5.1 Stack frontend et backend . . . 53
2.5.2 Bases de données, IA et infrastructure . . . 54
2.6 Conclusion . . . 56

Bibliographie **57**

Webographie **60**

Table des figures

2.1 Workflow général d'un système RAG [39] 26
2.2 Exemple de prompt système utilisé par l'Agent de recommandation 29
2.3 Architecture conceptuelle de Hindsight [53] 32
2.4 Fonctionnement de l'opération *Retain* dans Hindsight [54] 33
2.5 Fonctionnement de l'opération *Recall* dans Hindsight [54] 34
2.6 Fonctionnement de l'opération *Reflect* dans Hindsight [54] 35
2.7 Vue d'ensemble de l'architecture en couches de la plateforme 39
2.8 Diagramme de l'architecture microservices du backend 41
2.9 Diagramme de cas d'utilisation UML des rôles dans l'architecture multi-tenant . 43
2.10 Diagramme d'activité UML de l'agent de création de cours 46
2.11 Diagramme d'activité UML de l'agent de coaching pédagogique 47
2.12 Diagramme d'activité UML de l'agent de mémoire apprenant 48
2.13 Diagramme d'activité UML de l'agent de recommandation 50
2.14 Diagramme d'activité UML de l'agent de défis personnalisés 52

Liste des tableaux

1.1 Comparaison des solutions existantes 8
1.2 Exigences fonctionnelles 10
1.3 Exigences non fonctionnelles 12
1.4 Comparaison des frameworks AI-DLC disponibles en 2025–2026 17
1.5 Benchmark des outils de développement assisté par IA 19

2.1 Comparaison des LLMs compatibles avec OpenMAIC et Hindsight 23
2.2 Comparaison des modèles d'embeddings utilisables pour le système RAG 28
2.3 Tableau comparatif des technologies frontend et backend retenues 54
2.4 Tableau comparatif des technologies de données, IA et infrastructure 54

Chapitre 1

Contexte général et étude de l'existant

Contents

1.1 Introduction 2

1.2 Présentation de la société 2

1.2.1 Présentation générale 2

1.2.2 Domaines d'activité de 3S 2

1.3 Contexte du projet 3

1.3.1 Problématique 3

1.3.2 Objectif 4

1.3.3 Solution proposée 4

1.4 Étude et analyse de l'existant 5

1.4.1 Solutions commercialisées 5

1.4.2 Solutions non commercialisées 7

1.4.3 Synthèse comparative 7

1.4.4 Améliorations et innovations 8

1.5 Spécification des exigences 10

1.5.1 Exigences fonctionnelles 10

1.5.2 Exigences non fonctionnelles 11

1.6 Méthodologie de travail 13

1.6.1 Analyse des approches de développement 13

1.6.2 Approche AI-Driven Development Lifecycle (AI-DLC) 14

1.6.3 Frameworks d'Implémentation de l'AI-DLC 16

1.6.4 Étude Comparative des Frameworks 17

1.6.5 Choix de l'environnement de développement 18

1.6.6 Synthèse 19

1.7 Conclusion 20

1.1 Introduction

Ce chapitre a pour objectif de présenter le cadre général du projet de fin d'études. Nous commençons par une présentation de l'entreprise d'accueil ainsi que de ses principaux domaines d'activité. Ensuite, nous étudions les solutions existantes dans le domaine concerné afin d'identifier leurs limites et les améliorations possibles. Enfin, nous présentons les exigences du projet ainsi que la méthodologie de travail adoptée durant sa réalisation.

1.2 Présentation de la société

Cette section est consacrée à la présentation de la société d'accueil au sein de laquelle ce projet a été réalisé. Nous y décrivons son historique, son positionnement dans l'écosystème technologique tunisien ainsi que ses principaux domaines d'intervention.

1.2.1 Présentation générale

Standard Sharing Software, désignée sous l'acronyme **3S** [1], est une entreprise tunisienne fondée en 1988, spécialisée dans l'intégration de solutions technologiques et les services informatiques à forte valeur ajoutée. Forte de plus de 35 ans d'expérience, elle s'est imposée comme un acteur de référence sur le marché tunisien et africain, en accompagnant les organisations publiques et privées dans leurs projets de modernisation numérique.

3S se distingue par une approche globale qui couvre l'ensemble du cycle de vie des projets IT : de l'étude et de l'audit des besoins jusqu'au déploiement et au pilotage des solutions mises en place. Cette capacité à intervenir de bout en bout, combinée à des partenariats avec des éditeurs et constructeurs de renommée mondiale, lui permet de proposer des réponses adaptées aux exigences les plus complexes.

3S est la filiale fondatrice du **Groupe 3S** [2], un groupe technologique tunisien structuré autour de deux pôles complémentaires. Le **pôle IT** regroupe les filiales dédiées aux technologies de l'information : **3S** (intégration IT), **GlobalNet** (accès Internet grand public), **GlobalNet Business** (services cloud et sécurité pour entreprises), **Advancia Training** (formation et certification IT), **Smartup** (édition de progiciels), **Hexabyte** (connectivité et solutions high-tech), **Cyberesa** (solutions e-tourisme) et **Pro2C** (centre de contact multicanal). Le **pôle Cleantech** quant à lui rassemble des entités orientées développement durable, telles que **Africa Solar** (énergies renouvelables), **CandyLed** (éclairage LED), **BioPack** (bioplastiques) et **Océane** (construction navale).

1.2.2 Domaines d'activité de 3S

En tant que pôle IT du groupe, 3S intervient sur l'ensemble de la chaîne de valeur liée à la transformation numérique des entreprises. Ses domaines d'activité s'articulent autour de six

axes principaux :

- **Intégration des infrastructures IT :** 3S accompagne ses clients dans la conception et le déploiement d'environnements informatiques robustes et évolutifs, conformes aux standards internationaux, depuis l'audit initial jusqu'à la mise en production ;
- **Réseaux et connectivité :** l'entreprise propose des solutions d'interconnexion et de télécommunication garantissant des échanges fiables et sécurisés entre les différents composants des systèmes d'information ;
- **Datacenter et continuité de service :** virtualisation, sauvegarde, stockage et haute disponibilité constituent les piliers de l'offre datacenter de 3S, visant à assurer la résilience et la protection des données critiques ;
- **Cloud computing :** la société déploie des architectures cloud privées, hybrides et publiques, ainsi que des services d'hébergement managés, répondant aux besoins croissants des entreprises en matière de flexibilité et d'agilité ;
- **Cybersécurité :** 3S propose une offre complète de sécurité informatique intégrant des pare-feux nouvelle génération, des systèmes SIEM, une protection Anti-DDoS, des solutions de gestion des identités et des accès (IAM), ainsi que des centres opérationnels SOC et NOC dédiés à la surveillance et à la réponse aux incidents ;
- **Communication unifiée et collaboration :** l'entreprise intègre des outils de communication unifiée permettant d'améliorer la coordination et la productivité des équipes, en facilitant les échanges au sein des organisations.

Cette palette de compétences, combinée à l'écosystème du Groupe 3S, permet à 3S de se positionner comme un partenaire technologique global, capable de répondre aux enjeux actuels de la numérisation, de la sécurisation des systèmes d'information et de l'évolution des infrastructures modernes.

1.3 Contexte du projet

Ce projet intitulé *« Plateforme de formation et de mentorat assistée par l'intelligence artificielle »* a été réalisé au sein de la société Standard Sharing Software (3S) dans le cadre du Projet de Fin d'Études en vue de l'obtention du diplôme national d'ingénieur.

1.3.1 Problématique

Dans un environnement professionnel en constante évolution, les entreprises peinent à assurer une montée en compétences efficace de leurs collaborateurs. Les dispositifs de formation classiques montrent aujourd'hui leurs limites : les études indiquent que seulement 10 à 15% des cours en ligne sont effectivement complétés, révélant un problème profond de motivation et d'engagement des apprenants face à des contenus statiques et non personnalisés.

Les observations réalisées au sein de 3S montrent que l'intégration des nouveaux collaborateurs et l'évolution continue des équipes nécessitent un accompagnement régulier afin de leur

permettre de comprendre rapidement les outils, les méthodes de travail et les technologies utilisées dans les projets. Toutefois, cet accompagnement dépend fortement de la disponibilité des encadrants et des membres expérimentés de l'équipe. Cette situation peut entraîner des écarts de progression entre les apprenants et rendre difficile l'évaluation objective de leurs acquis.

À cela s'ajoute l'absence quasi totale de mécanismes de coaching et de mentorat structurés au sein des plateformes existantes. Les collaborateurs se retrouvent souvent sans suivi individualisé ni accompagnement adapté à leur profil et à leur progression. Les outils disponibles sur le marché restent cloisonnés, rigides et peu intelligents : ils ne permettent pas d'identifier les lacunes en temps réel, de recommander des contenus pertinents ni de mettre en relation efficacement un apprenant avec un mentor qualifié.

Dans ce contexte, le projet répond à un besoin réel observé au sein de l'entreprise. Il propose une solution adaptée permettant de structurer les parcours de formation, de renforcer l'accompagnement des collaborateurs et de mieux suivre leur progression tout au long de leur montée en compétences.

1.3.2 Objectif

Ce projet vise à concevoir et développer une plateforme web intelligente qui centralise la gestion des formations, le suivi des compétences et le mentorat au sein de l'entreprise. L'objectif est de proposer à chaque apprenant un parcours personnalisé, soutenu par des recommandations intelligentes et un coaching adapté à son profil et à sa progression.

La plateforme intègre également des mécanismes de gamification afin de renforcer la motivation des utilisateurs et d'améliorer le taux de complétion des formations. Elle doit aussi permettre à plusieurs entités du Groupe 3S d'utiliser la solution de manière indépendante, tout en partageant une infrastructure commune. Cette organisation vise à garantir une gestion séparée des utilisateurs, des données et des configurations propres à chaque entité.

1.3.3 Solution proposée

Pour répondre à ces problématiques, nous proposons une plateforme web intelligente intégrant la gestion des utilisateurs, des formations, des compétences et des parcours d'apprentissage, ainsi qu'un module de mentorat structurant la relation entre mentors et apprenants.

L'intelligence artificielle est au cœur de la solution : des modules intelligents exploitant le contexte de l'utilisateur assurent des recommandations personnalisées, une assistance continue et un coaching adapté à chaque utilisateur. Dans ce cadre, la recommandation IA désigne la proposition de contenus adaptés au profil de l'apprenant, l'assistance IA correspond à l'aide fournie à l'utilisateur lors de son parcours, tandis que le coaching IA renvoie à un accompagnement personnalisé basé sur sa progression et ses besoins. Des fonctionnalités de gamification complètent cette expérience en encourageant l'engagement et la progression des apprenants tout au long de leur parcours.

La solution est conçue pour être utilisée par plusieurs filiales du Groupe 3S à partir d'une infrastructure commune. Pour cela, elle repose sur une organisation multi-tenant, c'est-à-dire un modèle dans lequel plusieurs entités utilisent la même application tout en disposant chacune d'un espace indépendant. Chaque filiale peut ainsi gérer ses propres utilisateurs, ses formations, ses parcours et ses paramètres, sans interférence avec les autres entités.

Ce choix est particulièrement adapté au Groupe 3S, car celui-ci regroupe plusieurs filiales aux activités et besoins de formation différents, tout en appartenant à une même structure organisationnelle. Une telle approche permet donc de mutualiser l'infrastructure technique, de faciliter l'administration globale de la solution et de préserver l'autonomie de chaque filiale dans la gestion de ses données et de ses parcours de formation.

1.4 Étude et analyse de l'existant

Avant d'entamer la conception de notre solution, nous avons mené une étude approfondie des plateformes existantes dans le domaine de la formation et du développement professionnel. Cette analyse se concentre sur les plateformes qui intègrent des approches modernes telles que le coaching intelligent piloté par l'IA, la gamification, la génération automatique de cours et l'utilisation de fonctionnalités d'assistance conversationnelle. Elle s'intéresse également à des critères pratiques tels que la confidentialité des données et le modèle tarifaire de chaque solution. L'objectif est d'évaluer dans quelle mesure ces plateformes parviennent à améliorer la motivation des apprenants, à renforcer leur engagement et à leur offrir un accompagnement personnalisé et efficace. Cette étude s'articule autour de deux catégories : les solutions commerciales disponibles sur le marché, et les solutions non commerciales issues de la communauté open source ou de la recherche académique.

1.4.1 Solutions commercialisées

Plusieurs plateformes commerciales ont intégré des fonctionnalités avancées d'intelligence artificielle pour améliorer l'expérience d'apprentissage en entreprise. Nous présentons ci-dessous les solutions les plus représentatives du marché actuel, en nous concentrant sur leurs approches pédagogiques, leurs fonctionnalités clés et leur positionnement.

1.4.1.1 Google Skills

Lancée en octobre 2025, Google Skills [3] est une plateforme d'apprentissage unifiée regroupant près de 3 000 cours, labs et certifications issus de l'écosystème Google (Google Cloud, DeepMind, Grow with Google et Google for Education). Elle cible des profils allant du débutant au développeur confirmé, avec un accent fort sur l'IA générative et les technologies cloud. La plateforme mise sur la gamification pour stimuler l'engagement des apprenants à travers des ligues de points, des badges de compétences, des streaks d'apprentissage et des tableaux

de classement par équipe. Pour les entreprises clientes de Google Cloud, un accès organisationnel gratuit est disponible via Google Skills for Orgs, permettant d'assigner des parcours aux équipes et de suivre leur progression via des tableaux de bord analytiques.

1.4.1.2 Duolingo

Duolingo [4] est une plateforme d'apprentissage des langues largement reconnue pour son approche basée sur la gamification. Elle intègre des mécanismes tels que les points d'expérience, les séries de connexions quotidiennes (streaks) et les classements, afin de renforcer l'engagement et la régularité des apprenants. Son modèle pédagogique repose sur des exercices courts et interactifs, favorisant un apprentissage progressif et motivant.

Ces dernières années, la plateforme a renforcé son orientation vers l'intelligence artificielle en automatisant une grande partie de la création de ses contenus pédagogiques, avec le déploiement de nombreux cours générés par IA. Par ailleurs, son offre premium Duolingo Max intègre des fonctionnalités avancées basées sur des modèles de langage, notamment des agents conversationnels permettant de simuler des dialogues réalistes, ainsi qu'un moteur adaptatif qui ajuste dynamiquement la difficulté des exercices en fonction du niveau et des performances de l'apprenant.

1.4.1.3 360Learning

360Learning [5] est une plateforme d'apprentissage collaborative destinée aux entreprises, basée sur un modèle où les employés deviennent eux-mêmes créateurs de contenus pédagogiques. Elle favorise ainsi une approche d'apprentissage pair-à-pair et une production de formations directement issues des experts métiers.

La plateforme se distingue par son fort niveau d'engagement des apprenants, lié à son intégration dans le travail quotidien et à son approche collaborative. Elle intègre également des fonctionnalités d'intelligence artificielle, notamment des outils de recommandation de contenus et de création assistée permettant de transformer rapidement des documents (PDF, PowerPoint, Word) en modules de formation structurés.

1.4.1.4 CYPHER Learning

CYPHER Learning [6] est une plateforme LMS et LXP alimentée par l'IA, positionnée comme solution tout-en-un pour la création, la gestion et la personnalisation des parcours d'apprentissage. Son outil phare, CYPHER Copilot, permet de générer automatiquement des cours complets, des quiz et des évaluations à partir de ressources fournies par l'organisation, avec un mécanisme de vérification de l'exactitude des contenus générés (AI Crosscheck). La plateforme propose également une gamification pilotée par l'IA, adaptant les points, badges et niveaux au profil de chaque apprenant, ainsi que des parcours adaptatifs qui s'ajustent dynamiquement selon les résultats obtenus.

1.4.2 Solutions non commercialisées

Des initiatives issues de la communauté open source et de la recherche académique proposent des alternatives libres, transparentes et hautement personnalisables aux plateformes propriétaires. Ces solutions présentent un intérêt particulier pour les organisations qui souhaitent conserver la maîtrise de leurs données ou expérimenter des approches pédagogiques innovantes.

1.4.2.1 OpenMAIC

OpenMAIC [7] (Open Multi-Agent Interactive Classroom) est une plateforme open source développée par l'équipe de recherche MAIC de l'Université de Tsinghua et publiée en 2025. Elle propose une approche pédagogique basée sur des systèmes multi-agents, allant au-delà des chatbots éducatifs classiques.

À partir d'un document ou d'un sujet décrit en langage naturel, la plateforme génère automatiquement une expérience d'apprentissage interactive complète incluant des supports de cours, des quiz, des simulations et des activités collaboratives. Cette interaction est assurée par plusieurs agents spécialisés (enseignant, assistant et apprenants simulés) reproduisant une dynamique de classe réaliste.

Sur le plan technique, OpenMAIC repose sur une architecture d'orchestration d'agents et est compatible avec plusieurs fournisseurs de modèles de langage. En tant que solution open source, elle peut être déployée sur une infrastructure locale, offrant ainsi un contrôle total sur les données et leur confidentialité.

1.4.2.2 Moodle

Moodle [8] est la plateforme LMS open source la plus utilisée dans le monde, déployée dans plus de 240 pays par des universités, des gouvernements et des entreprises. Elle offre un ensemble complet de fonctionnalités couvrant la création de cours, la gestion des évaluations, les forums de discussion, le suivi de progression et le support SCORM. Sa bibliothèque de plus de 1 800 plugins permet d'étendre ses capacités avec des modules de gamification, d'apprentissage adaptatif et d'intégrations tierces. La version 4.5, publiée en octobre 2024, introduit un sous-système d'intelligence artificielle ouvrant la voie aux fonctionnalités de tutorat intelligent et de recommandation de contenus. Entièrement auto-hébergeable, Moodle offre un contrôle total sur les données et représente un choix privilégié pour les organisations soumises à des contraintes réglementaires strictes.

1.4.3 Synthèse comparative

L'analyse des solutions présentées met en évidence des différences importantes selon les critères qui sont au cœur de notre projet. Les plateformes commerciales offrent des fonctionnalités

avancées mais à des coûts élevés et avec un contrôle limité sur les données, tandis que les solutions open source garantissent la souveraineté des données mais manquent de fonctionnalités intelligentes intégrées. En se basant sur les solutions étudiées, aucune plateforme ne combine l'ensemble de ces fonctionnalités dans un environnement unifié destiné au contexte du Groupe 3S. Le tableau 1.1 présente une synthèse comparative des solutions étudiées selon les critères retenus pour notre projet.

TABLE 1.1 – Comparaison des solutions existantes

Critère	**Google Skills**	**Duolingo**	**360Learning**	**CYPHER Learning**	**OpenMAIC**	**Moodle**
Coaching IA	Non	Oui (GPT-4)	Partiel	Non	Oui (multi-agents + LLM externe requis)	Non
Gamification	Oui	Oui	Oui	Oui (pilotée par IA)	Non	Via plugin
Génération auto de cours	Non	Oui (IA générative)	Oui (à partir de PDF/DOCX)	Oui (CYPHER Copilot)	Oui (multi-agents)	Non
Assistance conversationnelle	Non	Oui (Lily)	Non	Non	Oui (AI Teacher + assistants + classmates orchestrés)	Non
Mentorat structuré	Non	Non	Partiel	Non	Non	Non
Suivi des compétences	Partiel	Non	Oui	Oui	Non	Partiel
Confidentialité des données	Faible (serveurs Google)	Faible (serveurs Duolingo)	Bonne (RGPD, AI Act)	Moyenne (cloud éditeur)	Totale (auto-hébergeable)	Totale (auto-hébergeable)
Architecture multi-tenant	Non	Non	Non	Oui (plan Enterprise)	Non	Partiel
Open source	Non	Non	Non	Non	Oui (AGPL-3.0, self-hosted, extensible, BYO LLM requis)	Oui (GPL)
Coût	**Gratuit (Starter) ; Pro à 29$/mois ; Career Certificates à 49$/mois [9]**	**Gratuit ; Super Duolingo à partir de 12,99$/mois ; Max avec fonctionnalités IA avancées [10]**	**8$/utilisateur/mois (Team) ; Business et Enterprise sur devis [11]**	**Sur devis (à partir d'environ 10 000$/an selon les besoins de l'organisation) [12]**	**Gratuit (open source) ; nécessite API LLM externe et infrastructure d'hébergement [7]**	**Gratuit (open source) ; coûts liés à l'hébergement et au support selon le déploiement [8]**

1.4.4 Améliorations et innovations

L'analyse des solutions existantes montre clairement qu'aucune d'entre elles ne répond de manière complète aux besoins d'une entreprise souhaitant centraliser la formation, le suivi des compétences et le mentorat dans un seul outil intelligent. Cette section présente les principaux axes d'amélioration qui guident la conception de notre plateforme.

Mentorat structuré et coaching intelligent. Aucune des plateformes étudiées ne propose un accompagnement humain et intelligent combiné dans un même outil. Les collaborateurs en phase d'intégration se retrouvent souvent sans suivi structuré, tandis que les rares outils de

recommandation existants manquent de mémoire contextuelle et ne s'adaptent pas au profil évolutif de l'apprenant. Notre solution place le coaching IA au centre de l'expérience d'apprentissage : un module intelligent suit en continu le parcours de chaque utilisateur, identifie ses lacunes et lui propose un accompagnement personnalisé à tout moment. Le mentorat vient renforcer cette dynamique en s'appuyant sur les données du coaching pour orienter les échanges entre mentor et apprenant, assurer un suivi cohérent de la progression et adapter les recommandations aux besoins réels de chaque collaborateur.

Génération de cours adaptée au contexte interne. Les outils de création automatique de cours existants produisent des contenus à partir de documents génériques. Notre solution va plus loin en permettant de générer des parcours d'apprentissage directement à partir des ressources internes de l'entreprise, en tenant compte des compétences cibles, du niveau de l'apprenant et des besoins métiers spécifiques de chaque filiale du Groupe 3S.

Gamification au service de la motivation. Notre plateforme intègre des mécanismes de gamification — points, badges, niveaux et tableaux de progression — directement liés aux compétences acquises, afin de rendre l'apprentissage plus engageant et d'encourager les apprenants à aller au bout de leur parcours.

Architecture multi-tenant adaptée au Groupe 3S. Parmi les solutions étudiées, seul CYPHER Learning propose une architecture multi-tenant, et uniquement dans son plan Enterprise à coût élevé. Notre plateforme est conçue nativement avec cette architecture, permettant à chaque filiale du Groupe 3S de disposer de son propre espace cloisonné, avec des configurations, des contenus et des utilisateurs indépendants, le tout sur une infrastructure partagée et mutualisée.

Confidentialité des données et contrôle des contenus. Dans le contexte d'une entreprise, les contenus de formation peuvent contenir des informations internes liées aux méthodes de travail, aux outils utilisés, aux projets ou aux processus propres à l'organisation. Il est donc essentiel que ces contenus restent accessibles uniquement aux utilisateurs autorisés.

Notre solution prend en compte cet aspect en assurant une séparation des espaces entre les différentes entités de l'entreprise. Chaque entité dispose de ses propres formations, parcours, utilisateurs et paramètres, ce qui permet de limiter l'accès aux contenus internes selon l'appartenance et le rôle de chaque utilisateur. Ainsi, les cours créés au sein d'une entité restent visibles uniquement par les collaborateurs concernés.

Cette organisation permet de renforcer la confidentialité des données, de mieux contrôler la diffusion des contenus pédagogiques et d'éviter qu'une information interne soit partagée en dehors du périmètre prévu.

Vision unifiée du développement professionnel. Les outils du marché traitent séparément la formation, le suivi des compétences et le mentorat, obligeant les responsables à jongler entre plusieurs plateformes sans vision globale. Notre solution centralise ces trois dimensions dans un seul environnement cohérent, offrant aux managers un tableau de bord complet pour suivre l'évolution professionnelle de chaque collaborateur.

1.5 Spécification des exigences

Cette section présente l'ensemble des exigences identifiées pour la plateforme *Skill Forge*. Ces exigences ont été définies à partir de l'analyse des besoins du Groupe 3S et des limites des solutions existantes étudiées dans la section précédente. Elles se divisent en deux catégories : les exigences fonctionnelles, qui décrivent ce que le système doit faire, et les exigences non fonctionnelles, qui définissent comment il doit le faire.

1.5.1 Exigences fonctionnelles

Les exigences fonctionnelles décrivent les fonctionnalités que le système doit offrir pour répondre aux besoins des utilisateurs. Le tableau 1.2 présente l'ensemble des exigences fonctionnelles identifiées.

TABLE 1.2 – Exigences fonctionnelles

ID	**Catégorie**	**Description**
EF-01	Authentification	Le système doit permettre l'authentification sécurisée des utilisateurs.
EF-02	Gestion des rôles	Le système doit gérer plusieurs rôles : super administrateur, administrateur, manager, expert pédagogique, responsable d'équipe et membre d'équipe.
EF-03	Gestion des profils	Le système doit permettre la création et la modification des profils utilisateurs.
EF-04	Multi-tenant	Le système doit permettre la gestion de plusieurs entreprises (tenants) de façon cloisonnée.
EF-05	Gestion des formations	Le système doit permettre la création, la modification, la suppression et la consultation des formations.
EF-06	Compétences	Le système doit permettre la gestion des compétences associées aux formations et aux utilisateurs.
EF-07	Parcours d'apprentissage	Le système doit permettre la création de parcours d'apprentissage personnalisés et l'affectation de compétences cibles.
EF-08	Suivi de progression	Le système doit permettre le suivi de l'avancement de chaque apprenant dans son parcours.

ID	Catégorie	Description
EF-09	Recommandation IA	Le système doit recommander des contenus de formation adaptés au profil et aux besoins de chaque utilisateur.
EF-10	Coaching IA	Le système doit intégrer un module d'assistance intelligent capable d'accompagner l'utilisateur tout au long de son apprentissage.
EF-11	Génération de cours	Le système doit permettre la génération automatique de cours à partir de documents ou de sujets fournis.
EF-12	Évaluations	Le système doit permettre la création et la gestion de quiz, tests et évaluations de validation.
EF-13	Gamification	Le système doit permettre l'attribution de points, badges et récompenses selon la progression des apprenants.
EF-14	Mentorat	Le système doit permettre l'affectation de mentors aux apprenants et la gestion de leurs interactions.
EF-15	Tableau de bord	Le système doit fournir des tableaux de bord de suivi de la progression, des compétences et de l'engagement.
EF-16	Recherche	Le système doit permettre la recherche et la consultation des formations disponibles.
EF-17	Gestion des contenus	Le système doit permettre la gestion des ressources pédagogiques (vidéos, documents, liens).
EF-18	Traçabilité	Le système doit enregistrer les activités des utilisateurs sur la plateforme.

1.5.2 Exigences non fonctionnelles

Les exigences non fonctionnelles définissent les critères de qualité que le système doit respecter, indépendamment des fonctionnalités qu'il offre. Conformément à la norme ISO/IEC 25010 [13], ces exigences couvrent des dimensions telles que la sécurité, la performance, la maintenabilité et l'ergonomie. Le tableau 1.3 présente l'ensemble des exigences non fonctionnelles retenues.

TABLE 1.3 – Exigences non fonctionnelles

ID	**Catégorie**	**Description**
ENF-01	Sécurité	La plateforme doit protéger les données des utilisateurs et garantir un contrôle d'accès strict selon les rôles.
ENF-02	Confidentialité	La plateforme doit garantir que les contenus de formation, les parcours pédagogiques et les données de progression restent accessibles uniquement dans le périmètre de l'entité concernée.
ENF-03	Performance	La plateforme doit assurer un temps de réponse inférieur à 2 secondes pour 95% des requêtes courantes, hors traitements complexes liés à la génération de contenus et aux recommandations intelligentes.
ENF-04	Disponibilité	La plateforme doit assurer une continuité de service fiable pour l'ensemble des utilisateurs.
ENF-05	Évolutivité	La plateforme doit être conçue pour permettre l'ajout de nouvelles fonctionnalités sans remettre en cause l'architecture existante.
ENF-06	Modularité	La plateforme doit reposer sur une architecture modulaire facilitant la maintenance et l'intégration de nouveaux services.
ENF-07	Maintenabilité	Le code doit être clair, documenté et organisé de façon à faciliter les interventions futures.
ENF-08	Extensibilité	La plateforme doit être conçue pour s'adapter à de nouveaux besoins dans un contexte multi-tenant en évolution.
ENF-09	Ergonomie	La plateforme doit offrir une interface simple, claire et intuitive, accessible à des utilisateurs de profils variés.
ENF-10	Accessibilité	La plateforme doit être accessible depuis différents types d'écrans et navigateurs modernes.
ENF-11	Intégrité des données	La plateforme doit garantir la cohérence et l'intégrité des données à tout moment.
ENF-12	Journalisation	La plateforme doit permettre le suivi des erreurs et la journalisation des événements système.

ID	Catégorie	Description
ENF-13	Compatibilité IA	La plateforme doit être compatible avec l'intégration de modèles de langage et de modules intelligents configurables.
ENF-14	Déployabilité	La plateforme doit faciliter son déploiement et la mise à jour de ses composants de manière indépendante.

1.6 Méthodologie de travail

La réalisation d'une plateforme intelligente intégrant des fonctionnalités d'intelligence artificielle, de mentorat et de gestion des compétences nécessite une démarche de développement adaptée à la complexité du projet. Ce chapitre présente la méthodologie adoptée pour conduire les différentes phases de réalisation, depuis la définition des besoins jusqu'à l'implémentation de la solution. Après une analyse des approches traditionnelles de gestion de projet logiciel, nous présentons le cadre méthodologique retenu ainsi que les outils utilisés pour assister le développement.

1.6.1 Analyse des approches de développement

1.6.1.1 Méthodes agiles traditionnelles

Depuis le début des années 2000, les méthodes agiles — Scrum, Kanban, Extreme Programming (XP) — ont constitué le socle dominant du développement logiciel. Fondées sur des itérations courtes (sprints de deux à quatre semaines), des équipes pluridisciplinaires et une livraison continue de valeur, ces méthodes ont représenté une rupture salutaire avec les modèles séquentiels de type *waterfall*.

Cependant, ces méthodes ont été conçues pour un contexte précis : celui d'une équipe humaine complète — développeurs, product owner, testeurs, UX designers — collaborant selon un rythme cadencé par des cérémonies régulières (daily standups, sprint reviews, rétrospectives). Or, l'émergence de l'IA générative remet fondamentalement en question ce modèle.

1.6.1.2 Inadéquation structurelle avec le développement assisté par l'IA

Comme l'a souligné une étude publiée dans le *Journal du Net* en mars 2026, l'arrivée de l'IA agentique dans le cycle de développement logiciel (SDLC) rend les méthodes agiles « progressivement inadaptées » [14]. Plusieurs raisons structurelles expliquent cette inadéquation :

— **Modèle d'équipe obsolète.** Scrum repose sur une squad de plusieurs développeurs, un product owner, des testeurs et des UX designers. Avec l'IA, un développeur augmenté

peut orchestrer des agents capables de jouer chacun de ces rôles. La taille des équipes se contracte, rendant le modèle organisationnel agile inadapté.

— **Sprints trop longs.** Le cycle en deux à quatre semaines introduit une latence incompatible avec la vitesse de génération du code par les agents IA. Anupam Mishra et Raja, architects chez AWS, ont démontré lors d'AWS re :Invent 2025 que « les sprints ne devraient plus durer deux semaines mais quelques heures » [15].

— **Absence d'implication de l'IA dans le cycle.** Ni Scrum ni Kanban ne définissent de rôle, de rituel ou d'artefact spécifiquement conçu pour l'orchestration d'agents IA. L'IA y est traitée au mieux comme un outil auxiliaire de productivité, jamais comme un collaborateur à part entière du processus de développement.

— **Gaspillage lié aux dépendances humaines.** La grande majorité du temps dans un SDLC classique n'est pas consacrée à l'écriture de code mais à des réunions d'alignement, des attentes entre équipes et des escalades. Les agents IA éliminent naturellement ces frictions lorsqu'ils sont orchestrés dans un cadre adapté.

1.6.1.3 Le vibe coding : une réponse insuffisante

Face à ces limites, une première génération de développeurs a adopté le *vibe coding*, concept popularisé par Andrej Karpathy en 2025 [16] : laisser l'IA générer le code par enchaînement de prompts conversationnels sans supervision structurée. Si cette approche permet un prototypage rapide, elle s'avère rapidement insuffisante pour des applications de production, notamment en raison de l'absence d'architecture cohérente, de la fragilité de la sécurité, et de la dégradation progressive du contexte de l'agent. En 2026, l'industrie a largement convergé vers des méthodologies plus structurées, capables de tirer parti de la puissance de l'IA sans en subir les dérives.

1.6.2 Approche AI-Driven Development Lifecycle (AI-DLC)

1.6.2.1 Présentation

L'**AI-Driven Development Lifecycle (AI-DLC)** est une méthodologie de développement logiciel introduite par AWS en juillet 2025 [17] et formalisée lors d'AWS re :Invent 2025 [15]. Elle est définie comme une approche qui « assigne stratégiquement les tâches routinières à l'IA tout en maintenant la supervision humaine pour les décisions critiques, couvrant l'ensemble du cycle de vie du développement logiciel » [17]. Son architecture repose sur un cycle collaboratif obligatoire à chaque étape : l'IA génère un plan, les parties prenantes le révisent et le valident avant toute exécution [18].

Contrairement aux approches agiles qui *intègrent* l'IA en périphérie de processus conçus pour les humains, l'AI-DLC *réimagine* le cycle de développement en partant du principe que les agents IA sont des participants à part entière du processus.

1.6.2.2 Principes fondamentaux

L'AI-DLC repose sur cinq principes directeurs :

1. **Planification avant exécution.** Avant toute génération de code, l'agent IA produit un plan explicite que le développeur valide. Ce cycle *plan* → *validation humaine* → *exécution* → *vérification* garantit l'alignement entre l'intention humaine et la production de l'agent.
2. **Spécification comme source de vérité.** La spécification — décrivant ce que le système doit garantir, ses contraintes et ses critères d'acceptation — devient l'artefact central du projet. Tout le code, les tests et la documentation en découlent.
3. **Décomposition atomique des tâches.** Les problèmes ambigus ou larges sont systématiquement décomposés en unités de travail étroites et non ambiguës avant d'être confiés à un agent, évitant ainsi la dérive incontrôlée.
4. **Gestion rigoureuse du contexte.** Le contexte des agents est traité comme une ressource précieuse : on l'enrichit avec les artefacts pertinents et on le purge des informations obsolètes, afin de maintenir la qualité de la génération.
5. **Vérification humaine à chaque étape.** Le développeur conserve la propriété intellectuelle et la responsabilité du code. L'IA agit comme un collaborateur expert sous supervision, non comme un système autonome.

1.6.2.3 Phases de l'AI-DLC

Le cycle AI-DLC est structuré en trois phases principales, elles-mêmes découpées en étapes adaptatives (neuf au total pour un nouveau projet from scratch) :

Phase 1 — Inception. Comprend la définition de l'intention, la clarification des exigences (session de *mob elaboration* réunissant toutes les parties prenantes), la création des user stories et l'analyse de l'architecture. L'agent IA génère les artefacts, le développeur les valide en temps réel.

Phase 2 — Construction. L'agent analyse le contexte existant (reverse engineering du code brownfield si nécessaire), propose un plan d'implémentation détaillé, génère le code par unités atomiques, et les tests unitaires et d'intégration accompagnent chaque livraison.

Phase 3 — Opération. Couvre le déploiement, la validation en environnement de staging, la surveillance et l'intégration CI/CD. L'IA assiste également la correction des régressions et la réduction de la dette technique.

Le caractère adaptatif de ce cadre est essentiel : un simple correctif de bug ne traverse que deux ou trois étapes ; une nouvelle fonctionnalité complexe en traverse davantage. L'agent lui-même propose le chemin le plus approprié que le développeur peut ajuster.

1.6.3 Frameworks d'Implémentation de l'AI-DLC

L'adoption croissante de l'AI-DLC a donné naissance à plusieurs frameworks concrets, chacun proposant une implémentation particulière des principes décrits ci-dessus. Nous présentons ici les quatre principaux frameworks disponibles en 2025–2026.

1.6.3.1 GitHub Spec Kit

Publié fin 2025 par GitHub en open source, le **GitHub Spec Kit** est une boîte à outils officielle pour le Spec-Driven Development (SDD) [19]. Il structure le cycle de développement en quatre phases séquentielles :

$$\texttt{Spec} \rightarrow \texttt{Plan} \rightarrow \texttt{Tasks} \rightarrow \texttt{Implement}$$

Chaque phase produit un artefact Markdown versionné qui alimente la phase suivante, fournissant à l'agent IA un contexte structuré plutôt que des prompts ad hoc. Spec Kit supporte plus de trente intégrations d'agents (Claude Code, Codex CLI, Gemini CLI, OpenCode, Cursor, etc.) et s'installe sans lock-in dans l'environnement existant. Il constitue une couche légère et pragmatique, idéale pour initier un projet selon les principes SDD.

1.6.3.2 BMAD Method

La **BMAD Method** (*Breakthrough Method for Agile AI-Driven Development*) est un framework agentique open source qui simule une équipe Agile complète via douze agents IA spécialisés [20]. Ces agents incarnent les rôles de l'Analyste, du Product Manager, de l'Architecte, du Scrum Master, du Développeur, de l'UX Designer et du QA.

Le cycle BMAD est divisé en deux phases : une phase de *Discovery & Planning* (génération du brief, du PRD et de l'architecture par des agents dédiés) suivie d'une phase d'implémentation où les agents collaborent pour produire le code et les tests. La version 6 du framework introduit un mécanisme d'adaptation automatique de la profondeur de planification selon la complexité du projet.

1.6.3.3 GSD Framework

Le **GSD Framework** (*Get Shit Done*) est un système léger de meta-prompting, d'ingénierie de contexte et de développement orienté spécification, conçu spécifiquement pour Claude Code et Codex CLI [21]. Il a dépassé 59 600 étoiles sur GitHub en mai 2026.

Son innovation principale réside dans la résolution du problème de *context rot* (dégradation du contexte) : GSD fragmente le projet en plans atomiques (2 à 3 tâches maximum par plan), chaque plan étant exécuté dans une fenêtre de contexte fraîche par un sous-agent dédié. Le processus suit le cycle suivant :

$$\texttt{Interview} \rightarrow \texttt{Roadmap} \rightarrow \texttt{Plans atomiques} \rightarrow \texttt{Exécution} \rightarrow \texttt{Vérification}$$

Les plans sont stockés sous forme de fichiers `PLAN.md` qui constituent directement les instructions exécutables des sous-agents, garantissant la traçabilité entre les exigences, les phases, les plans et les commits Git.

1.6.3.4 AWS Kiro

Kiro est un IDE agentique lancé par AWS en 2025, construit sur Code OSS, qui implémente nativement le Spec-Driven Development [22]. Son workflow guide le développeur à travers trois phases — Exigences, Design et Tâches — avant toute génération de code. Il utilise Claude Sonnet 4.5 et d'autres modèles frontier en coulisses. Kiro propose également des *steering files* persistants qui maintiennent en permanence le contexte du projet (stack technique, conventions, objectifs produit).

1.6.4 Étude Comparative des Frameworks

TABLE 1.4 – Comparaison des frameworks AI-DLC disponibles en 2025–2026

Critère	**GitHub Spec Kit**	**BMAD Method**	**GSD Framework**	**AWS Kiro**
Type	Toolkit SDD léger	Framework multi-agents	Méta-prompting agentique	IDE SDD intégré
Gestion du contexte	Artefacts Markdown versionné	Agents à contexte restreint	Sous-agents à contexte frais	Steering files persistants
Agents spécialisés	Non	Oui (12 agents)	Oui (orchestrateur + sous-agents)	Partiel (hooks automatiques)
Compatibilité	30+ intégrations	Claude, Cursor, Copilot	Claude Code, Codex CLI, OpenCode	VS Code (Code OSS)
Courbe d'apprentissage	Faible	Élevée	Moyenne	Faible à moyenne
Vérification intégrée	Checklists qualité	QA agent	Verify step dédié	Hooks automatiques
Open source	Oui	Oui	Oui	Non (propriétaire AWS)
Idéal pour	Initiation SDD, projets simples	Équipes entreprise, specs complexes	Projets multi-agents, solo dev	Projets AWS-centric

L'analyse de ce tableau met en évidence plusieurs observations clés :

— Le **GitHub Spec Kit** constitue une excellente porte d'entrée dans le Spec-Driven Development mais ne résout pas nativement le problème du context rot pour des projets de grande envergure.

— La **BMAD Method** offre la structure la plus proche d'une équipe Agile traditionnelle, mais sa complexité (12 agents, nombreux artefacts) peut être un obstacle pour un projet porté par un développeur unique.

— **GSD** se distingue par sa gestion avancée du contexte, sa compatibilité native avec Codex CLI et OpenCode, et son architecture de sous-agents qui correspond précisément aux besoins d'un projet multi-agents développé en solo.

— **AWS Kiro** offre une expérience intégrée de qualité mais reste lié à l'écosystème AWS, ce qui introduit un lock-in incompatible avec les contraintes du projet.

1.6.5 Choix de l'environnement de développement

À l'issue de cette analyse comparative, le **GSD Framework** a été retenu comme cadre principal de développement, car il répond aux besoins du projet en matière de structuration des tâches, de gestion du contexte et de traçabilité du travail réalisé. Ce choix est également adapté à un développement assisté par l'IA, dans lequel les fonctionnalités sont découpées en plans atomiques puis mises en œuvre progressivement avec l'appui d'un outil de développement assisté et de skills personnalisées.

1.6.5.1 Démarche adoptée : approche hybride progressive

La méthodologie appliquée dans ce projet a évolué en trois phases successives, reflétant la montée en maturité avec les principes de l'AI-DLC et les outils d'assistance au développement.

Phase 1 : Découverte et planification avec GSD La première phase a consisté à utiliser le **framework GSD** pour structurer l'ensemble de la démarche de découverte du projet. GSD a été mobilisé pour deux objectifs complémentaires :

— **Définition des spécifications du projet :** formalisation des exigences fonctionnelles et non fonctionnelles de la plateforme, identification des cas d'usage prioritaires et définition des contraintes techniques et métier.

— **Construction du plan d'implémentation :** décomposition du périmètre en modules cohérents (base de données, backend, agents IA, interface utilisateur), puis en plans atomiques de deux à trois tâches, conformément aux principes de GSD. Chaque plan a été matérialisé sous forme de fichier `PLAN.md` constituant directement les instructions exécutables pour les sous-agents.

Cette phase a produit l'ensemble des artefacts de planification qui ont servi de source de vérité tout au long du développement : spécifications, roadmap et plans atomiques versionnés

dans le dépôt Git.

Phase 2 : Sélection de l'outil de construction par benchmark empirique Avant d'engager la phase de construction, une évaluation comparative des principaux outils d'assistance au développement disponibles en 2025–2026 a été conduite. Cinq outils ont été mis en compétition sur des critères objectifs et mesurables :

TABLE 1.5 – Benchmark des outils de développement assisté par IA

Outil	**Qualité du code**	**Coût**	**Performance**	**Gestion du contexte**
OpenCode	Moyenne	Gratuit	Lente	Basique
Cline	Bonne	Payant	Correcte	Partielle
Antigravity	Correcte	Gratuit	Correcte	Limitée
GitHub Copilot	Bonne	Payant	Bonne	Faible
Codex CLI	**Très bonne**	**Accessible**	**Bonne**	**AGENTS.md natif**

À l'issue de ce benchmark, **Codex CLI** a été retenu comme outil principal de construction pour quatre raisons déterminantes : la qualité supérieure du code généré sur des tâches complexes, un modèle de coût accessible, une performance stable même sur des sessions longues, et la prise en charge native du fichier `AGENTS.md` qui permet une gestion structurée du contexte projet sans réinitialisation manuelle.

Phase 3 : Construction avec Codex CLI et skills personnalisées La phase de construction a été réalisée avec **Codex CLI**, utilisé comme outil principal d'assistance au développement. Afin d'améliorer son efficacité et de mieux l'adapter aux besoins du projet, son utilisation a été renforcée par des *skills* personnalisées dédiées à des tâches spécifiques.

Ces skills ont permis d'orienter l'assistance fournie par Codex selon la nature des tâches à réaliser, notamment la génération de code, l'organisation des modules, la correction d'anomalies et l'amélioration de certaines fonctionnalités. Cette approche a facilité la réalisation progressive de la plateforme tout en gardant une meilleure cohérence avec les objectifs du projet.

1.6.6 Synthèse

Ce chapitre a établi le fondement méthodologique du projet en suivant une progression logique : de la critique des méthodes agiles traditionnelles à l'adoption d'un cadre innovant adapté à l'ère de l'IA générative.

Les méthodes agiles classiques (Scrum, Kanban) ont été écartées non par rejet du principe itératif qu'elles incarnent, mais parce qu'elles n'intègrent structurellement pas l'IA comme

collaborateur du cycle de développement. L'AI-DLC, formalisé par AWS en 2025, propose un cadre réimagine qui place la spécification et les agents IA au cœur du processus.

Parmi les frameworks d'implémentation disponibles, le **GSD Framework** a été retenu pour sa gestion avancée du contexte, sa compatibilité native avec l'outillage utilisé (Codex CLI, OpenCode, Claude Code) et son adéquation avec le profil d'un développeur augmenté travaillant en autonomie sur un projet multi-agents complexe. Cette base a été enrichie par des skills personnalisées configurées dans Codex CLI, constituant une méthodologie hybride cohérente et documentée.

Le chapitre suivant présente l'architecture technique de la plateforme, conçue et développée dans ce cadre méthodologique.

1.7 Conclusion

Dans ce chapitre, nous avons présenté le contexte général du projet, l'entreprise d'accueil 3S ainsi que les besoins ayant motivé la réalisation de la plateforme. Nous avons également étudié les solutions existantes, défini les exigences fonctionnelles et non fonctionnelles, puis présenté la méthodologie de travail adoptée pour conduire le projet.

Le chapitre suivant sera consacré à la présentation de l'architecture de la solution et des choix techniques retenus pour sa mise en œuvre.

Chapitre 2

Fondements IA, conception et architecture de la solu

Contents

2.1 Introduction 22

2.2 Fondements de l'intelligence artificielle utilisée 22

2.2.1 Les modèles de langage de grande taille (LLMs) 22

2.2.2 Les agents intelligents et les systèmes multi-agents 24

2.2.3 Le Retrieval-Augmented Generation (RAG) 26

2.2.4 Modèles d'Embeddings 27

2.2.5 Les prompts système des agents IA 28

2.2.6 Les agent skills 29

2.3 Système de mémoire persistante des agents IA 30

2.3.1 Présentation de Hindsight 31

2.3.2 Architecture générale de Hindsight 31

2.3.3 Fonctionnalités fondamentales utilisées 32

2.3.4 Infrastructure et configuration de Hindsight dans le projet 35

2.3.5 Structure des mémoires persistantes dans Hindsight 36

2.4 Architecture de la plateforme 37

2.4.1 Vue d'ensemble de l'architecture 37

2.4.2 Architecture microservices du backend 40

2.4.3 Architecture multi-tenant 42

2.4.4 Modèle de données 44

2.4.5 Architecture des agents IA 45

2.5 Choix technologiques et justification 53

2.5.1 Stack frontend et backend 53

2.5.2 Bases de données, IA et infrastructure 54

2.6 Conclusion 56

2.1 Introduction

Après avoir présenté le contexte du projet, l'étude de l'existant, les exigences fonctionnelles et non fonctionnelles ainsi que la méthodologie de travail adoptée, ce chapitre est consacré à la conception de la solution proposée et aux choix techniques retenus pour sa mise en œuvre.

La réalisation d'une plateforme de formation et de mentorat assistée par l'intelligence artificielle repose sur plusieurs concepts liés à l'ingénierie logicielle, aux systèmes distribués et aux technologies d'intelligence artificielle. Il est donc nécessaire de présenter les fondements techniques sur lesquels s'appuie la plateforme afin de mieux comprendre son architecture et l'organisation de ses différents modules.

Ce chapitre présente d'abord les principaux concepts mobilisés dans le cadre du projet, notamment les modèles de langage de grande taille, les agents intelligents, les systèmes multi-agents, les embeddings, les prompts système, les agent skills, le RAG ainsi que les mécanismes de mémoire utilisés pour enrichir les interactions avec les agents. Il expose ensuite l'architecture globale de la solution, les choix technologiques retenus, l'organisation des services et la structure du système multi-agent.

Enfin, ce chapitre présente les modèles de conception et la modélisation des données afin de fournir une représentation claire de la solution avant d'aborder sa réalisation et sa validation dans les parties suivantes.

2.2 Fondements de l'intelligence artificielle utilisée

La plateforme développée dans le cadre de ce projet repose sur plusieurs concepts fondamentaux de l'intelligence artificielle moderne qui constituent la base de son fonctionnement.

Les sections suivantes présentent les principaux fondements mobilisés, notamment les modèles de langage de grande taille, les agents intelligents et les systèmes multi-agents, les représentations vectorielles sémantiques, les prompts système et les agent skills.

2.2.1 Les modèles de langage de grande taille (LLMs)

2.2.1.1 Définition des LLMs

Un grand modèle de langage [23] (Large Language Model, LLM) est un modèle d'intelligence artificielle entraîné sur de très vastes corpus de données textuelles afin d'apprendre les structures statistiques et sémantiques du langage naturel. Il est capable de comprendre, générer et manipuler du texte avec un haut niveau de cohérence, en produisant des sorties adaptées au contexte d'entrée.

2.2.1.2 Utilisation dans le projet

Dans le cadre de ce projet, les modèles de langage de grande taille sont utilisés pour assister certaines fonctionnalités intelligentes de la plateforme. Ils interviennent notamment dans la génération de contenus pédagogiques, l'analyse des demandes formulées par les utilisateurs, la production de réponses adaptées au contexte d'apprentissage et la génération d'activités personnalisées.

Ces modèles ne sont pas utilisés de manière isolée. Ils sont intégrés dans des traitements applicatifs qui leur fournissent un contexte précis, comme le cours concerné, la progression de l'utilisateur ou l'objectif pédagogique recherché. Les réponses produites peuvent ensuite être structurées, par exemple sous forme de données JSON, afin d'être exploitées par les différents modules de la plateforme.

2.2.1.3 Étude du choix du LLM

Le choix du modèle de langage constitue une étape importante dans la conception des fonctionnalités intelligentes de la plateforme. Ce choix doit tenir compte de plusieurs critères, notamment la qualité des réponses générées, la capacité du modèle à traiter des contextes longs, le coût d'utilisation, la facilité d'intégration et la compatibilité avec les besoins du projet.

Dans ce cadre, plusieurs modèles de langage ont été étudiés afin d'identifier la solution la plus adaptée aux contraintes fonctionnelles et techniques de la plateforme. Le tableau 2.1 présente une comparaison des principaux modèles considérés selon leur fournisseur, leur nombre de paramètres, leur fenêtre de contexte et leur coût d'utilisation.

TABLE 2.1 – Comparaison des LLMs compatibles avec OpenMAIC et Hindsight

Modèle	**Fournisseur**	**Nombre de paramètres**	**Fenêtre de contexte**	**Coût du LLM**
openai/gpt-oss-120b :free [24]	OpenRouter / OpenAI OSS	117 milliards	131K tokens [25]	0 $ / 1M tokens en entrée ; 0 $ / 1M tokens en sortie [25]
gemma-4-4b	Serveur interne de la société	4 milliards	Non communiqué publiquement	0 $ / 1M tokens en entrée ; 0 $ / 1M tokens en sortie
GPT-5.4 mini [26]	OpenAI	Non communiqué	400K tokens [26]	0,75 $ / 1M tokens en entrée ; 4,50 $ / 1M tokens en sortie [27]
Claude Haiku 4.5 [28]	Anthropic	Non communiqué	200K tokens [29]	1 $ / 1M tokens en entrée ; 5 $ / 1M tokens en sortie [30]
Gemini 3.1 Flash-Lite [31]	Google / Gemini	Non communiqué	1M tokens [31]	0,25 $ / 1M tokens en entrée ; 1,50 $ / 1M tokens en sortie [32]
Llama 3.1 8B Instant [33]	Groq	8 milliards	131072 tokens [33]	0,05 $ / 1M tokens en entrée ; 0,08 $ / 1M tokens en sortie [34]
Mistral Small 4 [35]	Mistral AI	Non communiqué	256K tokens [35]	0,10 $ / 1M tokens en entrée ; 0,30 $ / 1M tokens en sortie [36]

2.2.1.4 Choix retenu

Le modèle retenu pour les fonctionnalités d'intelligence artificielle de la plateforme est *openai/gpt-oss-120b :free*, accessible via OpenRouter. Ce modèle est utilisé comme modèle principal pour la génération de contenus pédagogiques, l'assistance aux utilisateurs, la formulation de recommandations et la production de réponses contextualisées.

Ce choix s'explique par sa capacité à produire des réponses structurées, sa fenêtre de contexte étendue de 131K tokens et son coût nul dans sa variante gratuite. Ces caractéristiques sont adaptées aux besoins du projet, notamment pendant les phases de test, d'intégration et de validation, où le volume de requêtes peut être important.

Le modèle hébergé sur les serveurs internes de la société a également été pris en compte, notamment pour les cas où l'utilisation d'un modèle local serait préférable du point de vue du contrôle de l'environnement d'exécution. Toutefois, ce modèle n'a pas été retenu comme modèle principal, car son utilisation reste limitée au réseau interne de l'entreprise. Cette contrainte réduit sa disponibilité lors du développement, des tests et des démonstrations réalisées en dehors de l'infrastructure de 3S.

Ainsi, *openai/gpt-oss-120b :free* a été privilégié comme modèle principal, tandis que le modèle interne reste une solution complémentaire envisageable dans un contexte d'utilisation strictement interne à l'entreprise.

2.2.2 Les agents intelligents et les systèmes multi-agents

2.2.2.1 Définition des agents intelligents

Un agent intelligent [37] peut être défini comme un composant logiciel fondé sur l'intelligence artificielle, conçu pour analyser un contexte, prendre des décisions et exécuter des actions afin d'atteindre un objectif donné. Contrairement à un programme déterministe classique, il peut s'appuyer sur des mécanismes de raisonnement, de planification, de mémoire et d'adaptation pour produire un comportement plus autonome.

Dans les systèmes récents basés sur les modèles de langage de grande taille, le LLM joue souvent le rôle de moteur de raisonnement. L'agent, quant à lui, est défini par son rôle, ses outils, sa mémoire, ses consignes et son intégration dans un processus applicatif.

2.2.2.2 Définition des systèmes multi-agents

Un système multi-agents [38] correspond à une architecture dans laquelle plusieurs agents spécialisés interviennent au sein d'un même environnement logiciel. Chaque agent prend en charge une responsabilité précise, échange des informations avec les autres composants du système et contribue à la réalisation d'un objectif global.

Cette approche permet de remplacer une logique centralisée par une organisation distribuée, dans laquelle chaque agent possède un rôle clair. Elle favorise ainsi la séparation des

responsabilités, la modularité et l'évolution progressive du système.

2.2.2.3 Utilisation dans le projet

Dans le cadre de ce projet, l'utilisation d'un système multi-agents a été retenue afin de séparer les responsabilités liées aux différentes fonctionnalités intelligentes de la plateforme. En effet, les besoins du projet ne se limitent pas à une seule tâche d'assistance : la plateforme doit générer des contenus pédagogiques, accompagner les apprenants, mémoriser certaines informations utiles, proposer des recommandations et produire des défis personnalisés.

Le recours à plusieurs agents spécialisés permet donc d'éviter une logique unique trop généraliste et difficile à maintenir. Chaque agent prend en charge une responsabilité précise, ce qui facilite l'évolution du système, l'amélioration indépendante de chaque fonctionnalité et l'adaptation des traitements au contexte de l'apprenant.

Dans cette architecture, certains agents peuvent également s'appuyer sur des sous-agents. Un sous-agent désigne ici un composant spécialisé rattaché à un agent principal, chargé d'exécuter une tâche interne précise au service de cet agent.

Les principaux agents développés dans la plateforme sont les suivants :

- **Agent de création de cours :** il assiste la génération de contenus pédagogiques structurés à partir des objectifs de formation et des informations fournies par l'utilisateur. Il s'appuie sur deux sous-agents spécialisés. Le premier est un sous-agent de mémoire de cours, chargé d'exploiter les informations relatives au cours en cours de création afin d'améliorer la cohérence des contenus générés et d'assurer une continuité entre les différentes étapes de construction du cours. Le second est un sous-agent de révision de scènes, qui aide l'administrateur à ajuster certaines parties d'un cours généré à partir d'une consigne de modification, sans devoir réécrire manuellement tout le contenu concerné.
- **Agent de coaching :** il accompagne l'apprenant pendant son parcours de formation en lui fournissant des réponses contextualisées et des conseils adaptés à sa progression.
- **Agent de mémoire apprenant :** il constitue un agent transversal chargé de structurer, conserver et récupérer les informations utiles liées au parcours de l'apprenant, à ses interactions et aux difficultés rencontrées.
- **Agent de recommandation :** il propose des contenus ou des actions adaptés au profil de l'apprenant, à ses compétences et à son avancement dans les parcours de formation.
- **Agent de défis personnalisés :** il génère des exercices ou des défis adaptés au niveau et aux besoins de l'apprenant afin de renforcer l'engagement et la progression.

Ainsi, l'approche multi-agents permet d'organiser les fonctionnalités intelligentes de la plateforme autour de responsabilités distinctes, tout en conservant une architecture modulaire et évolutive.

2.2.3 Le Retrieval-Augmented Generation (RAG)

2.2.3.1 Définition du RAG

Le Retrieval-Augmented Generation (RAG) [39] est une approche qui consiste à enrichir la génération d'un LLM par des informations récupérées depuis une source de connaissances externe. Au lieu de produire une réponse uniquement à partir des connaissances apprises pendant son entraînement, le modèle reçoit d'abord des éléments pertinents issus d'une base documentaire, d'une base de données ou d'une mémoire spécialisée. Ces informations sont ensuite ajoutées au contexte de la requête afin de guider la génération de la réponse.

2.2.3.2 Workflow général

Le fonctionnement général d'un système RAG suit plusieurs étapes. Les données utiles sont d'abord préparées, découpées en fragments et transformées en représentations exploitables pour la recherche, généralement à l'aide d'embeddings. Lorsqu'un utilisateur formule une requête, le système recherche les fragments les plus pertinents dans la base de connaissances, puis les injecte dans le prompt transmis au LLM. Le modèle génère alors une réponse en s'appuyant à la fois sur la question de l'utilisateur et sur le contexte récupéré.

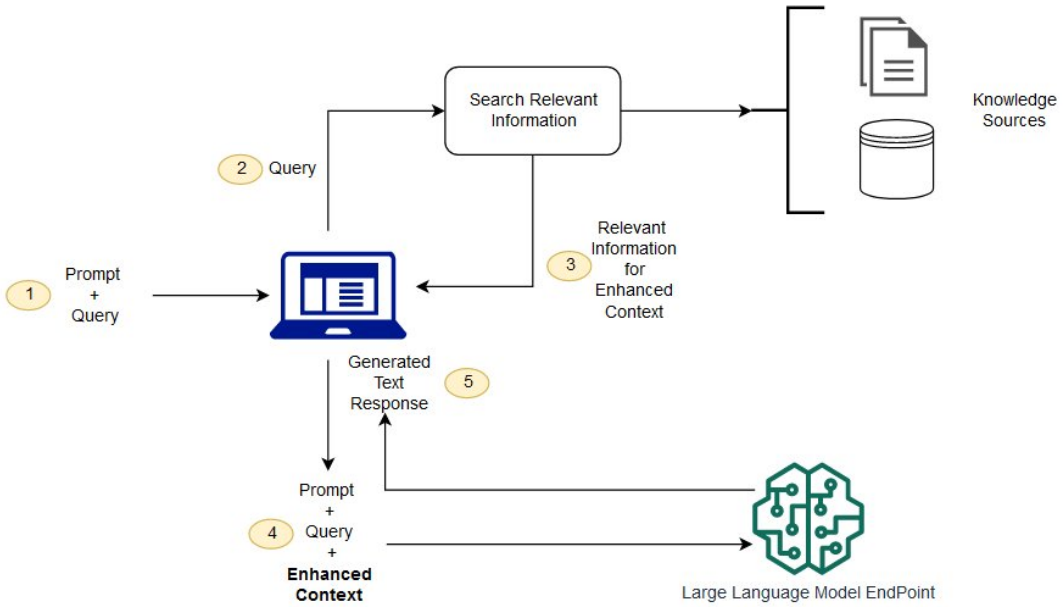


FIGURE 2.1 – Workflow général d'un système RAG [39]

2.2.3.3 Agentic RAG

L'*agentic RAG* [40] désigne une évolution du RAG dans laquelle la récupération d'information n'est pas seulement déclenchée de manière automatique, mais pilotée par un ou plusieurs agents capables de décider quelles sources consulter, quels outils utiliser et comment intégrer

les informations récupérées dans leur raisonnement. Cette approche rend le RAG plus flexible qu'un pipeline classique, car l'agent peut adapter la récupération au contexte de la requête.

2.2.3.4 Utilisation dans le projet

Dans la plateforme, l'approche d'*agentic RAG* est utilisée dans les fonctionnalités qui nécessitent une réponse contextualisée, notamment le coaching pédagogique, les recommandations, les défis personnalisés et l'exploitation de la mémoire liée aux cours ou aux apprenants. Elle permet aux agents de récupérer les informations utiles selon la demande, le profil de l'utilisateur, le cours concerné et l'objectif pédagogique recherché.

Ce choix est plus adapté qu'un RAG classique, car les besoins de récupération varient d'un agent à l'autre. Un agent de coaching, un agent de recommandation et un agent de défis personnalisés n'exploitent pas le même contexte. L'*agentic RAG* permet donc d'adapter la récupération des informations à la responsabilité de chaque agent, afin de produire des réponses plus personnalisées et cohérentes avec la situation pédagogique.

2.2.4 Modèles d'Embeddings

2.2.4.1 Définition des embeddings

Les incorporations [41], ou embeddings, désignent des représentations vectorielles denses de données textuelles dans un espace mathématique de haute dimension. Elles permettent de représenter des objets, tels que du texte, des images ou de l'audio, sous forme de points dans un espace vectoriel continu dont la position porte une signification sémantique. Dans le cas du texte, la proximité géométrique entre deux vecteurs reflète ainsi une similarité de sens entre les éléments représentés.

2.2.4.2 Embeddings et recherche sémantique

Dans les systèmes basés sur les Transformers, les embeddings représentent des passages entiers et non seulement des mots isolés. Ils permettent ainsi la recherche sémantique, où le système compare le sens des requêtes et des contenus plutôt que des mots-clés exacts. Dans un système RAG, cette représentation sert à retrouver les fragments de connaissances les plus proches de la requête de l'utilisateur.

2.2.4.3 Étude du choix du modèle d'embeddings

Le choix du modèle d'embeddings influence directement la qualité de la recherche sémantique dans le système RAG. La comparaison porte donc sur la dimension des vecteurs, le mode de déploiement, le coût d'utilisation et l'intégration avec les mémoires et les contenus pédagogiques de la plateforme.

TABLE 2.2 – Comparaison des modèles d'embeddings utilisables pour le système RAG

Modèle	Fournisseur	Dimension	Coût et déploiement
BAAI/bge-small-en-v1.5 [42]	Local / Sentence-Transformers	384	Gratuit à l'usage, exécution locale, modèle léger d'environ 130 Mo
text-embedding-3-small [43]	OpenAI	1536	Service cloud payant : 0,02 $ / 1M tokens [44]
mistral-embed [45]	Mistral AI / LiteLLM	1024	Service cloud payant : 0,10 $ / 1M tokens en entrée [46]
embed-english-v3.0 [47]	Cohere	1024	Service cloud avec clé API ; prix public par token non précisé pour ce modèle dans la page officielle [48]
gemini-embedding-001 [49]	Google / Vertex AI	3072 par défaut, dimension configurable	Service cloud : gratuit en free tier, puis 0,15 $ / 1M tokens en entrée [32]

2.2.4.4 Choix retenu

À partir de cette comparaison, le modèle *BAAI/bge-small-en-v1.5* a été retenu pour la génération des embeddings dans le système RAG du projet. Ce choix s'explique par son exécution locale, son coût nul à l'usage et sa légèreté, puisqu'il produit des vecteurs de 384 dimensions.

Ce modèle offre un compromis adapté entre qualité de recherche sémantique, consommation mémoire et simplicité d'intégration. Les tests réalisés ont montré qu'il répond aux besoins de récupération d'informations de la plateforme. Il est également cohérent avec le système de mémoire utilisé dans le projet, qui supporte les embeddings locaux basés sur ce modèle [50].

2.2.5 Les prompts système des agents IA

2.2.5.1 Définition

Un prompt système [51] correspond à un ensemble de consignes placées en amont de l'interaction avec le LLM. Il permet d'orienter le modèle avant même la demande de l'utilisateur, en précisant le rôle attendu, les règles de comportement, le style de réponse, les contraintes fonctionnelles et les limites à ne pas dépasser.

2.2.5.2 Rôle dans les agents IA

Dans une application basée sur des agents IA, le prompt système permet de spécialiser un modèle généraliste afin qu'il adopte un comportement cohérent avec un contexte métier précis. Chaque agent reçoit ainsi des consignes qui définissent son périmètre d'action, les informations à prendre en compte et la forme attendue de sa réponse.

2.2.5.3 Utilisation dans le projet

Dans ce projet, les prompts système sont utilisés pour construire et spécialiser les agents de coaching, de mémoire apprenant, de recommandation et de génération de défis. Ils permettent également d'intégrer les éléments dynamiques nécessaires au raisonnement des agents, comme l'historique de conversation, le profil de l'apprenant, le contexte du cours ou les mémoires récupérées.

Ces prompts imposent aussi des formats de sortie structurés, notamment en JSON, afin que les réponses générées soient directement exploitables par les services applicatifs de la plateforme.

La figure 2.2 présente un exemple de prompt système utilisé dans le projet pour encadrer l'analyse des difficultés de l'apprenant par l'Agent de recommandation.

```
reflect_query = (
    "You are a recommendation agent mapping learner-course difficulties to skill domains.\n"
    "Use the course-bank knowledge to determine what exact skill domains and concepts these learner signals refer to.\n"
    "Read the learner signals as a grouped difficulty set for this course.\n"
    "Return valid JSON only.\n\n"
    "Tasks:\n"
    "- identify the main skill domains involved in these learner signals\n"
    "- map each signal to the most relevant domain\n"
    "- distinguish weak unresolved domains from remediated ones\n"
```

FIGURE 2.2 – Exemple de prompt système utilisé par l'Agent de recommandation

2.2.6 Les agent skills

2.2.6.1 Définition

Les agent skills [52] désignent des blocs d'instructions spécialisés qu'un agent peut utiliser pour traiter une tâche précise. Contrairement au prompt système, qui définit le comportement général de l'agent, un skill apporte une logique plus ciblée : il précise une méthode de raisonnement, des règles de décision ou une procédure adaptée à un cas particulier.

2.2.6.2 Besoin des skills dans le projet

Dans le cadre de ce projet, l'utilisation des skills permet d'éviter de regrouper toutes les règles de fonctionnement dans un seul prompt système. Cette approche rend les agents plus modulaires et plus faciles à faire évoluer. Lorsqu'une tâche spécifique doit être réalisée, l'agent peut mobiliser uniquement le skill correspondant, sans surcharger son contexte avec des consignes inutiles.

Ce choix est particulièrement utile pour les fonctionnalités qui nécessitent plusieurs modes de traitement selon la situation de l'apprenant, comme la génération de défis personnalisés. Chaque skill permet alors de traiter un besoin pédagogique précis tout en gardant une organisation claire et maintenable.

2.2.6.3 Skills ajoutés dans la plateforme

Dans la plateforme, les skills sont utilisés principalement par l'**Agent de création de cours** et par l'**Agent de défis personnalisés**. Ils permettent de spécialiser le comportement de ces agents selon la nature de la tâche à réaliser, sans surcharger leur prompt principal avec toutes les règles possibles.

Pour l'**Agent de création de cours**, plusieurs skills de génération pédagogique ont été ajoutés afin d'encadrer les différentes étapes de construction d'un cours. Un premier skill est chargé de transformer la demande de l'utilisateur, les documents fournis et les ressources disponibles en un plan structuré comprenant le titre du cours, la langue d'enseignement, les scènes, leurs objectifs et leur ordre pédagogique. D'autres skills interviennent ensuite selon le type de scène à produire : génération de diapositives, génération de quiz, création de scènes interactives, production de simulations, de diagrammes, d'exercices de code ou de jeux éducatifs.

Cet agent utilise également des skills dédiés à la génération des actions pédagogiques associées aux scènes, comme les explications orales, les transitions entre les idées ou la mise en évidence de certains éléments sur une diapositive. Un skill de révision de scène permet aussi d'aider l'administrateur à modifier une scène existante à partir d'une consigne, sans réécrire manuellement tout le contenu concerné.

Pour l'**Agent de défis personnalisés**, les skills permettent d'adapter le type de défi à la situation de l'apprenant. Cet agent peut ainsi choisir le mode de défi le plus approprié, générer un exercice à partir d'une erreur commise dans un quiz précédent, cibler une difficulté déclarée par l'apprenant, exploiter un point important du cours ou proposer un renforcement général à partir du contenu étudié.

Ainsi, les skills ajoutés dans la plateforme permettent de séparer les différentes stratégies de génération et d'adaptation pédagogique. Cette organisation rend les agents plus modulaires, plus lisibles et plus faciles à faire évoluer, tout en améliorant la cohérence des contenus et des activités générés.

2.3 Système de mémoire persistante des agents IA

La personnalisation des interactions avec les agents IA nécessite de conserver certaines informations au-delà d'une simple session d'utilisation. Dans la plateforme, cette mémoire permet de réutiliser les éléments liés au parcours de l'apprenant, aux contenus de formation, aux difficultés rencontrées et aux interactions précédentes.

Cette section revient sur la solution retenue pour mettre en place cette mémoire persistante. Elle présente son fonctionnement général, les opérations qui structurent le cycle de vie des mémoires, son intégration dans la plateforme ainsi que l'organisation des différentes mémoires exploitées par les agents IA.

2.3.1 Présentation de Hindsight

Hindsight [53] est un système de mémoire conçu pour les agents IA. Il fournit une couche dédiée à la mémorisation, à la récupération et à l'exploitation des informations retenues au fil des interactions. Hindsight ne se limite donc pas à stocker des messages : il vise à construire une mémoire durable, structurée et réutilisable par des agents intelligents [54].

Dans ce projet, Hindsight est retenu comme solution de support à la mémoire persistante des agents IA. Son utilisation s'inscrit dans le besoin de conserver un contexte exploitable au fil des interactions, afin de renforcer la continuité et la personnalisation des traitements réalisés par la plateforme.

2.3.2 Architecture générale de Hindsight

L'architecture de Hindsight peut être comprise en deux niveaux. Le premier niveau correspond à la couche d'intégration : l'agent ou l'application n'accède pas directement au stockage interne, mais communique avec Hindsight à travers un client, un SDK ou une API HTTP. Cette interface expose les opérations de mémoire principales, notamment *retain*, *recall* et *reflect*. Le second niveau correspond à la couche de mémoire elle-même, organisée autour de banques de mémoire, appelées *memory banks*. Chaque banque isole un contexte de mémorisation, par exemple un utilisateur, un agent, un cours ou un domaine métier.

À l'intérieur d'une *memory bank*, les informations ne sont pas stockées uniquement comme un historique brut de messages. Hindsight les organise sous plusieurs formes complémentaires. Les documents et leurs fragments, ou *chunks*, constituent les sources initiales. À partir de ces sources, le système extrait des mémoires, des entités, des relations et des informations temporelles. Ces éléments alimentent ensuite différents types de connaissances : des faits liés au monde, des expériences propres à l'agent, des observations consolidées et, dans certains cas, des modèles mentaux qui représentent une compréhension plus stable construite à partir des mémoires accumulées.

La figure 2.3 présente une vue conceptuelle de cette architecture et met en évidence l'organisation des sources, des mémoires et des connaissances manipulées par Hindsight.

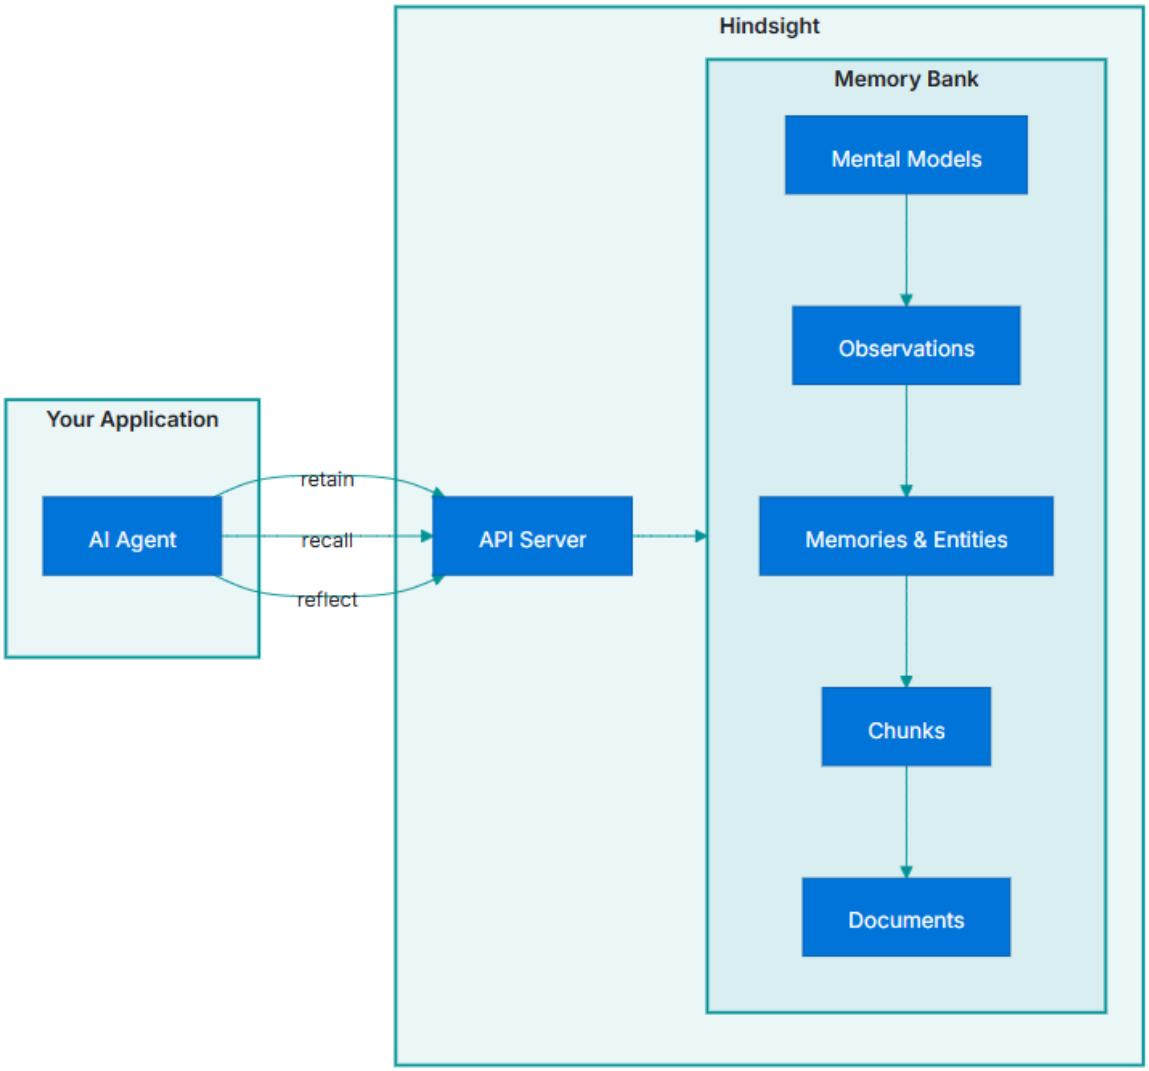


FIGURE 2.3 – Architecture conceptuelle de Hindsight [53]

2.3.3 Fonctionnalités fondamentales utilisées

Dans ce projet, l'intégration de Hindsight repose principalement sur trois opérations complémentaires : *retain*, *recall* et *reflect*. Ces opérations couvrent le cycle de vie de la mémoire d'un agent : enregistrer une information, la retrouver lorsqu'elle devient utile, puis raisonner à partir des mémoires disponibles.

— **Retain :** cette opération correspond à l'écriture dans la mémoire. Comme l'illustre la figure 2.4, Hindsight ne stocke pas directement le texte brut : il utilise le LLM pour extraire les faits importants, identifier les entités, les périodes temporelles et les types de faits, puis normaliser les entités afin d'éviter les doublons. Ces informations sont ensuite transformées en *memory units*, enrichies par des métadonnées et des embeddings, puis reliées entre elles par des liens d'entités, temporels, sémantiques ou causaux. Enfin, les souvenirs sont classés dans des catégories de mémoire, comme *world*, *experience*, *opinion* ou *observation*, avant leur stockage final [55]. Dans la plateforme, cette opération

permet de mémoriser les difficultés exprimées par l'apprenant, ses erreurs récurrentes, ses préférences pédagogiques et les éléments importants issus de ses interactions avec les agents.

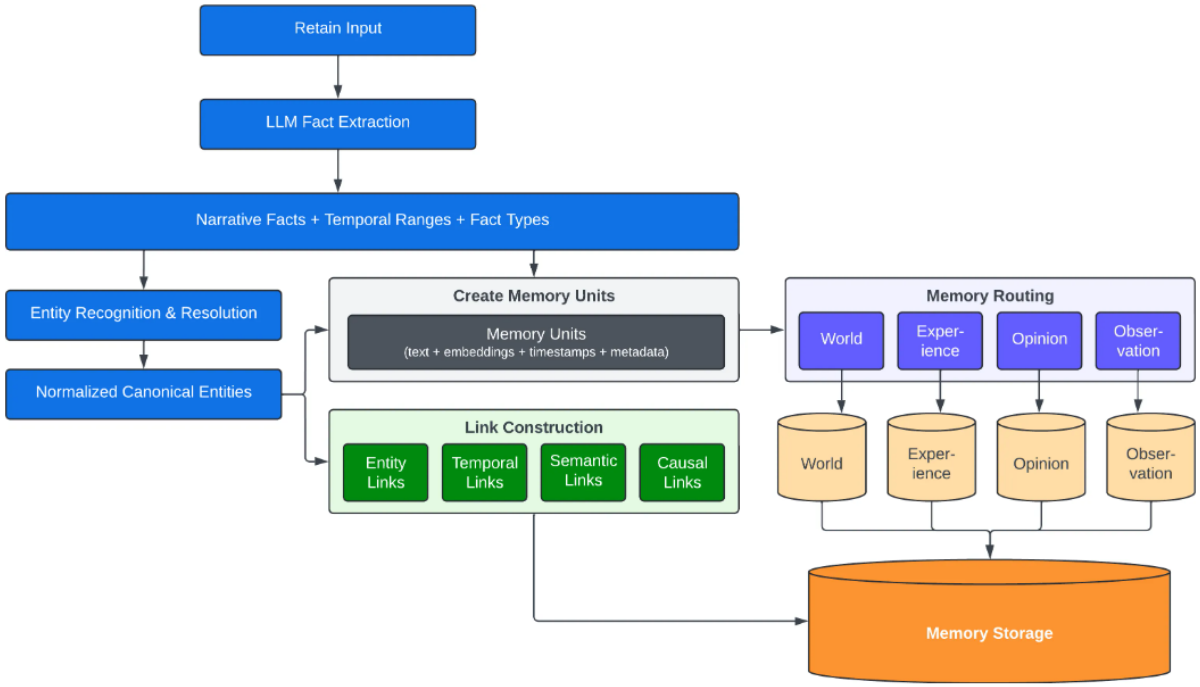


FIGURE 2.4 – Fonctionnement de l'opération *Retain* dans Hindsight [54]

— **Recall :** cette opération correspond à la récupération intelligente des mémoires déjà stockées. Comme l'illustre la figure 2.5, Hindsight ne renvoie pas toute la mémoire à l'agent : il lance plusieurs recherches en parallèle, notamment la recherche sémantique par similarité vectorielle, la recherche par mots-clés, l'exploration des liens entre entités et l'exploitation des informations temporelles. Les résultats obtenus sont ensuite fusionnés, réordonnés et filtrés selon le budget de tokens disponible, afin de constituer un ensemble de souvenirs contextualisés à transmettre au LLM [56]. Dans ce projet, *recall* permet donc de retrouver les informations les plus utiles sur l'apprenant, son historique et le cours avant la génération d'une réponse.

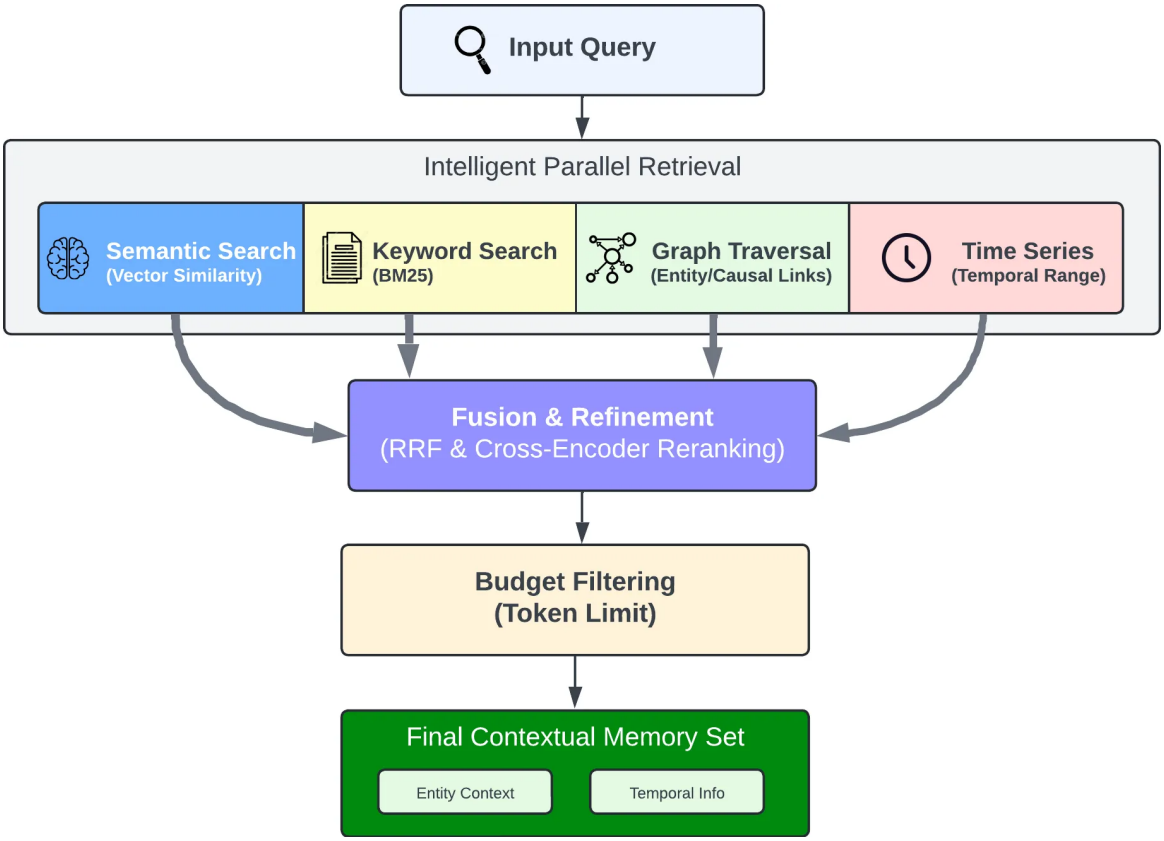


FIGURE 2.5 – Fonctionnement de l'opération *Recall* dans Hindsight [54]

— **Reflect :** cette opération correspond à la phase de réflexion et de mise à jour de la mémoire après une interaction. Comme l'illustre la figure 2.6, Hindsight récupère d'abord les mémoires pertinentes, construit un contexte, charge le profil de l'agent, puis utilise le LLM pour générer une réponse cohérente avec ce contexte. La réponse produite est ensuite analysée afin d'identifier de nouvelles observations ou de mettre à jour des opinions existantes, avec un niveau de confiance associé. Ces éléments sont réinjectés dans la mémoire persistante, ce qui permet à l'agent d'améliorer progressivement la cohérence de ses futures interactions [57]. Dans ce projet, *reflect* est utile pour dégager des tendances sur le parcours d'un apprenant, consolider des observations pédagogiques et enrichir la mémoire des agents au fil des échanges.

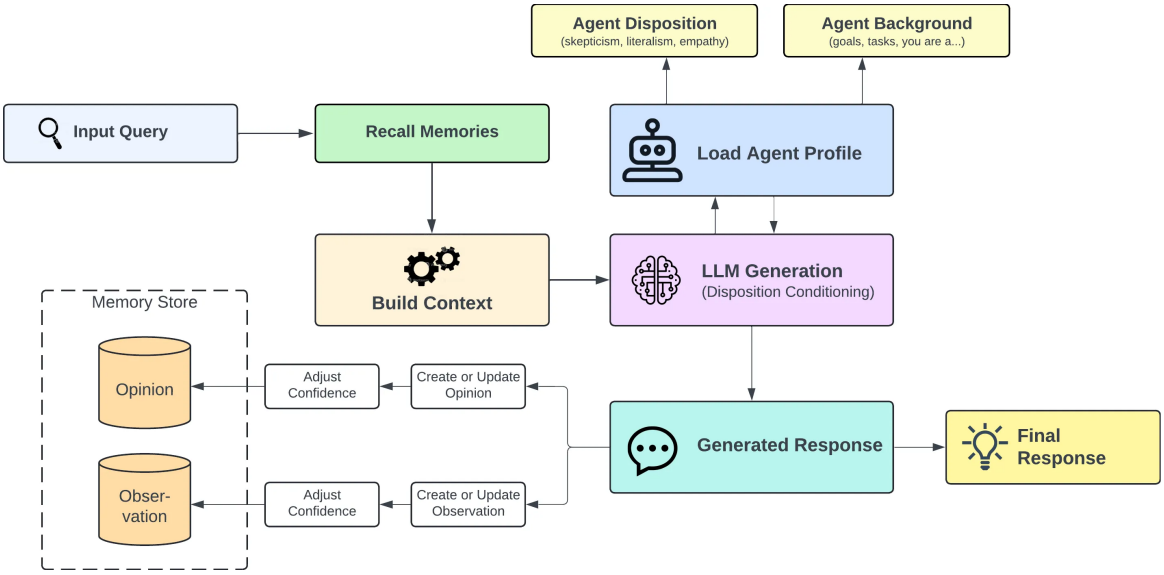


FIGURE 2.6 – Fonctionnement de l'opération *Reflect* dans Hindsight [54]

En résumé, l'organisation de la mémoire Hindsight repose sur un cycle continu qui permet de conserver, d'exploiter et d'améliorer progressivement les informations utiles aux agents IA. Cette approche donne à la plateforme une mémoire durable, capable de maintenir le contexte au fil des interactions et de soutenir une personnalisation plus cohérente des réponses, des recommandations et des activités proposées.

2.3.4 Infrastructure et configuration de Hindsight dans le projet

L'infrastructure mise en place pour Hindsight peut être décrite à travers plusieurs éléments complémentaires :

2.3.4.1 Position dans l'architecture

Hindsight est intégré comme une couche de mémoire séparée de la logique applicative. Les agents communiquent avec cette couche à travers son API, sans manipuler directement les tables, les vecteurs ou les mécanismes internes de recherche. Cette séparation permet de centraliser la gestion de la mémoire tout en gardant les agents focalisés sur leurs responsabilités fonctionnelles.

2.3.4.2 Stockage et persistance

Les informations mémorisées sont persistées dans une base PostgreSQL conteneurisée, configurée avec l'extension *pgvector*. Cette extension permet à PostgreSQL de stocker les vecteurs issus des embeddings et d'effectuer des recherches par similarité entre ces vecteurs. Ainsi, lorsqu'un agent cherche une information utile, Hindsight peut comparer le vecteur de la requête avec les vecteurs déjà enregistrés afin de retrouver les mémoires les plus proches sur le plan sémantique.

2.3.4.3 Configuration des embeddings

Dans le cadre du projet, Hindsight a été configuré pour utiliser le modèle *BAAI/bge-small-en-v1.5* afin de générer les représentations vectorielles des informations mémorisées. Cette configuration permet d'associer chaque mémoire à une représentation sémantique exploitable par la couche de mémoire.

2.3.4.4 Configuration du LLM

Hindsight a été configuré pour utiliser *openai/gpt-oss-120b :free* via OpenRouter dans les étapes nécessitant de l'analyse ou du raisonnement, notamment l'extraction des faits pendant *retain* et l'enrichissement de la mémoire pendant *reflect*. Le modèle *gemma-4-4b*, hébergé sur le serveur interne de la société, est conservé comme solution alternative lorsque le modèle principal n'est pas disponible ou lorsqu'une utilisation interne est requise.

2.3.5 Structure des mémoires persistantes dans Hindsight

Dans ce projet, Hindsight organise les informations sous forme de banques mémoire séparées, appelées *memory banks*. Chaque banque est identifiée à partir du *tenantId*, du *userId* et du *courseId*, selon le contexte concerné. Cette organisation permet d'isoler les mémoires par organisation, par apprenant ou par cours, tout en fournissant aux agents un contexte précis à exploiter.

Le préfixe `tenant:{tenantId}` est conservé dans chaque identifiant afin de rattacher chaque mémoire à l'organisation concernée. Ce choix est cohérent avec l'architecture multi-tenant de la plateforme et permet d'éviter le mélange des mémoires entre différentes filiales ou espaces d'utilisation.

— **Banque de cours :** elle contient la mémoire pédagogique du cours publié et suit l'identifiant :

`tenant:{tenantId}:course:{courseId}`

Elle est alimentée par le sous-agent de mémoire de cours après la génération et la publication du cours. Elle conserve les éléments stables du contenu pédagogique : objectifs, leçons, explications, quiz, supports, transcriptions vidéo et concepts importants. Cette banque est notamment utilisée par l'Agent de coaching, l'Agent de recommandation et l'Agent de défis personnalisés.

— **Banque apprenant-cours :** elle représente l'historique personnel d'un apprenant dans un cours donné et suit la forme :

`tenant:{tenantId}:user:{userId}:course:{courseId}`

Elle est alimentée par l'Agent de mémoire apprenant à partir des événements du parcours : complétion de leçon, progression vidéo, résultats de quiz, mauvaises réponses, difficultés détectées, messages de coaching liés au cours et résultats des défis personnalisés.

— **Banque générale de l'apprenant :** elle mémorise les informations durables qui ne sont pas limitées à un cours particulier, comme les préférences pédagogiques, les éléments de profil, les connaissances préalables ou les informations générales exprimées pendant les échanges. Son identifiant est :

`tenant:{tenantId}:user:{userId}`

— **Banque de profil de compétences :** elle est utilisée par l'Agent de recommandation pour conserver la synthèse des compétences de l'apprenant, notamment son profil de compétences et l'analyse de ses écarts de compétences. Elle suit l'identifiant :

`tenant:{tenantId}:user:{userId}:skill-profile`

Elle permet à l'Agent de recommandation de s'appuyer sur une mémoire synthétique déjà structurée, sans recalculer toute l'analyse à chaque demande.

Ainsi, la structure des mémoires dans Hindsight repose sur une séparation entre la connaissance du cours, l'historique de l'apprenant dans un cours, le profil général de l'apprenant et la synthèse de ses compétences. Cette organisation rend la mémoire plus contrôlable et limite les risques de confusion entre les contextes. Elle permet aussi aux agents de choisir la bonne banque selon leur objectif : comprendre le contenu d'un cours, analyser la progression d'un apprenant, personnaliser une réponse ou produire une recommandation.

2.4 Architecture de la plateforme

Cette section présente l'architecture globale retenue pour la plateforme. Elle décrit d'abord l'organisation générale du système en couches, afin de clarifier la séparation entre l'interface utilisateur, les services métier, les composants IA, la mémoire persistante et les données. Elle présente ensuite l'architecture microservices du backend, le modèle multi-tenant adopté, la structure des données ainsi que l'organisation des agents IA intégrés à la solution.

2.4.1 Vue d'ensemble de l'architecture

La plateforme repose sur une architecture en couches afin de structurer le système de manière claire et évolutive. Cette vue d'ensemble permet de présenter les principales responsabilités de la solution ainsi que les échanges entre ses composants.

2.4.1.1 Organisation générale des couches

L'architecture est structurée autour de six couches principales, présentées de haut en bas selon le parcours d'une requête dans le système :

1. **Couche de présentation :** elle correspond à l'interface web utilisée par les différents profils de la plateforme. Elle permet d'afficher les données, de déclencher les actions utilisateur et de communiquer avec le backend à travers des appels API.

2. **Couche API Gateway :** elle constitue le point d'entrée unique entre l'interface web et les services internes. Elle reçoit les requêtes du frontend, les redirige vers le service approprié et centralise l'accès aux fonctionnalités backend.
3. **Couche des microservices :** elle regroupe les services responsables des principaux domaines fonctionnels de la plateforme, tels que l'identité, l'administration, la gestion des cours, le suivi de progression et la gamification. Elle applique les règles métier et prépare les données nécessaires aux traitements du système.
4. **Couche IA :** elle regroupe les agents spécialisés responsables des traitements intelligents de la plateforme, comme la création assistée de cours, le coaching, la mémorisation, la recommandation et la génération de défis personnalisés.
5. **Couche Hindsight :** elle constitue la couche de mémoire persistante utilisée par les agents IA. Elle permet de conserver et de récupérer les informations utiles à la personnalisation des traitements.
6. **Couche de données :** elle regroupe les systèmes de stockage utilisés par la plateforme, notamment PostgreSQL et les composants nécessaires à la persistance des données métier, des historiques et des résultats produits par le système.

La figure 2.7 synthétise cette organisation en couches et montre la position des principaux composants de la plateforme.

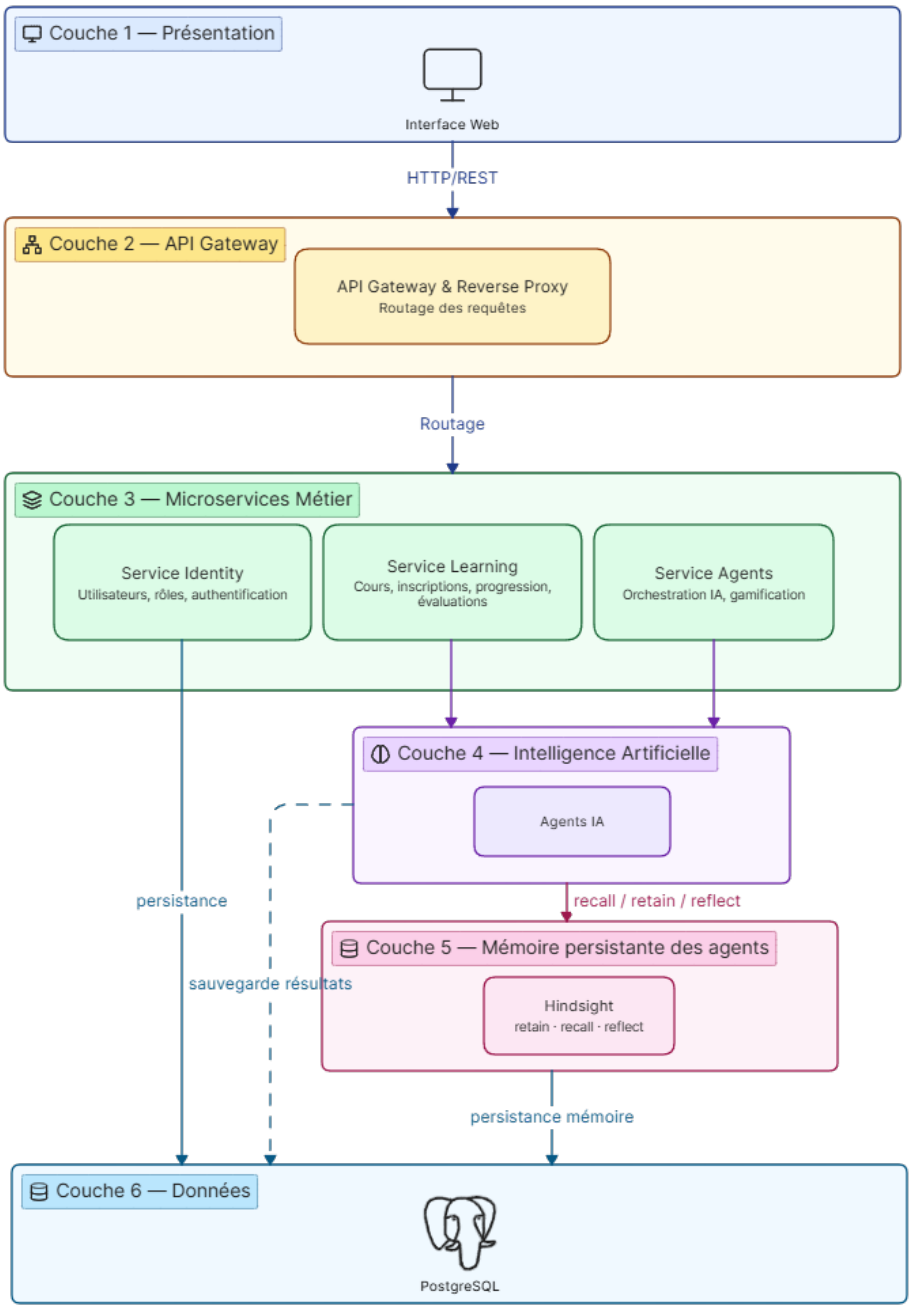


FIGURE 2.7 – Vue d'ensemble de l'architecture en couches de la plateforme

2.4.1.2 Articulation entre les couches

Ces six couches s'articulent de manière progressive. L'utilisateur interagit avec la couche de présentation, qui envoie ses requêtes vers l'*API Gateway*. Celle-ci transmet les appels aux microservices concernés. Lorsque le traitement nécessite une personnalisation ou une génération intelligente, les microservices sollicitent la couche IA. Les agents peuvent alors récupérer ou enrichir le contexte à travers Hindsight, puis retourner le résultat vers les services métier. Les données nécessaires au suivi applicatif sont ensuite stockées dans la couche de données, tandis que les traces utiles à la personnalisation sont conservées dans la mémoire persistante.

2.4.1.3 Séparation entre logique métier et logique IA

Cette organisation met en évidence une séparation importante entre la logique métier et la logique IA. Les microservices restent responsables des règles fonctionnelles de la plateforme, alors que les agents IA sont responsables des traitements intelligents liés au contenu, à l'accompagnement et à la personnalisation. Cette séparation rend l'architecture plus lisible, facilite l'évolution des agents et limite l'impact d'une modification IA sur le fonctionnement métier de la plateforme.

Les sous-sections suivantes détaillent ensuite les deux parties principales de cette architecture : l'organisation microservices du backend, puis l'architecture des agents IA et leurs workflows.

2.4.2 Architecture microservices du backend

L'architecture backend de la plateforme repose sur une approche microservices. Ce choix permet d'éviter un backend monolithique dans lequel l'authentification, la gestion pédagogique, le suivi des apprenants et les traitements IA seraient regroupés dans une seule application. La plateforme couvre plusieurs domaines fonctionnels distincts ; il est donc plus adapté de séparer ces responsabilités afin de faciliter la maintenance, l'évolution et le déploiement progressif des fonctionnalités.

Dans ce projet, le backend est structuré autour de quatre services principaux : *Identity*, *Learning*, *Agents* et *API Gateway*. Ce découpage permet d'introduire les principaux composants backend qui seront détaillés dans les sous-sections suivantes.

2.4.2.1 API Gateway

L'accès aux microservices est centralisé à travers une couche *API Gateway*. Traefik, utilisé comme reverse proxy, est chargé de recevoir les requêtes entrantes et de les rediriger vers le microservice approprié selon les règles de routage définies. Cette couche reçoit les requêtes provenant du frontend, applique les règles de routage et transmet chaque appel vers le service approprié. Elle permet donc au frontend de communiquer avec un point d'entrée unique au lieu de connaître directement les adresses internes des services. Elle facilite aussi l'organisation des routes API, l'isolation des services dans le réseau Docker et l'évolution de l'architecture lorsqu'un nouveau service est ajouté.

2.4.2.2 Microservices réels et modules fonctionnels internes

Dans l'implémentation de la plateforme, le backend n'est pas découpé en autant de services que de fonctionnalités. Il repose sur trois microservices principaux : *identity*, *learning* et *agents*. Les éléments comme l'authentification, la gestion des rôles, les cours, la progression, les quiz, les recommandations ou les défis correspondent donc à des modules fonctionnels internes rattachés à l'un de ces microservices, et non à des microservices indépendants.

— **Microservice identity :** ce microservice porte tout le domaine lié à l'identité et à l'accès à la plateforme. Il contient les modules internes d'authentification, de gestion des tenants, de gestion des utilisateurs, des rôles, des permissions, de l'onboarding, de la configuration initiale et des journaux d'audit. Il constitue donc le point de référence pour contrôler qui accède à la plateforme et avec quels droits.

— **Microservice learning :** ce microservice regroupe le domaine pédagogique de la plateforme. Il contient les modules internes liés aux cours, aux modules, aux leçons, aux inscriptions, à la progression, aux quiz, aux tentatives, aux objectifs, aux équipes, à la gamification, aux recommandations métier et aux défis côté plateforme. Les recommandations et les défis ne sont donc pas des microservices séparés : ce sont des fonctionnalités du service *learning* qui peuvent préparer les données, sauvegarder les résultats et appeler la couche IA lorsque la génération intelligente est nécessaire.

— **Microservice agents :** ce microservice constitue le composant backend dédié aux traitements d'intelligence artificielle. Il regroupe la logique d'orchestration des agents de création de cours, de coaching pédagogique, de mémoire apprenant, de recommandation et de défis personnalisés. Il reçoit les demandes provenant de la plateforme, prépare le contexte nécessaire, déclenche l'agent concerné, puis retourne un résultat exploitable par les services métier. Il centralise ainsi l'exécution des workflows IA et isole cette logique spécialisée du reste du backend.

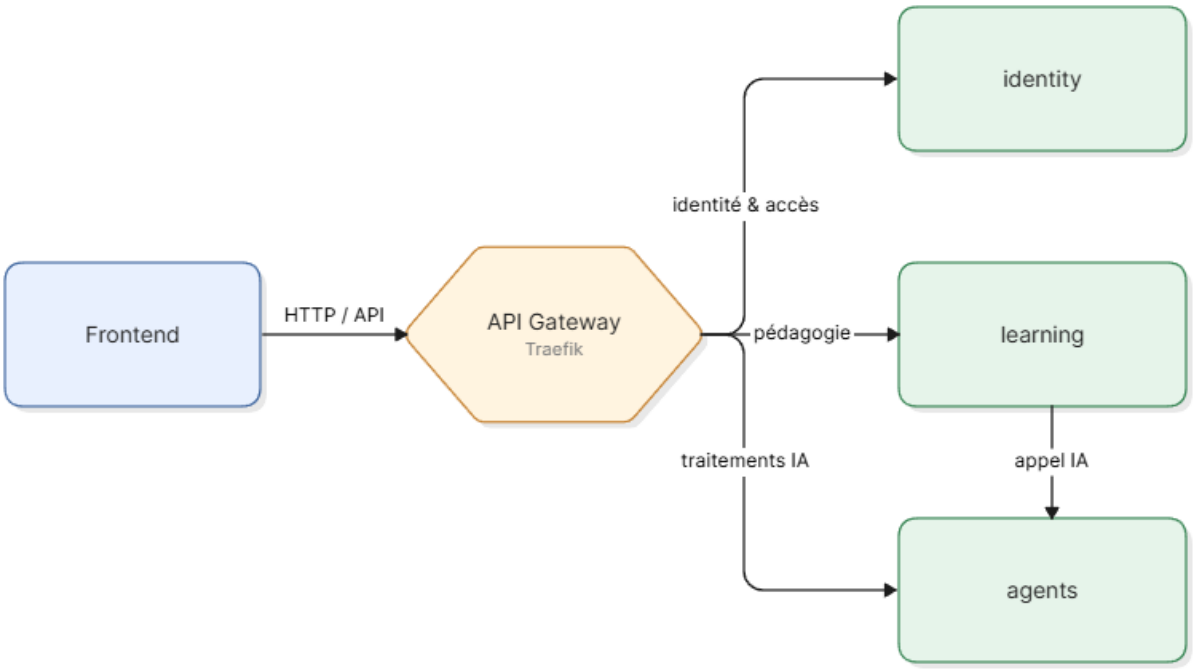


FIGURE 2.8 – Diagramme de l'architecture microservices du backend

2.4.2.3 Communication entre les services

La communication entre le frontend et le backend passe principalement par l'*API Gateway*, qui redirige les requêtes vers les microservices concernés selon les routes définies.

La majorité des échanges sont synchrones lorsqu'une réponse immédiate est attendue par l'utilisateur, par exemple lors de la connexion, de l'ouverture d'une leçon ou de la récupération d'une recommandation. Certaines actions métier peuvent aussi déclencher des traitements IA, comme l'indexation d'un cours publié, la mémorisation d'une trace apprenant ou la génération de recommandations à partir d'un quiz échoué.

2.4.3 Architecture multi-tenant

Une architecture multi-tenant désigne un modèle dans lequel une même instance applicative est partagée par plusieurs organisations, appelées tenants, tout en maintenant une séparation logique de leurs données, de leurs utilisateurs et de leurs règles d'accès [58].

Dans le cadre de ce projet, ce choix est adapté au contexte du groupe 3S, composé de plusieurs sociétés pouvant utiliser une même plateforme de formation tout en conservant leurs propres utilisateurs, rôles, cours et données de suivi. L'objectif est donc de mutualiser l'infrastructure applicative tout en garantissant l'isolation des données entre les organisations.

2.4.3.1 Isolation des données au niveau des services

L'isolation des données est appliquée au niveau des services backend afin de garantir que chaque organisation accède uniquement à ses propres informations. Cette séparation repose principalement sur l'association des données métier à un identifiant de tenant, appelé *tenant_id*. Lorsqu'une requête est traitée, ce contexte permet aux services backend de sélectionner uniquement les données appartenant à l'organisation concernée.

Les services de la plateforme exploitent ensuite ce contexte pour limiter les utilisateurs, les rôles, les cours, les inscriptions, les progressions et les traitements IA au périmètre de l'organisation concernée. Ainsi, même si l'infrastructure applicative est partagée entre plusieurs sociétés du groupe 3S, les données et les traitements restent séparés logiquement.

2.4.3.2 Gestion des rôles par tenant

La gestion des rôles suit aussi cette logique multi-tenant. Un utilisateur possède généralement un rôle dans un tenant donné, par exemple *Admin*, *Formateur* ou *Apprenant*. L'*Admin* gère la configuration et les membres de son organisation, le *Formateur* crée ou administre les contenus pédagogiques, tandis que l'*Apprenant* consulte les cours, passe les quiz et reçoit les recommandations ou défis personnalisés. En complément, la plateforme prévoit un rôle *Super Admin*, rattaché à la couche administrative du groupe 3S. Ce rôle dispose d'une vision transversale sur les tenants et permet de créer, configurer ou administrer les différentes sociétés du groupe depuis un niveau central. Comme l'illustre la figure 2.9, cette organisation permet donc

d'appliquer des droits spécifiques à chaque tenant, tout en conservant un niveau d'administration global pour le pilotage de l'ensemble de la plateforme.

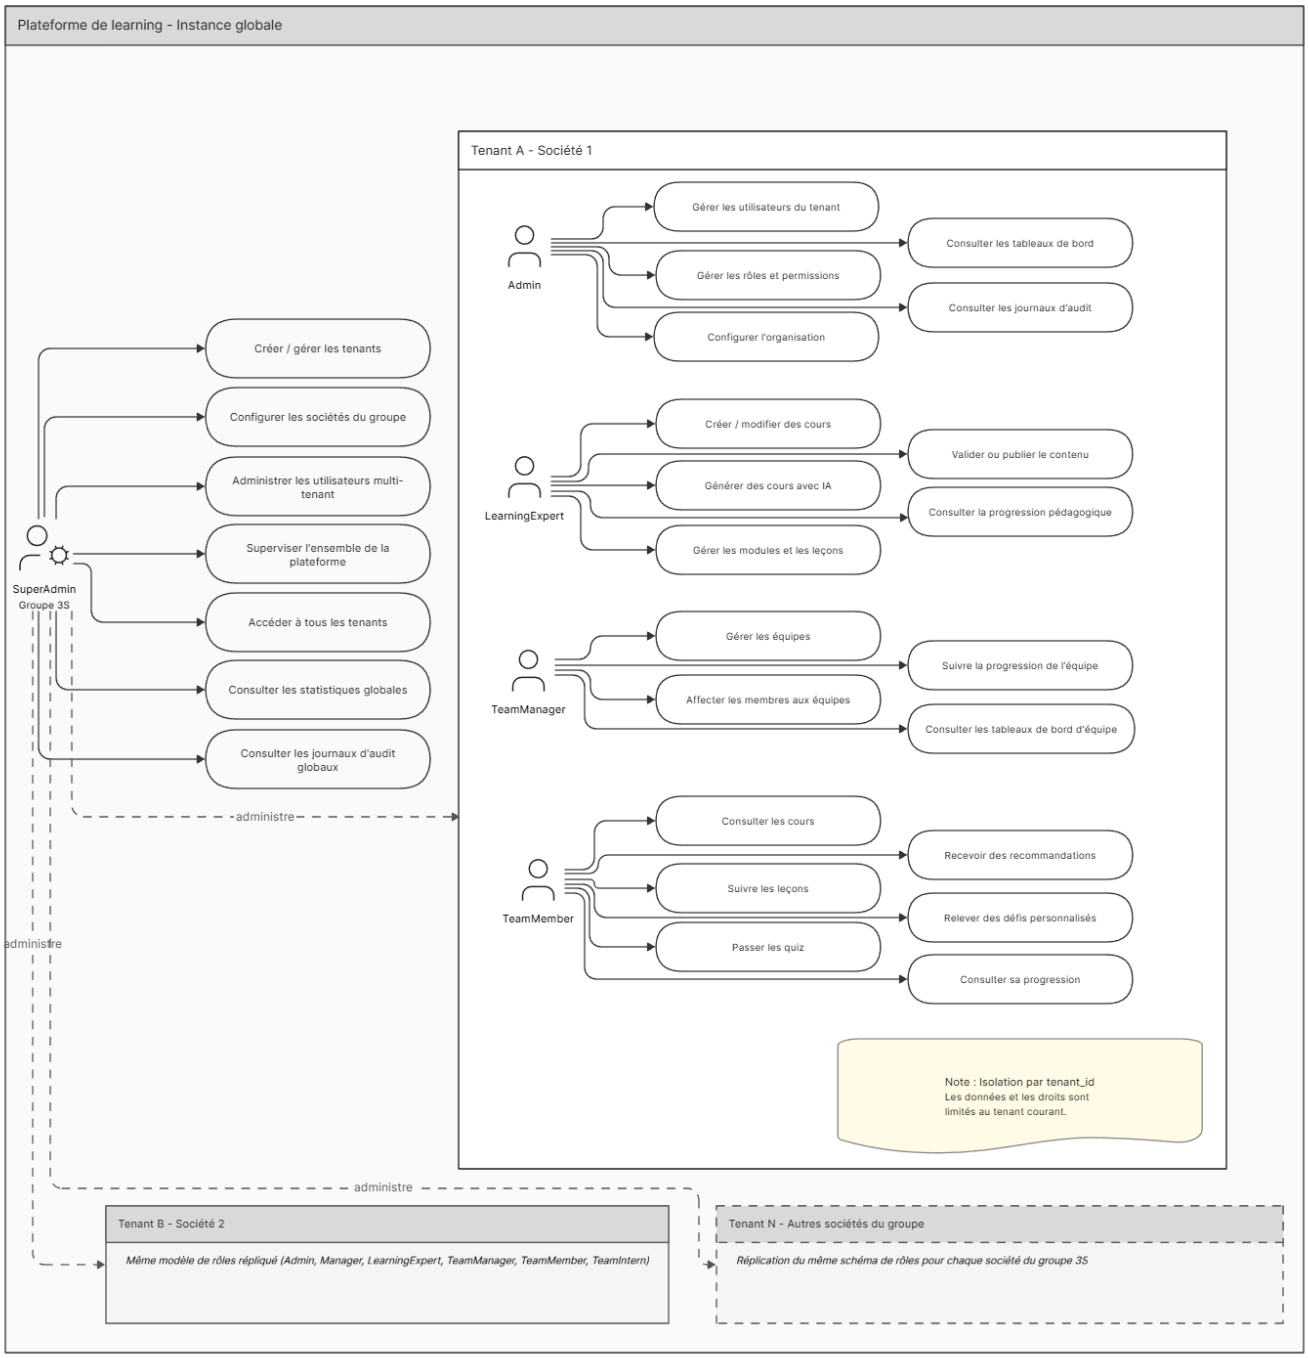


FIGURE 2.9 – Diagramme de cas d'utilisation UML des rôles dans l'architecture multi-tenant

Cette architecture garantit donc que la plateforme reste commune au niveau technique, tout en séparant les organisations au niveau fonctionnel et au niveau des données. Cette logique se retrouve directement dans le modèle de données, où les principales informations métier sont rattachées à un tenant afin de préserver l'isolation entre les sociétés du groupe.

2.4.4 Modèle de données

Le modèle de données de la plateforme repose sur une base relationnelle PostgreSQL pour stocker les informations structurées du système. Ces données concernent principalement les utilisateurs, les organisations, les cours, les inscriptions, la progression des apprenants, les évaluations, les défis personnalisés et les recommandations.

Ce choix est adapté au projet, car ces informations sont fortement liées entre elles et nécessitent une cohérence relationnelle afin d'assurer le suivi des parcours, le contrôle des accès et la gestion des contenus pédagogiques. Les données propres à chaque organisation restent rattachées au contexte du tenant, conformément à l'architecture multi-tenant présentée précédemment.

2.4.4.1 Organisation générale des données

Les données manipulées par la plateforme peuvent être regroupées en plusieurs familles fonctionnelles. La première concerne l'identité et l'administration des organisations. La deuxième porte sur les contenus pédagogiques, notamment les cours, modules, leçons et évaluations. La troisième concerne le suivi de l'apprentissage, à travers les inscriptions, la progression et les résultats des apprenants. Enfin, certaines données sont liées aux fonctionnalités intelligentes, comme les recommandations, les profils de compétences et les défis personnalisés.

Cette organisation permet de structurer les informations nécessaires au fonctionnement de la plateforme sans exposer inutilement les détails internes de chaque table.

2.4.4.2 Stockage hybride des ressources

La plateforme adopte un stockage hybride afin de séparer les données structurées des ressources pédagogiques volumineuses. Les métadonnées, comme le titre d'un cours, l'ordre d'une leçon, l'inscription d'un apprenant ou le score d'un quiz, sont conservées dans PostgreSQL.

En revanche, les fichiers pédagogiques tels que les vidéos, images, documents PDF, miniatures et supports de cours sont stockés dans MinIO, un stockage objet compatible S3. La base relationnelle conserve uniquement les références vers ces ressources, par exemple sous forme de chemins ou de liens.

Cette séparation permet d'alléger la base relationnelle, de mieux gérer les fichiers volumineux et de faciliter l'organisation des ressources pédagogiques par tenant. Elle offre ainsi une structure plus adaptée aux besoins d'une plateforme de formation contenant à la fois des données métier et des contenus multimédias.

Ainsi, le modèle de données combine une base relationnelle pour assurer la cohérence des informations métier et un stockage objet pour gérer efficacement les ressources pédagogiques. Cette organisation soutient à la fois le fonctionnement multi-tenant et le suivi des parcours d'apprentissage.

2.4.5 Architecture des agents IA

La couche IA de la plateforme est organisée autour de plusieurs agents spécialisés, chacun associé à une responsabilité pédagogique précise. L'objectif n'est pas de construire un seul agent généraliste chargé de toutes les tâches, mais de répartir les traitements intelligents entre des agents plus ciblés : agent de création de cours, agent de coaching pédagogique, agent de mémoire apprenant, agent de recommandation et agent de défis personnalisés. Cette séparation permet de mieux contrôler le comportement de chaque agent et d'adapter ses consignes au contexte fonctionnel dans lequel il intervient.

2.4.5.1 Agent de création de cours

Cet agent assure la génération assistée des cours à travers une orchestration autour d'OpenMAIC. À partir d'une consigne fournie par l'expert pédagogique, éventuellement accompagnée d'un document PDF, il prépare la demande, suit l'exécution du processus et récupère le brouillon produit. OpenMAIC prend en charge la génération principale du contenu pédagogique, notamment les scènes de cours, les diapositives, les scripts du professeur, les quiz et, lorsque c'est pertinent, les activités interactives. Le résultat n'est pas un fichier statique, mais un brouillon structuré et éditable, ensuite sauvegardé dans la plateforme afin d'être révisé, validé puis transformé en cours officiel. Après la validation finale, le cours peut être enrichi par la génération audio TTS et transmis au Course Memory Agent pour son intégration dans la mémoire persistante. Le déroulement détaillé de cet agent est illustré par la figure 2.10.

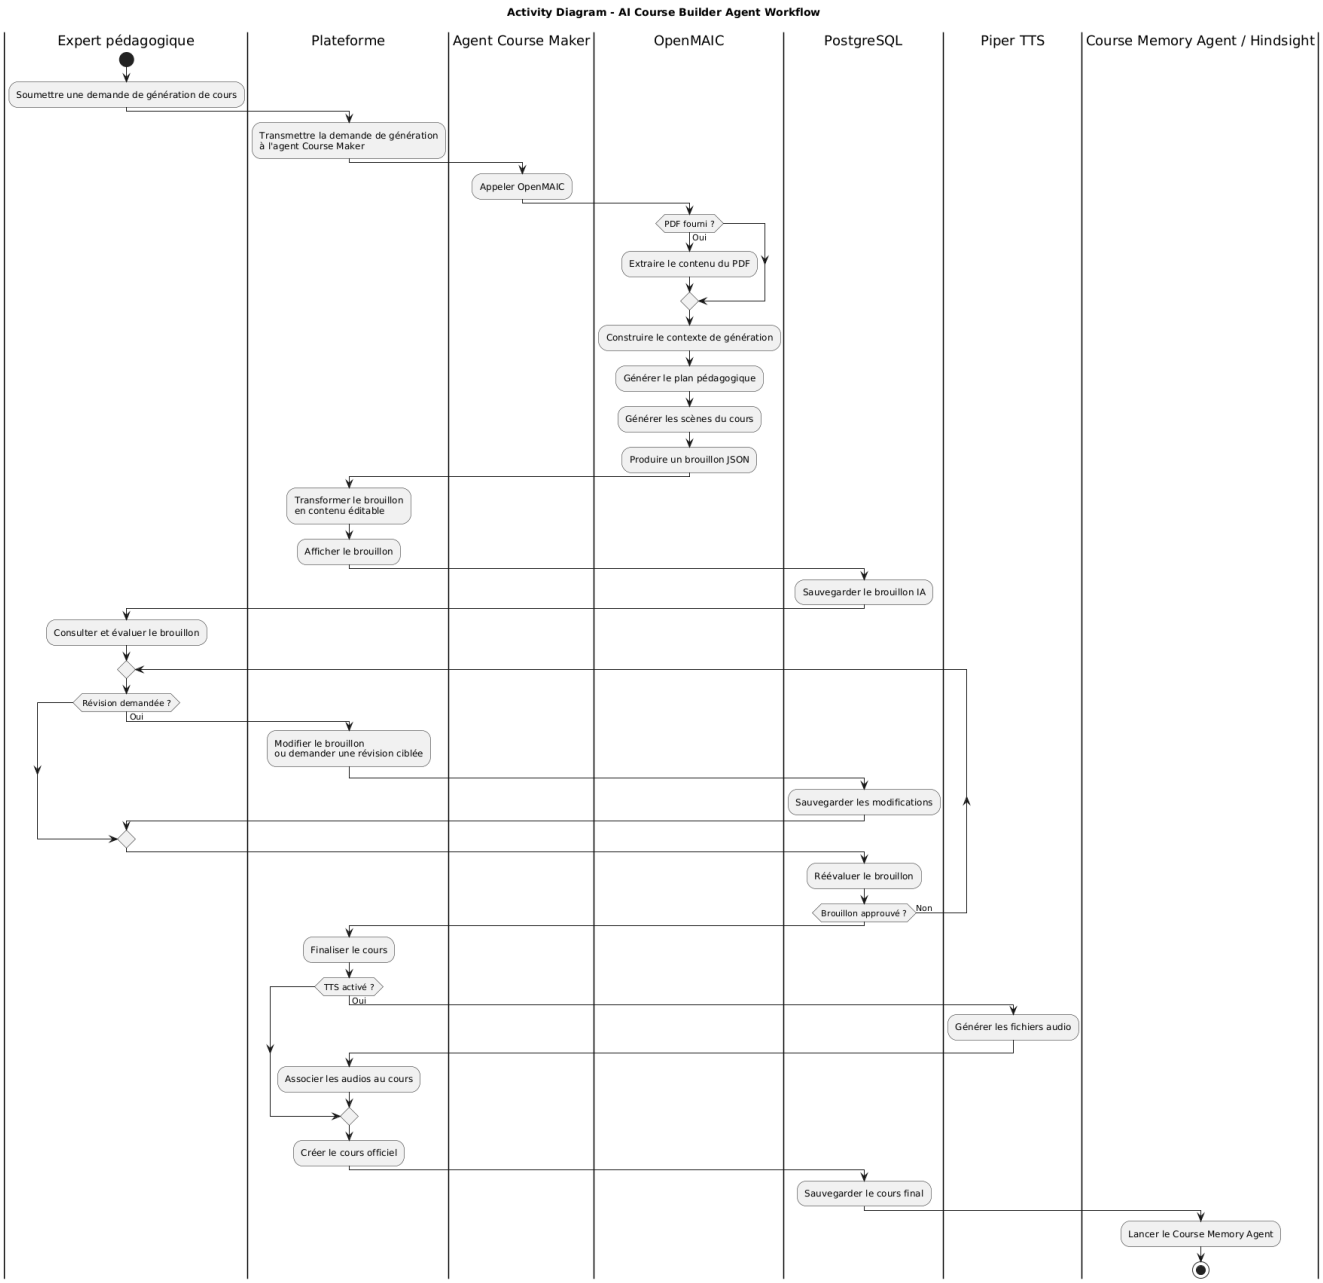


FIGURE 2.10 – Diagramme d'activité UML de l'agent de création de cours

2.4.5.2 Agent de coaching pédagogique

Cet agent accompagne l'apprenant pendant son parcours en répondant à ses questions à partir du contexte du cours et de sa mémoire personnelle. Lorsqu'une question est posée, la plateforme transmet la demande à l'agent *AI Coaching Agent*. Celui-ci récupère d'abord les informations pertinentes du cours à travers l'opération *recall* de Hindsight, tout en déclenchant la mémorisation de la question de l'apprenant via l'agent de mémoire apprenant. Les éléments rappelés sont ensuite utilisés pour construire une requête enrichie, puis Hindsight exécute une opération *reflect* sur la mémoire propre à l'apprenant et au cours. La réponse produite est

ainsi contextualisée, liée au contenu pédagogique et adaptée à l'historique de l'utilisateur. Le déroulement de cet agent est illustré par la figure 2.11.

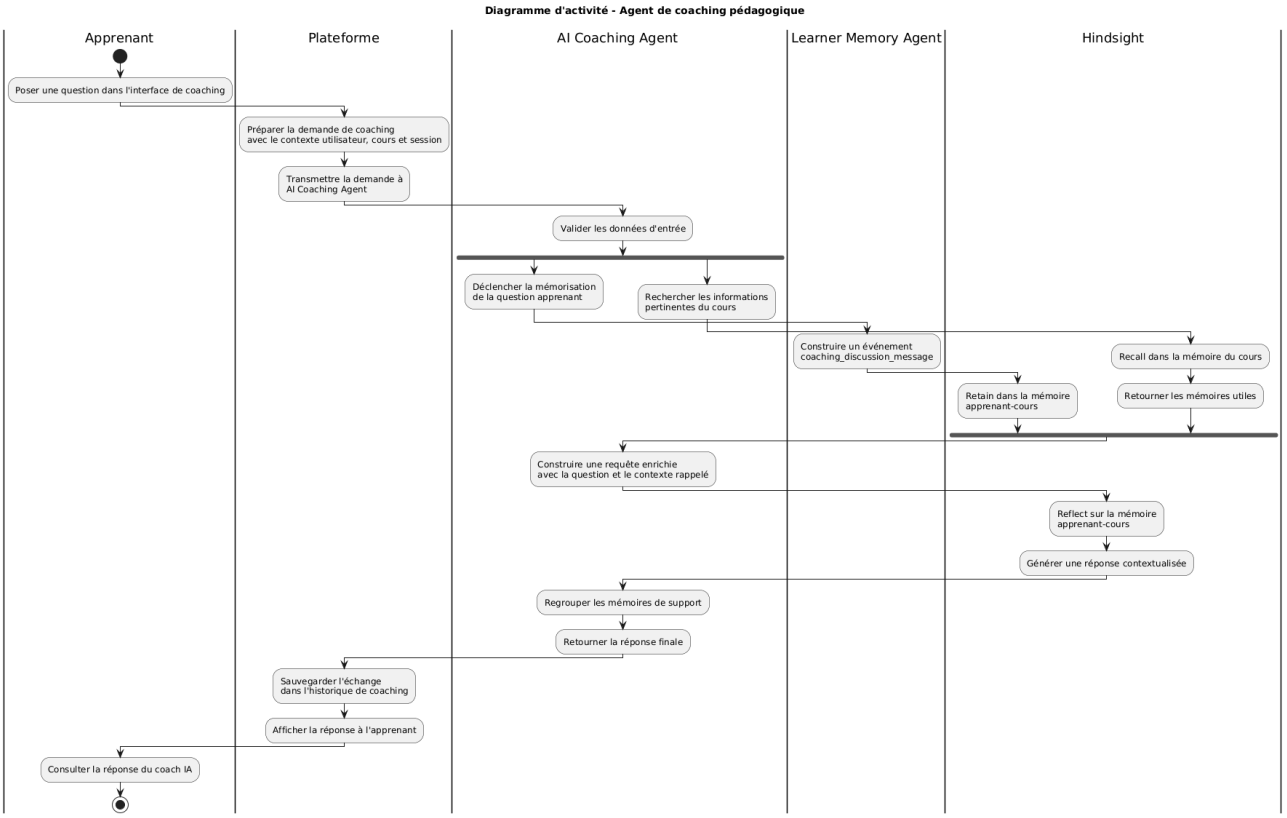


FIGURE 2.11 – Diagramme d'activité UML de l'agent de coaching pédagogique

2.4.5.3 Agent de mémoire apprenant

Cet agent alimente la mémoire persistante du suivi pédagogique. Il est déclenché par plusieurs événements du parcours apprenant, comme l'envoi d'un message au *AI Coaching Agent*, la complétion d'une leçon, le passage d'un quiz, la progression dans une vidéo, la détection d'une difficulté, la réponse à un défi personnalisé ou la complétion d'un cours. Après validation des données reçues, il prépare le contenu à mémoriser. Pour les messages de coaching, il vérifie les mémoires similaires avec *recall* afin d'éviter les doublons, puis conserve les nouvelles informations avec *retain*. Pour les autres événements d'apprentissage, il enregistre une trace structurée dans la banque mémoire de l'apprenant et du cours. Ces informations peuvent ensuite être rappelées par les autres agents pour personnaliser leurs réponses.

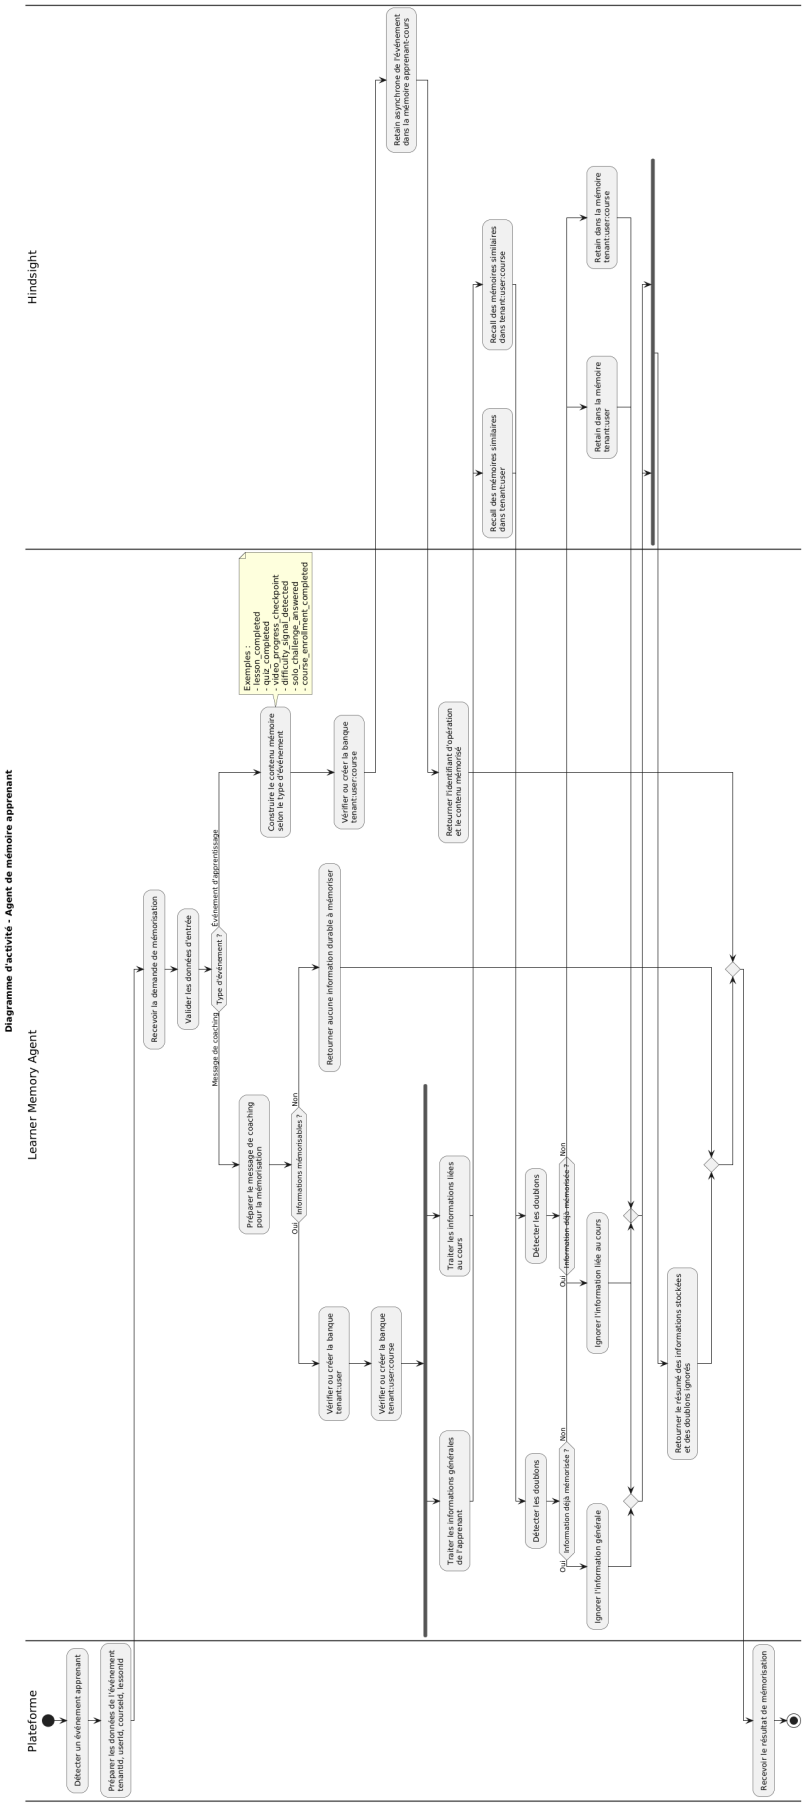


FIGURE 2.12 – Diagramme d'activité UML de l'agent de mémoire apprenant

2.4.5.4 Agent de recommandation

Cet agent a pour objectif de personnaliser le parcours d'apprentissage en proposant à chaque apprenant les actions les plus adaptées à son état actuel. Il s'appuie d'abord sur les mémoires liées aux cours suivis par l'apprenant afin de construire un *skill gap radar*, c'est-à-dire une synthèse des domaines de compétences maîtrisés, partiellement maîtrisés ou encore faibles. Les compétences faibles sont ensuite comparées avec le catalogue des cours publiés. Cette comparaison ne repose pas uniquement sur une décision manuelle : Hindsight et le LLM interviennent pour transformer les signaux d'apprentissage en domaines de compétences, tandis que l'agent applique ensuite une logique de correspondance par mots-clés entre ces compétences et les informations des cours, comme le titre, la description, la catégorie et le niveau. Pour chaque cours candidat, un score de pertinence est calculé selon le nombre de mots-clés communs, l'état de la compétence détectée et la situation de l'apprenant dans le cours. Par exemple, une compétence non maîtrisée reçoit une priorité plus forte, tandis qu'un cours déjà terminé est moins favorisé. Si le score obtenu dépasse le seuil défini, l'agent génère une recommandation de cours, de leçon ou de révision selon le contexte. Dans le cas contraire, il propose simplement un sujet à retravailler. Le déroulement détaillé de cet agent est présenté dans la figure 2.13.

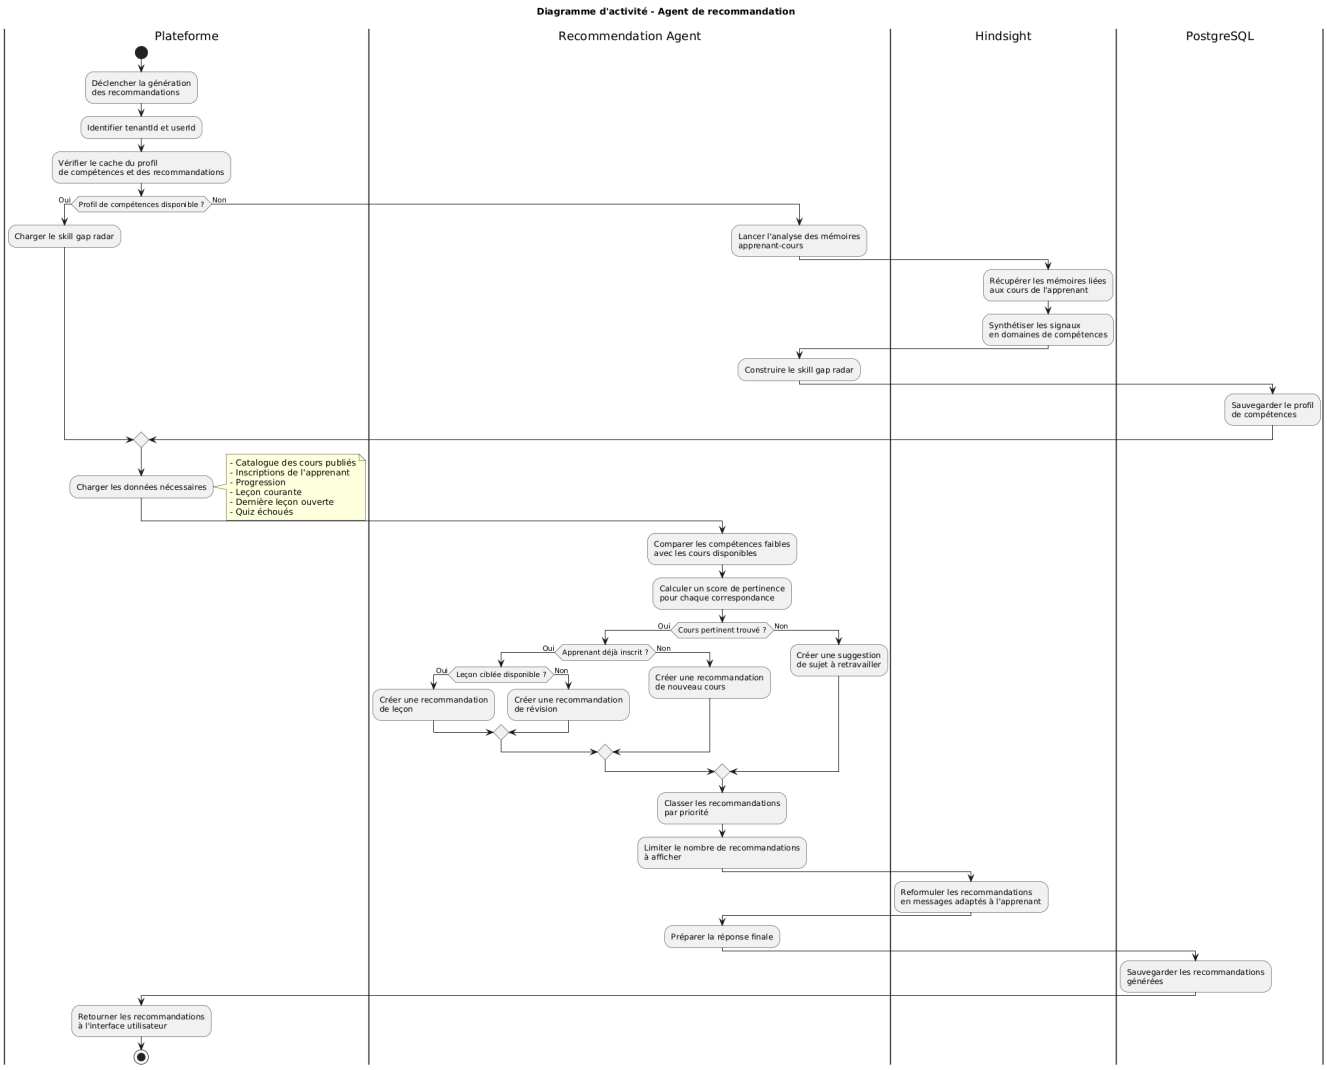


FIGURE 2.13 – Diagramme d'activité UML de l'agent de recommandation

2.4.5.5 Agent de défis personnalisés

Cet agent, appelé *Solo Challenge Agent*, est lancé automatiquement lorsque l'utilisateur se connecte et accède à la plateforme. Son rôle est de préparer une courte activité personnalisée, généralement sous forme d'une question à choix multiples, afin de renforcer une notion liée au parcours réel de l'apprenant. Au démarrage, la plateforme transmet les informations d'identification de l'utilisateur, notamment le *tenantId*, le *userId* et le rôle. L'agent recherche ensuite le cours le plus pertinent pour le défi : il utilise en priorité le dernier cours publié auquel l'apprenant est inscrit, mais il peut basculer vers le cours d'un quiz échoué récent lorsque cette difficulté n'a pas encore été corrigée par un défi réussi.

L'agent interroge ensuite Hindsight avec l'opération *recall* sur la mémoire propre à l'apprenant et au cours, afin de récupérer les difficultés, confusions, mauvaises réponses et signaux pédagogiques déjà mémorisés. Ces éléments sont utilisés pour choisir le type de défi à générer. Cette décision est encadrée par le skill *solo-challenge-mode-selector*. Ce skill contient

les règles de sélection du mode de défi : il impose de choisir exactement un mode parmi *failed_ quiz_ reformulation*, *learner_ reported_ difficulty*, *course_ problem_ signal* et *general_ course_ reinforcer*
Le premier mode cible un quiz réellement échoué, le deuxième cible une difficulté explicitement déclarée par l'apprenant, le troisième exploite un signal de blocage détecté dans la mémoire, et le dernier sert de renforcement général lorsqu'aucune difficulté prioritaire n'est disponible.

Après la sélection du mode, l'agent charge le skill détaillé correspondant. Par exemple, le mode *failed_ quiz_ reformulation* demande de reformuler une question liée au concept échoué sans recopier l'énoncé original, tandis que le mode *learner_ reported_ difficulty* transforme une difficulté déclarée en question ciblée. La génération finale est réalisée avec Hindsight *reflect* sur la banque mémoire du cours. L'agent attend une réponse structurée contenant le titre du défi, l'introduction, l'énoncé, quatre options, la bonne réponse et une explication. Avant d'envoyer le défi à l'interface, la plateforme sauvegarde la tentative dans PostgreSQL, masque la bonne réponse côté client, puis vérifie la réponse de l'apprenant lors de la soumission. Le résultat est ensuite mémorisé par l'agent de mémoire apprenant afin d'enrichir les futures recommandations et les prochains défis. Le déroulement détaillé de cet agent est illustré par la figure 2.14.

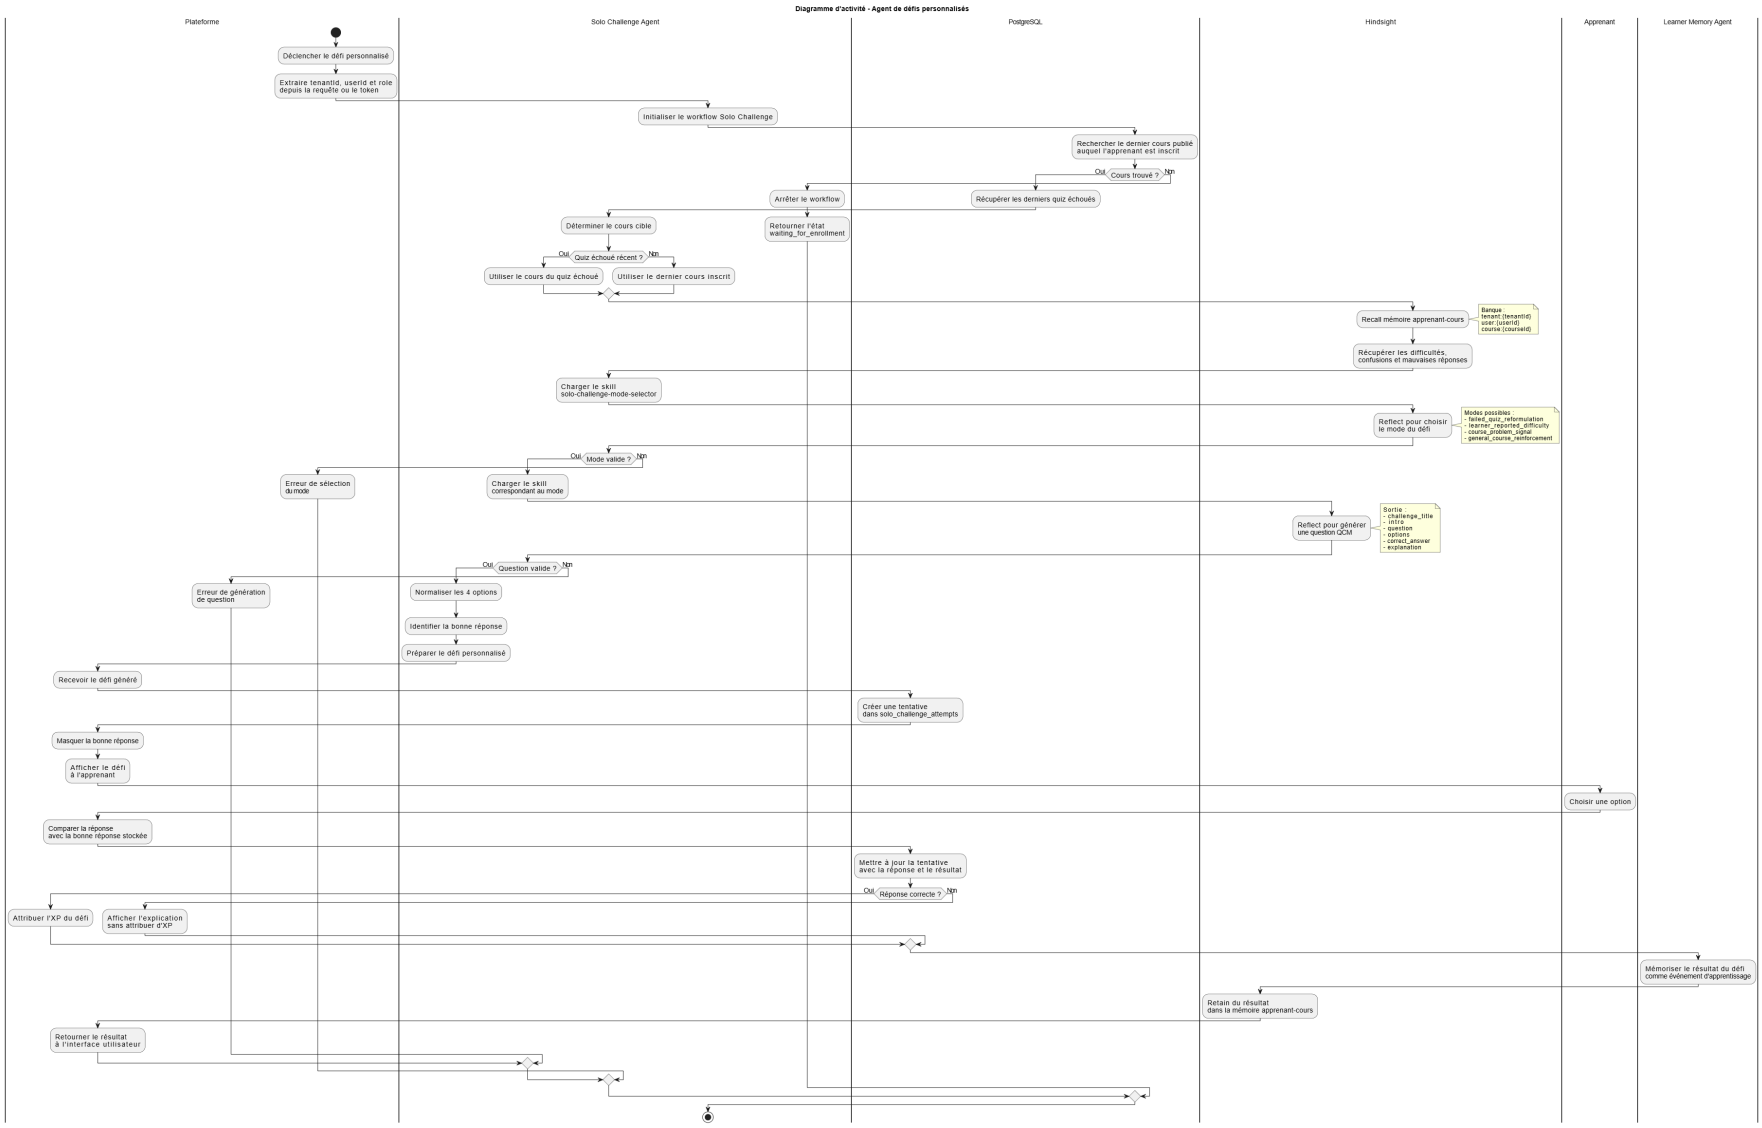


FIGURE 2.14 – Diagramme d'activité UML de l'agent de défis personnalisés

En conclusion, cette architecture met en place une couche IA structurée autour de workflows spécialisés, mais cohérents entre eux. Chaque traitement intelligent est déclenché dans un contexte précis, reçoit des données bien définies et produit une sortie exploitable par la plateforme. Cette séparation évite de concentrer toute la logique d'intelligence artificielle dans un seul composant et facilite le contrôle du comportement de chaque agent. Elle permet également d'assurer une personnalisation progressive du parcours apprenant, car les décisions prises par les agents s'appuient sur les événements réels de l'utilisation de la plateforme. Ainsi, l'architecture proposée ne se limite pas à ajouter des réponses générées par IA : elle organise l'IA comme une couche fonctionnelle intégrée au système, capable d'accompagner la création, le suivi, l'analyse et l'adaptation du parcours pédagogique.

2.5 Choix technologiques et justification

Cette section présente les principales technologies retenues pour la réalisation de la plateforme. L'objectif n'est pas seulement de lister les outils utilisés, mais de justifier leur choix par rapport aux besoins techniques du projet et aux alternatives possibles.

2.5.1 Stack frontend et backend

La plateforme repose sur une stack web séparant l'interface utilisateur, les services backend et les traitements liés à l'intelligence artificielle. Les choix technologiques ont été effectués en tenant compte de la maintenabilité, de la modularité, de la compatibilité avec l'architecture microservices et de la facilité d'intégration avec les autres composants du système.

Le tableau 2.3 présente les principales technologies retenues pour le frontend et le backend, ainsi que leur rôle et leur justification technique.

TABLE 2.3 – Tableau comparatif des technologies frontend et backend retenues

Technologie	**Rôle dans le projet**	**Justification**
React	Construction des composants de l'interface utilisateur.	React permet de construire des interfaces modulaires à partir de composants réutilisables, ce qui facilite l'organisation des écrans et la maintenance de l'interface.
Next.js	Framework frontend basé sur React pour organiser les pages et les routes.	Next.js apporte une structure applicative au-dessus de React, avec un routage intégré et une meilleure organisation des pages, alors qu'une application React seule nécessite davantage de configuration.
FastAPI	Développement des microservices backend.	FastAPI s'intègre directement avec l'écosystème Python utilisé par les services IA et offre une définition rapide d'API REST typées, alors que NestJS aurait introduit une stack backend Node.js séparée.
Traefik	Routage des requêtes vers les services backend.	Traefik s'intègre facilement avec Docker et permet de centraliser le routage vers les différents services backend à partir de règles déclarées dans l'environnement de déploiement.

2.5.2 Bases de données, IA et infrastructure

Les choix liés au stockage, à la mémoire persistante, aux modèles d'IA et au déploiement ont été réalisés en fonction des contraintes du projet : cohérence des données, isolation par tenant, recherche sémantique, simplicité de déploiement et maîtrise des coûts.

Le tableau 2.4 synthétise les choix retenus pour les données, l'IA et l'infrastructure.

TABLE 2.4 – Tableau comparatif des technologies de données, IA et infrastructure

Technologie	**Rôle dans le projet**	**Justification**
PostgreSQL	Stockage des données relationnelles de la plateforme.	PostgreSQL est adapté aux données fortement liées, comme les utilisateurs, cours, inscriptions et progressions, car il garantit la cohérence relationnelle nécessaire au suivi pédagogique.
pgvector	Stockage et recherche des représentations vectorielles.	pgvector permet d'ajouter la recherche par similarité directement dans PostgreSQL, ce qui simplifie l'infrastructure et évite de maintenir un service de stockage vectoriel indépendant.

Technologie	**Rôle dans le projet**	**Justification**
MinIO	Stockage objet des fichiers pédagogiques volumineux.	MinIO permet de gérer efficacement les vidéos, images, PDF et supports de cours, tandis que PostgreSQL conserve uniquement les métadonnées et les références vers ces ressources.
Hindsight	Mémoire persistante exploitée par les agents IA.	Hindsight fournit des opérations dédiées à la mémorisation et à la récupération sémantique, ce qui permet d'exploiter une mémoire plus structurée qu'un simple historique de conversation.
Agno	Orchestration des agents IA et structuration de leurs workflows.	Agno permet d'organiser les agents autour de rôles, d'outils et de workflows explicites, ce qui facilite la maintenance des traitements IA et leur intégration dans la plateforme.
OpenRouter / LLM	Accès au modèle de langage principal utilisé par les fonctionnalités IA.	OpenRouter permet d'utiliser un modèle performant et accessible hors réseau interne, tout en conservant le modèle local de l'entreprise comme solution de secours lorsque le contexte le permet.
RabbitMQ	Gestion des échanges asynchrones entre certains services.	RabbitMQ permet de traiter des événements métier sans bloquer directement le parcours utilisateur, ce qui convient aux notifications et aux traitements déclenchés en arrière-plan.
Redis	Stockage temporaire de contextes préparés pour certains agents IA.	Redis est adapté aux données intermédiaires et temporaires, tandis que PostgreSQL reste réservé aux données métier persistantes nécessitant une cohérence relationnelle.
Piper	Génération audio locale pour la synthèse vocale des contenus.	Piper permet de produire des voix de synthèse dans l'environnement de déploiement, ce qui limite la dépendance à un service externe pour la génération audio.
Docker / Docker Compose	Conteneurisation et orchestration locale des services de la plateforme.	Docker isole les services dans des conteneurs reproductibles, tandis que Docker Compose facilite leur lancement coordonné dans un même environnement.

2.6 Conclusion

Ce chapitre a permis de poser les bases nécessaires à la conception de la plateforme proposée. Les notions liées à l'intelligence artificielle ont été abordées en relation directe avec les besoins du projet, notamment la personnalisation des parcours, l'assistance des utilisateurs et l'exploitation du contexte d'apprentissage. Cette analyse a permis de montrer que les fonctionnalités intelligentes ne constituent pas un ajout isolé, mais un élément intégré au fonctionnement global de la solution.

La conception présentée dans ce chapitre met en évidence une architecture organisée autour de responsabilités clairement séparées. Cette organisation facilite l'évolution de la plateforme, l'intégration des agents IA, la gestion de la mémoire persistante et l'isolation des données entre les différentes organisations. Les choix technologiques retenus viennent soutenir cette architecture en répondant aux contraintes de modularité, de traçabilité, de recherche sémantique et de déploiement.

Ainsi, ce chapitre établit le cadre conceptuel et architectural sur lequel repose la réalisation de la plateforme. Le chapitre suivant sera consacré à la mise en oeuvre de la solution, à travers la présentation des principales fonctionnalités développées et de leur fonctionnement dans l'environnement applicatif.

Bibliographie

[13] International Organization for Standardization, *ISO/IEC 25010 : Systems and software engineering – Systems and software Quality Requirements and Evaluation (SQuaRE) – System and software quality models*, International Standard, 2011.

[14] S. Bourguignon, "Spec-driven development, agents IA : le nouveau modèle qui bouscule les organisations produit," *Journal du Net*, mars 2026, Chronique Sopra Steria Next. adresse : https://www.journaldunet.com/intelligence-artificielle/1548579-spec-driven-development-agents-ia-le-nouveau-modele-qui-bouscule-les-organisations-produit/

[16] A. Sarkar et I. Drosos, "Vibe Coding : Programming Through Conversation with Artificial Intelligence," in *Proceedings of the 36th Annual Conference of the Psychology of Programming Interest Group*, arXiv :2506.23253, 2025. doi : 10.48550/arXiv.2506.23253 adresse : https://arxiv.org/abs/2506.23253

[17] Amazon Web Services, *AI-Driven Development Life Cycle : Reimagining Software Engineering*, AWS DevOps & Developer Productivity Blog, juill. 2025. adresse : https://aws.amazon.com/blogs/devops/ai-driven-development-life-cycle/

[18] Amazon Web Services, *Open-Sourcing Adaptive Workflows for AI-DLC*, AWS DevOps & Developer Productivity Blog, nov. 2025. adresse : https://aws.amazon.com/blogs/devops/open-sourcing-adaptive-workflows-for-ai-driven-development-life-cycle-ai-dlc/

[23] Cloudflare. "What is a Large Language Model (LLM) ?" Cloudflare Learning Center. adresse : https://www.cloudflare.com/fr-fr/learning/ai/what-is-large-language-model/

[24] OpenAI. "Introducing gpt-oss." Documentation officielle OpenAI. adresse : https://openai.com/index/introducing-gpt-oss

[25] OpenRouter. "OpenAI : gpt-oss-120b (free)." Page officielle OpenRouter du modèle et de sa tarification. adresse : https://openrouter.ai/openai/gpt-oss-120b%3Afree

[26] OpenAI. "Introducing GPT-5.4 mini and nano." Présentation officielle du modèle GPT-5.4 mini. adresse : https://openai.com/index/introducing-gpt-5-4-mini-and-nano/

[28] ANTHROPIC. "Claude Haiku." Documentation officielle Anthropic. adresse : https://www.anthropic.com/claude/haiku

[29] ANTHROPIC. "Claude Haiku 4.5 System Card." Fiche système officielle Claude Haiku 4.5. adresse : https://www-cdn.anthropic.com/7aad69bf12627d42234e01ee7c36305dc2f6a970.pdf

[30] ANTHROPIC. "Pricing." Tarification officielle Anthropic. adresse : https://docs.anthropic.com/en/docs/about-claude/pricing

[31] CLOUDFLARE. "Gemini 3.1 Flash Lite." Documentation Cloudflare du modèle Gemini 3.1 Flash Lite. adresse : https://developers.cloudflare.com/ai/models/google/gemini-3.1-flash-lite/

[33] GROQ. "Llama 3.1 8B." Documentation officielle Groq du modèle llama-3.1-8b-instant. adresse : https://console.groq.com/docs/model/llama-3.1-8b-instant

[34] GROQ. "On-Demand Pricing for Tokens-as-a-Service." Tarification officielle Groq. adresse : https://groq.com/pricing

[35] MISTRAL AI. "Mistral Small 4." Fiche modèle officielle Mistral Small 4. adresse : https://docs.mistral.ai/models/model-cards/mistral-small-4-0-26-03

[41] IBM. "Qu'est-ce que l'incorporation ?" IBM Think. adresse : https://www.ibm.com/fr-fr/think/topics/embedding

[42] BAAI. "BAAI/bge-small-en-v1.5." Hugging Face Model Card. adresse : https://huggingface.co/BAAI/bge-small-en-v1.5

[43] OPENAI. "Vector embeddings." Documentation officielle OpenAI. adresse : https://platform.openai.com/docs/guides/embeddings

[45] MISTRAL AI. "Text Embeddings." Documentation officielle Mistral AI. adresse : https://docs.mistral.ai/capabilities/embeddings/text_embeddings/

[47] COHERE. "Cohere's Embed Models." Documentation officielle Cohere. adresse : https://docs.cohere.com/docs/cohere-embed

[49] GOOGLE CLOUD. "Get text embeddings." Documentation officielle Vertex AI. adresse : https://cloud.google.com/vertex-ai/generative-ai/docs/embeddings/get-text-embeddings

[62] et AL., "From Today's Code to Tomorrow's Symphony : The AI Transformation of Developer's Routine by 2030," *ACM Transactions on Software Engineering and Methodology*, 2025. DOI : 10.1145/3709353

[70] A. VASWANI et al., "Attention Is All You Need," in *Advances in Neural Information Processing Systems*, t. 30, 2017. adresse : https://arxiv.org/abs/1706.03762

[71] T. B. Brown et al., "Language Models are Few-Shot Learners," in *Advances in Neural Information Processing Systems*, t. 33, 2020, p. 1877-1901. adresse : https://arxiv.org/abs/2005.14165

[72] IBM. "Qu'est-ce que le traitement automatique du langage naturel ?" IBM Think. adresse : https://www.ibm.com/fr-fr/think/topics/natural-language-processing

[74] OpenAI. "GPT-4o mini." Documentation officielle OpenAI. adresse : https://developers.openai.com/api/docs/models/gpt-4o-mini

[75] Google Cloud. "Gemini 2.5 Flash." Documentation officielle Google Cloud. adresse : https://cloud.google.com/vertex-ai/generative-ai/docs/models/gemini/2-5-flash

[76] T. Mikolov, K. Chen, G. Corrado et J. Dean, "Efficient Estimation of Word Representations in Vector Space," in *International Conference on Learning Representations*, 2013. adresse : https://arxiv.org/abs/1301.3781

[77] I. Goodfellow et al., "Generative Adversarial Nets," in *Advances in Neural Information Processing Systems*, t. 27, 2014.

[78] P. Lewis et al., "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," in *Advances in Neural Information Processing Systems*, t. 33, 2020.

[79] M. Wooldridge et N. R. Jennings, "Intelligent Agents : Theory and Practice," *The Knowledge Engineering Review*, t. 10, n° 2, p. 115-152, 1995. doi : 10.1017/S0269888900008122

[80] S. Yao et al., "ReAct : Synergizing Reasoning and Acting in Language Models," in *International Conference on Learning Representations*, 2023.

Webographie

[1] 3S, *Site officiel de 3S*, https://www.3s.com.tn/, Dernier accès : Mai 2026, 2026.

[2] Groupe 3S, *Site officiel de Groupe 3S*, https://www.3sgroup.tn/, Dernier accès : Mai 2026, 2026.

[3] Google, *Google Skills Platform Overview and Features*, https://skills.google/, Dernier accès : Mai 2026, 2026.

[4] Duolingo, *Duolingo*, https://about.duolingo.com/, Dernier accès : Mai 2026, 2026.

[5] 360Learning, *360Learning AI-Powered Learning Platform Features*, https://360learning.com/, Dernier accès : Mai 2026, 2026.

[6] CYPHER Learning, *CYPHER Copilot and AI Learning Automation Features*, https://www.cypherlearning.com/platform, Dernier accès : Mai 2026, 2026.

[7] THU-MAIC, *OpenMAIC - Open Multi-Agent AI Classroom System*, https://github.com/THU-MAIC/OpenMAIC, Demo : https://open.maic.chat/, Dernier accès : Mai 2026, 2026.

[8] Moodle, *Moodle LMS - Open Source Learning Platform*, https://github.com/moodle/moodle, Site web : https://moodle.org/, Dernier accès : Mai 2026, 2026.

[9] Google, *Google Skills - Pricing Plans*, https://www.skills.google/payments/new, Dernier accès : Mai 2026, 2026.

[10] Duolingo, *Duolingo Super and Max Plans*, https://www.duolingo.com/super, Dernier accès : Mai 2026, 2026.

[11] 360Learning, *360Learning Pricing Plans*, https://360learning.com/pricing/, Dernier accès : Mai 2026, 2026.

[12] CYPHER Learning, *CYPHER Learning Pricing Plans*, https://www.cypherlearning.com/pricing, Dernier accès : Mai 2026, 2026.

[15] A. Mishra et Raja, *AI-Driven Development Lifecycle (AI-DLC)*, AWS re :Invent 2025, Session DVT214, Voir à 14 :26, déc. 2025. adresse : https://www.youtube.com/watch?v=1HNUH6j5t4A&t=866

[19] GitHub, *Spec Kit — Toolkit for Spec-Driven Development*, GitHub, 2025. adresse : https://github.com/github/spec-kit

[20] BMad Code, *BMAD Method — Breakthrough Method for Agile AI-Driven Development*, Documentation officielle, 2025. adresse : https://docs.bmad-method.org/

[21] TACHES / gsd-build, *GSD — Get Shit Done Framework*, GitHub, 2026. adresse : https://github.com/gsd-build/get-shit-done

[22] Amazon Web Services, *Kiro — Spec-Driven Development IDE*, AWS, 2025. adresse : https://kiro.dev

[27] OpenAI. "API Pricing." Tarification officielle de l'API OpenAI. adresse : https://openai.com/api/pricing/

[32] Google. "Gemini Developer API Pricing." Tarification officielle de l'API Gemini. adresse : https://ai.google.dev/gemini-api/docs/pricing

[36] Mistral AI. "Pricing." Tarification officielle Mistral AI. adresse : https://mistral.ai/pricing/

[37] Google Cloud. "Qu'est-ce qu'un agent IA ?" Visité le 3 juin 2026. adresse : https://cloud.google.com/discover/what-are-ai-agents?hl=fr

[38] Google Cloud. "Qu'est-ce qu'un système multi-agents en IA ?" Visité le 3 juin 2026. adresse : https://cloud.google.com/discover/what-is-a-multi-agent-system?hl=fr

[39] Amazon Web Services. "Qu'est-ce que la RAG (génération à enrichissement contextuel) ?" Visité le 4 juin 2026. adresse : https://aws.amazon.com/fr/what-is/retrieval-augmented-generation/

[40] IBM. "Qu'est-ce que la RAG agentique ?" Visité le 4 juin 2026. adresse : https://www.ibm.com/fr-fr/think/topics/agentic-rag

[44] OpenAI. "text-embedding-3-large Model." Page officielle indiquant aussi le coût de text-embedding-3-small dans la comparaison rapide. adresse : https://developers.openai.com/api/docs/models/text-embedding-3-large

[46] Mistral AI. "Mistral Embed." Fiche officielle du modèle indiquant le prix de Mistral Embed. adresse : https://docs.mistral.ai/models/model-cards/mistral-embed-23-12

[48] Cohere. "Pricing." Page officielle de tarification Cohere. adresse : https://cohere.com/pricing

[50] Vectorize.io. "Hindsight Models." Documentation officielle Hindsight. adresse : https://hindsight.vectorize.io/0.5/developer/models

[51] KERN-IT. "System Prompt : Qu'est-ce qu'un system prompt ?" Visité le 3 juin 2026. adresse : https://www.kern-it.be/fr/definitions/system-prompt/

[52] Agent Skills. "Agent Skills Overview," visité le 3 juin 2026. adresse : https://agentskills.io/home

[53] VECTORIZE.IO. "Hindsight," visité le 3 juin 2026. adresse : https://hindsight.vectorize.io/

[54] VECTORIZE.IO. "Hindsight GitHub Repository," visité le 3 juin 2026. adresse : https://github.com/vectorize-io/hindsight

[55] VECTORIZE.IO. "Retain : How Hindsight Stores Memories," visité le 3 juin 2026. adresse : https://hindsight.vectorize.io/0.4/developer/retain

[56] VECTORIZE.IO. "Recall : Retrieving Memories," visité le 3 juin 2026. adresse : https://docs.hindsight.vectorize.io/recall/

[57] VECTORIZE.IO. "Reflect : Reasoning Over Memories," visité le 3 juin 2026. adresse : https://docs.hindsight.vectorize.io/reflect/

[58] MEDIMAGH. "Comprendre l'architecture multitenant," visité le 7 juin 2026. adresse : https://medimagh.wordpress.com/comprendre-l-architecture-multitenant/

[59] THU-MAIC, *OpenMAIC System Documentation and Demo Platform*, https://open.maic.chat/, Dernier accès : Mai 2026, 2025.

[60] MCKINSEY & COMPANY, *The State of AI 2024*, https://www.mckinsey.com/capabilities/quantumblack/our-insights/the-state-of-ai, Dernier accès : Mai 2026, 2024.

[61] BAYTECH CONSULTING, *Agentic SDLC : The AI-Powered Blueprint Transforming Software Development*, https://www.baytechconsulting.com/blog/agentic-sdlc-ai-software-blueprint, Dernier accès : Mai 2026, 2025.

[63] STACK OVERFLOW, *Stack Overflow Developer Survey 2025*, https://survey.stackoverflow.co/2025, Dernier accès : Mai 2026, 2025.

[64] BCMS, *Spec-Driven Development (SDD) : The Definitive 2026 Guide*, https://thebcms.com/blog/spec-driven-development, Dernier accès : Mai 2026, 2026.

[65] ET AL., *Spec-Driven Development : From Code to Contract in the Age of AI Coding Assistants*, https://arxiv.org/abs/2602.00180, Dernier accès : Mai 2026, 2026.

[66] MICROSOFT, *An AI-led SDLC : Building an End-to-End Agentic Software Development Lifecycle*, https://techcommunity.microsoft.com/blog/appsonazureblog/an-ai-led-sdlc-building-an-end-to-end-agentic-software-development-lifecycle-wit/4491896, Dernier accès : Mai 2026, 2026.

[67] AUGMENT CODE, *What Is Spec-Driven Development ? A Complete Guide*, https://www.augmentcode.com/guides/what-is-spec-driven-development, Dernier accès : Mai 2026, 2026.

[68] J. HAMADE, *Architecting the Future : Planning and Tooling the AI-Driven SDLC*, https://medium.com/@justhamade/architecting-the-future-planning-and-tooling-the-ai-driven-sdlc-334dcd02a4c9, Dernier accès : Mai 2026, 2025.

[69] IJERET, *AI-Powered Software Development Life Cycle : From Requirements to Maintenance*, https://ijeret.org/index.php/ijeret/article/download/340/322, Dernier accès : Mai 2026, 2025.

[73] VECTORIZE.IO. "Hindsight Configuration." Documentation officielle Hindsight. adresse : https://hindsight.vectorize.io/0.5/developer/configuration

[81] VECTORIZE.IO. "Hindsight Agent Memory Skill | AI Coding Assistant Integration," visité le 3 juin 2026. adresse : https://hindsight.vectorize.io/0.5/sdks/integrations/skills